

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería



**Identificación de espacio sin aprovechar en
imágenes aéreas de surcos de cultivos a través de
algoritmos de detección de líneas.**

Trabajo profesional de graduación presentado por Adrián Ricardo Flores Trujillo para optar al grado académico de Licenciado en Ingeniería en Ciencia de la Computación y Tecnologías de la Información

Guatemala,
2025

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería



**Identificación de espacio sin aprovechar en
imágenes aéreas de surcos de cultivos a través de
algoritmos de detección de líneas.**

Trabajo profesional de graduación presentado por Adrián Ricardo Flores Trujillo para optar al grado académico de Licenciado en Ingeniería en Ciencia de la Computación y Tecnologías de la Información

Guatemala,
2025

Vo.Bo.:

(f) _____
MSc. Alan Reyes

Tribunal Examinador:

(f) _____
MSc. Alan Reyes

(f) _____
Ing. Marlón Osiris Fuentes López

Fecha de aprobación: Guatemala, 21 de noviembre de 2025.

Índice

Lista de Figuras	vii
Lista de Cuadros	viii
Lista de Abreviaturas y Siglas	ix
Resumen	x
Abstract	xi
1. Introducción	1
2. Objetivos	2
2.1. Objetivo General	2
2.2. Objetivos Específicos	2
3. Justificación	3
4. Marco Teórico	4
4.1. Transformada de Hough	4
4.1.1. Transformada de Hough Convencional	4
4.1.2. Transformada de Hough Probabilística	6
4.2. Análisis de Componentes Principales	7
4.2.1. PCA para el Procesamiento de Imágenes	8
4.3. Transformada de Fourier	10
4.3.1. Análisis de Frecuencia en Imágenes	11
5. Metodología	14
5.1. Estimación de la orientación principal	15
5.1.1. Transformada de Hough	15
5.1.2. Detección de líneas mediante Análisis de Componentes Principales (PCA) . .	19
5.1.3. Detección de líneas mediante Transformada de Fourier	23
5.2. Detección de espacios vacíos	29
6. Resultados	32
6.0.1. Caso base de evaluación de algoritmos	32
7. Discusión de Resultados	71

8. Conclusiones	73
9. Recomendaciones	75
Bibliografía	77

Lista de Figuras

4.1. Dos puntos colineares a una línea (izquierda) y su representación en el plano paramétrico (derecha).	5
4.2. Esquema de detección de líneas rectas mediante PCA.	8
4.3. Imagen espacial de una persona en escala de grises.	12
4.4. Espectro de magnitud (escala logarítmica).	12
4.5. Espectro de fase.	12
4.6. Imagen espacial de líneas diagonales.	13
4.7. Espectro de magnitud (escala logarítmica).	13
4.8. Espectro de fase.	13
5.1. Ejemplo de imagen RGB y su versión binarizada.	14
5.2. Esquema de detección de líneas utilizando la Transformada de Hough.	15
5.3. Líneas detectadas antes del agrupamiento con MeanShift.	16
5.4. Líneas detectadas después del agrupamiento con MeanShift.	16
5.5. Ejemplo de detección incompleta con líneas excesivamente separadas.	17
5.6. Conjunto final de líneas tras la extrapolación de los extremos y la inserción de líneas faltantes.	18
5.7. Esquema de detección de líneas utilizando PCA.	20
5.8. Ejemplo de resultado de la aplicación de PCA sobre el componente conectado más grande.	20
5.9. Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul).	22
5.10. Conjunto de líneas tras agrupamiento y eliminación de redundancia.	22
5.11. Conjunto final tras relleno de líneas faltantes (verde).	23
5.12. Espectros de magnitud y fase resultantes de imagen binarizada.	24
5.13. Puntos de mayor intensidad sobrepuertos al espectro de magnitud.	24
5.14. Resultado de la regresión lineal aplicada a los puntos más intensos del espectro.	25
5.15. Ejemplo de línea con ángulo correcto.	26
5.16. Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul) utilizando ángulo de Fourier.	27
5.17. Conjunto de líneas final luego de agrupamiento y relleno.	27
5.18. Ejemplo de caso donde el ángulo obtenido mediante Fourier difiere significativamente del esperado.	28
5.19. Puntos más intensos en el espectro de magnitud del caso de ejemplo fallido.	28
5.20. Resultado de la aplicación conjunta de la Transformada de Hough sobre el espectro de Fourier.	29
5.21. Visualización de los espacios vacíos detectados a lo largo de las líneas.	31

5.22. Visualización de los espacios vacíos detectados a lo largo de las líneas. Las cajas rojas indican los píxeles escaneados pertenecientes a segmentos vacíos.	31
6.1. Imagen de caso ideal.	32
6.2. Líneas detectadas mediante la Transformada de Hough (rojo) y líneas rellenas por inferencia (verde).	33
6.3. Espacios vacíos detectados.	33
6.4. Espacios vacíos visualizados por su área escaneada.	33
6.5. Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul) para $k = 10$	34
6.6. Líneas detectadas (rojo) y líneas rellenas por inferencia (verde) para $k = 10$	34
6.7. Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul) para $k = 5$	35
6.8. Línea de escaneo (rojo) y surcos detectados previo al agrupamiento (azul) para $k = 0$	35
6.9. Líneas detectadas (rojo) y líneas rellenas por inferencia (verde) para $k = 0$	35
6.10. Espectros de magnitud y fase resultantes de la imagen binarizada.	36
6.11. Puntos de mayor intensidad sobrepuertos al espectro de magnitud.	36
6.12. Línea arbitraria con ángulo resultante del análisis en el dominio de Fourier.	37
6.13. Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul).	37
6.14. Líneas detectadas (rojo) y líneas rellenas por inferencia (verde).	38
6.15. Espacios vacíos visualizados por su área escaneada.	38
6.16. Primera imagen aérea.	39
6.17. Máscara aplicada a imagen binaria.	39
6.18. Líneas detectadas e inferidas por el algoritmo basado en la Transformada de Hough.	40
6.19. Espacios vacíos detectados con el algoritmo basado en la Transformada de Hough.	40
6.20. Líneas de escaneo determinadas a partir del ángulo estimado por PCA.	41
6.21. Líneas detectadas e inferidas por el algoritmo basado en PCA.	42
6.22. Espacios vacíos detectados con el algoritmo basado en PCA.	42
6.23. Espectro de magnitud (escala logarítmica) y puntos de mayor intensidad.	43
6.24. Líneas de escaneo determinadas mediante la Transformada de Fourier.	44
6.25. Líneas detectadas e inferidas por el algoritmo basado en la Transformada de Fourier.	44
6.26. Espacios vacíos detectados mediante la Transformada de Fourier.	45
6.27. Segunda imagen aérea.	46
6.28. Líneas detectadas e inferidas mediante la Transformada de Hough.	46
6.29. Espacios vacíos detectados con la Transformada de Hough.	47
6.30. Líneas de escaneo con ángulo determinado mediante PCA.	48
6.31. Líneas detectadas e inferidas mediante PCA.	48
6.32. Espacios vacíos detectados mediante PCA.	49
6.33. Espectro de magnitud (escala logarítmica) y puntos más intensos.	49
6.34. Líneas de escaneo con ángulo determinado por la Transformada de Fourier.	50
6.35. Líneas detectadas e inferidas mediante la Transformada de Fourier.	51
6.36. Espacios vacíos detectados mediante la Transformada de Fourier.	51
6.37. Tercera imagen aérea.	52
6.38. Máscara aplicada a imagen binaria.	52
6.39. Líneas detectadas e inferidas por algoritmo con Transformada de Hough.	53
6.40. Espacios vacíos detectados con Transformada de Hough.	53
6.41. Líneas de escaneo con ángulo determinado por PCA.	54
6.42. Líneas detectadas e inferidas por algoritmo con PCA.	54
6.43. Espacios vacíos detectados con PCA.	55
6.44. Espectro de magnitud (escala logarítmica) y puntos más intensos.	56
6.45. Líneas de escaneo con ángulo determinado por Transformada de Fourier.	57
6.46. Líneas detectadas e inferidas por algoritmo con Transformada de Fourier.	57
6.47. Espacios vacíos detectados con Transformada de Fourier.	58
6.48. Cuarta imagen aérea.	58

6.49. Líneas detectadas e inferidas por algoritmo con Transformada de Hough.	59
6.50. Espacios vacíos detectados con Transformada de Hough.	59
6.51. Líneas de escaneo con ángulo determinado por PCA.	60
6.52. Líneas detectadas e inferidas por algoritmo con PCA.	60
6.53. Espacios vacíos detectados con PCA.	61
6.54. Espectro de magnitud (escala logarítmica) y puntos más intensos.	61
6.55. Líneas de escaneo con ángulo determinado por Transformada de Fourier.	62
6.56. Líneas detectadas e inferidas por algoritmo con Transformada de Fourier.	62
6.57. Espacios vacíos detectados con Transformada de Fourier.	63
6.58. Quinta imagen aérea.	64
6.59. Máscara aplicada a la imagen binaria.	64
6.60. Líneas detectadas e inferidas por el algoritmo con Transformada de Hough.	65
6.61. Espacios vacíos detectados con Transformada de Hough.	65
6.62. Líneas de escaneo con ángulo determinado por PCA.	66
6.63. Líneas detectadas e inferidas por el algoritmo con PCA.	66
6.64. Espacios vacíos detectados con PCA.	67
6.65. Espectro de magnitud (escala logarítmica) y puntos más intensos.	68
6.66. Líneas de escaneo con ángulo determinado por Transformada de Fourier.	69
6.67. Líneas detectadas e inferidas por el algoritmo con Transformada de Fourier.	69
6.68. Espacios vacíos detectados con Transformada de Fourier.	70

Lista de Cuadros

6.1.	Comparativa de algoritmos de detección y relleno de líneas.	38
6.2.	Métricas de desempeño para los algoritmos aplicados a la primera imagen real.	45
6.3.	Métricas comparativas de los tres métodos para la segunda imagen.	51
6.4.	Resultados de detección de espacios vacíos para la tercera imagen.	58
6.5.	Resultados de detección de espacios vacíos para la cuarta imagen.	63
6.6.	Resultados cuantitativos para la quinta imagen.	70

Lista de Abreviaturas y Siglas

FFT Fast Fourier Transform (Transformada Rápida de Fourier).

PCA Principal Component Analysis (Análisis de Componentes Principales).

RGB Red, Green, Blue (Rojo, Verde y Azul).

UAV Unmanned Aerial Vehicle (Vehículo Aéreo No Tripulado).

Resumen

El presente trabajo desarrolla un método automatizado para la identificación de fallos en surcos de cultivos a partir de imágenes aéreas. El objetivo principal fue obtener métricas de aprovechamiento del espacio de siembra mediante la detección de líneas y la cuantificación de espacios vacíos. Para ello, se diseñó un procedimiento que combina técnicas de procesamiento digital de imágenes y análisis geométrico, aplicando distintas transformaciones para la detección de surcos y un algoritmo de evaluación de discontinuidades a lo largo de cada línea. A partir de estas detecciones, se calcularon métricas físicas basadas en los metadatos espaciales de las imágenes, lo que permitió cuantificar con precisión la extensión de los fallos de cultivo.

Los resultados demostraron que el método propuesto permite identificar interrupciones significativas en los surcos, incluso en escenarios con ruido o irregularidades estructurales. Las representaciones visuales generadas facilitan la interpretación de las zonas con bajo aprovechamiento del terreno, contribuyendo así al monitoreo eficiente de los cultivos.

Se concluye que el sistema cumple con los objetivos planteados al ofrecer una herramienta precisa y adaptable para el análisis automatizado de cultivos. Asimismo, se recomienda mejorar las etapas de segmentación y binarización, automatizar la selección de parámetros y optimizar el filtrado de líneas redundantes para incrementar la robustez y escalabilidad del método en futuras aplicaciones agrícolas.

Abstract

This work presents an automated method for identifying crop row failures using aerial imagery. The main objective was to obtain planting-space utilization metrics through line detection and quantification of empty areas. To achieve this, a procedure was designed that combines digital image processing and geometric analysis techniques, applying different transformations for row detection and an algorithm for evaluating discontinuities along each line. Based on these detections, physical metrics were calculated using the spatial metadata of the images, allowing for precise quantification of cultivation gaps.

The results demonstrated that the proposed method effectively identifies significant interruptions in crop rows, even in scenarios with some noise or structural irregularities. The generated visual representations facilitate the interpretation of areas with low land utilization, thus contributing to efficient crop monitoring.

It is concluded that the system meets the established objectives by providing an accurate and adaptable tool for automated crop analysis. Furthermore, it is recommended to improve the segmentation and binarization stages, automate parameter selection, and optimize redundant line filtering to enhance the robustness and scalability of the method for future agricultural applications.

CAPÍTULO 1

Introducción

La agricultura es la principal actividad económica en Guatemala y una fuente esencial de recursos para la alimentación y la industria (Banco de Guatemala, n.d.). En la producción a gran escala, el monitoreo eficiente de los cultivos es fundamental para optimizar la gestión de recursos y maximizar el rendimiento. Tradicionalmente, la inspección de cultivos ha sido un proceso manual que requiere tiempo y esfuerzo, lo que dificulta la detección temprana de problemas como la ausencia de plantas en la franja de siembra, conocida como un fallo (Oliveira et al., 2018).

El uso de vehículos aéreos no tripulados (UAVs) ha transformado la agricultura moderna al permitir un monitoreo eficiente de los cultivos a gran escala. Gracias a su capacidad para capturar imágenes aéreas de alta resolución, los UAVs han facilitado la detección temprana de problemas en el campo, como estrés hídrico, enfermedades y fallos en la siembra (Rejeb et al., 2022). Estas tecnologías han demostrado ser una alternativa más rápida y económica en comparación con las inspecciones manuales o el uso de imágenes satelitales, que pueden verse afectadas por condiciones climáticas y resoluciones limitadas (Sishodia et al., 2020).

Por otro lado, los avances en visión por computadora han permitido desarrollar herramientas capaces de analizar imágenes agrícolas con un alto grado de precisión. Algoritmos de procesamiento de imágenes pueden segmentar cultivos, detectar patrones y extraer información relevante para la toma de decisiones agrícolas (Oliveira et al., 2018). En particular, la combinación de UAVs y visión computarizada abre nuevas oportunidades para mejorar la eficiencia en la detección de anomalías dentro de los surcos de siembra, optimizando la producción agrícola (Osco et al., 2021).

En este contexto, el presente estudio tiene como objetivo desarrollar un método para la identificación de fallos en imágenes aéreas de surcos de cultivos. Para ello, se diseñará un procedimiento que permita detectar los surcos en las imágenes, se compararán diferentes enfoques para la detección y cuantificación de fallos, y se generarán representaciones visuales con métricas que faciliten la interpretación de los resultados.

CAPÍTULO 2

Objetivos

2.1. Objetivo General

Desarrollar un método para identificar fallos en surcos de cultivos a partir de imágenes aéreas mediante algoritmos de detección de líneas.

2.2. Objetivos Específicos

- Diseñar un procedimiento para la detección de surcos de cultivos a través de algoritmos de detección de líneas.
- Comparar distintos enfoques para identificar fallos en surcos de cultivos a partir de imágenes aéreas.
- Generar representaciones visuales con métricas asociadas para la interpretación de los resultados obtenidos en la identificación y cuantificación de fallos en los cultivos.

CAPÍTULO 3

Justificación

La eficiencia en la agricultura es fundamental para garantizar la competitividad y sostenibilidad del sector. La adopción de prácticas eficientes no solo reduce los costos de producción, sino que también mejora la rentabilidad de las explotaciones agrícolas (Balafoutis et al., 2020). Por lo tanto, la implementación de tecnologías avanzadas y automatizadas para la agricultura a gran escala presenta grandes oportunidades de crecimiento en esta industria.

El desarrollo de métodos automáticos para la detección de fallos en cultivos es de gran importancia tanto en el ámbito científico como en el sector agrícola. Actualmente, el monitoreo de cultivos a partir de imágenes aéreas se basa en enfoques que requieren intervención humana o en métodos tradicionales como el uso de índices de vegetación. Sin embargo, estas estrategias pueden no ser lo suficientemente eficientes para identificar fallos en los surcos de siembra a gran escala, lo que justifica la necesidad de explorar técnicas más avanzadas (Gutiérrez et al., 2018).

Desde el punto de vista económico, la identificación temprana de fallos en los surcos permite a los agricultores tomar decisiones informadas para mejorar el manejo del terreno, reducir el desperdicio de insumos y maximizar la producción. Detectar áreas sin cultivo o con fallos en la siembra puede ayudar a optimizar la distribución de semillas, fertilizantes y agua, reduciendo costos y minimizando el impacto ambiental (Miyake & Bargiel, 2017).

Con este trabajo, se espera contribuir al desarrollo de herramientas más precisas y eficientes para el monitoreo de cultivos, ayudando a optimizar la producción agrícola mediante el uso de UAVs y visión por computadora. Adicionalmente, se busca automatizar este proceso de monitoreo para facilitar aún más el uso de la herramienta e incrementar la eficiencia en producciones agrícolas.

CAPÍTULO 4

Marco Teórico

4.1. Transformada de Hough

4.1.1. Transformada de Hough Convencional

En el procesamiento de imágenes y la extracción de características, la detección de figuras geométricas constituye un problema común. Para este fin, se han desarrollado diversos algoritmos, como el detector de bordes de Canny, que permite resaltar y separar los contornos de los objetos de una imagen. Sin embargo, este tipo de métodos no proporciona una descripción estructural de las formas detectadas, lo cual es una limitación importante. En muchos casos, se dispone de un mapa de bordes, pero no se cuenta con la información necesaria para describir ni localizar formalmente las figuras representadas (Gonzalez & Woods, 2018).

En estas situaciones, intentar interpretar y relacionar todos los píxeles de un mapa de bordes mediante un acercamiento ingenuo puede ser computacionalmente costoso, ya que la complejidad de procesar los puntos de una imagen crece de manera cuadrática (Duda & Hart, 1972). En imágenes grandes, este tipo de procesamiento se vuelve inviable.

Como alternativa, Hough (Hough, 1962) propone un método para el reconocimiento de patrones complejos en imágenes. Este enfoque consiste en interpretar cada punto de borde como el conjunto parametrizado de líneas que podrían pasar por él (Duda & Hart, 1972), utilizando la ecuación general de la recta:

$$x \cos(\theta) + y \sin(\theta) = \rho. \quad (4.1)$$

Esta parametrización a través del ángulo de la línea θ restringido a $[0, \pi]$ y su distancia del origen ρ permite que cada línea posible en el plano xy corresponda a un único punto del plano paramétrico $\rho\theta$. Bajo esta representación, cada punto en el mapa de ejes se convierte en una sola curva sinusoidal en el plano paramétrico (Duda & Hart, 1972). Por lo tanto, un conjunto de puntos $(x_1, y_1), \dots, (x_n, y_n)$ se transforma a un conjunto de curvas sinusoidales en el plano $\rho\theta$ definidas por:

$$\rho = x_i \cos(\theta) + y_i \sin(\theta). \quad (4.2)$$

En este plano, es fácil encontrar curvas correspondientes a puntos colineales a través de los puntos de intersección de estas. El punto de intersección (θ_0, ρ_0) define los parámetros de la línea que pasa a través de los puntos colineales en el plano xy (Duda & Hart, 1972), como se ilustra en la Figura 4.2.

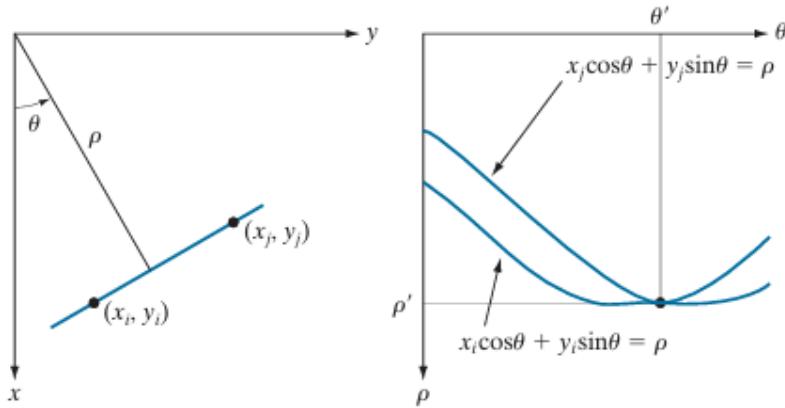


Figura 4.1: Dos puntos colineares a una línea (izquierda) y su representación en el plano paramétrico (derecha).

Reproducido de Digital Image Processing (4.a ed., p. 739), por R. C. Gonzalez y R. E. Woods, 2018, Pearson.

El acercamiento anterior describe únicamente la formulación matemática de la Transformada de Hough en un espacio continuo con un número reducido de puntos. Sin embargo, para su implementación computacional es necesario discretizar dicho espacio. Esto se logra subdividiendo el espacio paramétrico en una matriz de celdas acumuladoras, correspondiente a las coordenadas del plano paramétrico $A(\theta, \rho)$. Inicialmente, todas las celdas del arreglo acumulador se inicializan con un valor de cero. Luego, para cada punto detectado en el plano xy , se evalúan distintos valores de θ , determinados por la cantidad de subdivisiones del eje angular. Para cada valor θ_q se resuelve la ecuación de la recta en coordenadas polares para obtener el valor correspondiente de ρ . Este valor de ρ se aproxima al índice de la celda más cercana dentro del acumulador. Si para una combinación específica de θ_q y ρ_p se encuentra una coincidencia, entonces la celda correspondiente se incrementa:

$$A(p, q) = A(p, q) + 1. \quad (4.3)$$

Una vez procesados todos los puntos, el valor K en una celda $A(i, j)$ indica la cantidad de puntos en el plano xy que se alinean sobre la recta definida por la ecuación:

$$x \cos(\theta_j) + y \sin(\theta_j) = \rho_i. \quad (4.4)$$

(Gonzalez & Woods, 2018)

El número de subdivisiones del plano paramétrico define la precisión con la que se determina la colinealidad entre los puntos. Además, es posible establecer un umbral sobre K , el cual determina la certeza mínima requerida para considerar que una celda representa una línea válida dentro de la imagen.

4.1.2. Transformada de Hough Probabilística

La transformada de Hough convencional, definida como el algoritmo propuesto por Duda y Hart, 1972, pertenece a la familia de algoritmos uno a muchos, donde un solo punto en el mapa de bordes se transforma en múltiples puntos en el espacio paramétrico. Esta implementación utiliza el plano $\rho\theta$, generando un acumulador de $N_\rho \times N_\theta$ celdas, como se describió en la sección anterior. Durante la ejecución del algoritmo, se realiza una búsqueda exhaustiva sobre todas las celdas del acumulador para localizar máximos, lo que implica un costo computacional de $O(N_\rho \cdot N_\theta)$. Además, poblar el acumulador requiere $O(M \cdot N_\theta)$ operaciones, donde M representa la cantidad total de puntos en el mapa de bordes (Kiryati et al., 1991).

Kiryati et al., 1991 destacan que este acercamiento no suele presentar limitaciones importantes en imágenes de tamaño pequeño. Sin embargo, al trabajar con imágenes grandes, la cantidad de operaciones necesarias para las fases de población y búsqueda puede volverse restrictiva. Aunque una implementación paralela puede mitigar este problema, su aplicación depende de la disponibilidad de hardware especializado, el cual puede ser costoso o no ser accesible en todos los entornos.

Con el objetivo de reducir la carga computacional, Kiryati et al., 1991 proponen un acercamiento estocástico. Esta variante de la transformada de Hough se basa en la selección aleatoria de un subconjunto de m puntos del total de M disponibles en el mapa de bordes, con $m < M$. Esto reduce la complejidad a un número de operaciones proporcional a $m \cdot N_\theta$, y los autores destacan que se pueden obtener ahorros computacionales significativos si m se mantiene considerablemente menor que M . Además, si se cumple que $m < N_\rho$, la fase de búsqueda del acumulador puede optimizarse aún más mediante el método de Gerig, el cual reemplaza la búsqueda exhaustiva por una detección de picos guiada por sinusoides (Gerig, 1987). Es importante destacar que la elección de un valor óptimo para m depende del problema específico. Una estrategia sugerida por los autores consiste en identificar una característica prominente en la imagen que se manifieste como un máximo en el acumulador de la transformada de Hough convencional, para luego, mediante un proceso de prueba y error, determinar un valor de m que permita detectar dicho máximo con alta probabilidad (Kiryati et al., 1991).

Es evidente que depender de conocimiento *a priori*, como el valor de m , no es factible en la mayoría de los casos, especialmente en aplicaciones en tiempo real. Generalmente, se utiliza un valor de m que puede ser óptimo para ciertas imágenes, pero que en otras puede conducir a falsos negativos (características faltantes) o al desperdicio de recursos computacionales. Estas desventajas implican que, sin conocimiento previo de m , se reducen significativamente los beneficios de un enfoque estocástico (Matas et al., 2000).

Para abordar este problema, Matas et al. (2000) proponen la Transformada de Hough Probabilística Progresiva (PPHT). Inicialmente, el algoritmo selecciona un punto aleatorio del mapa de bordes, lo elimina de la imagen y procede a emitir su voto correspondiente en el acumulador. Luego de emitir el voto, se realiza una prueba para verificar si, habiendo muestrado m de M puntos, existe una celda en el acumulador que excede el umbral l , con el fin de determinar si la línea detectada podría deberse únicamente a ruido aleatorio. En este proceso, el valor de l se actualiza cada vez que se emite un voto. Si la prueba indica que el valor de la celda no es producto del ruido, todos los votos de los puntos evaluados hasta ese momento se eliminan del acumulador. Además, todos los puntos que apoyan a la línea detectada se eliminan del conjunto de puntos no votados, y el proceso se repite desde el inicio hasta que ya no queden puntos en el mapa.

Un aspecto importante a destacar es que este algoritmo, en su forma más simple, no cuenta con una regla de paro definida. En ausencia de dicha regla, la PPHT difiere de la transformada convencional únicamente en la cantidad de falsos positivos generados, siendo menos propensa a producirlos (Matas et al., 2000).

Para el ajuste del umbral de decisión, Matas et al. (2000) sugieren asumir el peor caso, donde

todos los puntos podrían deberse a ruido aleatorio. Los autores señalan que esta suposición mantiene cierta validez cuando la imagen contiene múltiples líneas, ya que la mayoría de los puntos no pertenecerán a una única línea. Luego de que un punto emite su voto, se asume que el conteo en cualquier celda es una variable aleatoria independiente que sigue una distribución binomial $B(N, p)$, donde N es el número de puntos que han votado hasta ese momento, y $p = \frac{1}{N_p}$ representa la probabilidad de que un punto vote por una celda específica con un θ dado. A partir de esto, se plantea la siguiente hipótesis:

¿Es el conteo C en la celda (ρ, θ) mayor que un valor que sería esperable si $C(\rho, \theta)$ fuese una realización de una variable aleatoria con distribución binomial $B(N, p)$?

Con el objetivo de seleccionar un umbral tal que:

$$P(C(\rho, \theta) > \text{thr}(N)) < l. \quad (4.5)$$

Donde l es el umbral de significancia determinado por el usuario. Para una distribución binomial, este umbral $\text{thr}(N)$ se puede calcular evaluando la suma acumulada:

$$\sum_{i=0}^{1-l} P(C(\rho, \theta) = i). \quad (4.6)$$

Según los autores, este paso puede simplificarse aún más mediante la aproximación de la distribución binomial por una distribución de Poisson. En este caso, $P(C(\rho, \theta) > \text{thr})$ se puede obtener a partir de la tabla de errores de la distribución, considerando una media Np y desviación estándar $\sqrt{Np(1-p)}$.

4.2. Análisis de Componentes Principales

El análisis de componentes principales (PCA, por sus siglas en inglés) es una técnica de análisis de datos que permite reducir la dimensionalidad de grandes conjuntos de datos, facilitando su interpretación con la mínima pérdida posible de información. Esto se logra mediante la creación de nuevas variables no correlacionadas que maximizan la varianza de manera sucesiva. Estas variables, conocidas como componentes principales, transforman el problema en uno de eigenvalores. Dado que este método depende únicamente de las variables generadas a partir de los propios datos, no es un método *a priori*, lo que lo convierte en una técnica adaptable a distintos problemas (Jolliffe & Cadima, 2016).

En mayor detalle, el PCA parte de un conjunto de datos compuesto por observaciones de p variables numéricas para cada una de n entidades. Estos datos definen una matriz \mathbf{X} de dimensión $n \times p$, cuya j -ésima columna es el vector \mathbf{x}_j de observaciones de la j -ésima variable. El objetivo es encontrar combinaciones lineales de las columnas de \mathbf{X} que maximicen la varianza. Dichas combinaciones se expresan como $\sum_{j=1}^p a_j \mathbf{x}_j = \mathbf{X}\mathbf{a}$, donde \mathbf{a} es un vector de constantes. Para que el problema tenga una solución bien definida, se impone la restricción $\mathbf{a}'\mathbf{a} = 1$, donde $'$ denota transposición. Con esta restricción, la varianza de una combinación lineal está dada por $\text{Var}(\mathbf{X}\mathbf{a}) = \mathbf{a}'\mathbf{S}\mathbf{a}$, donde \mathbf{S} es la matriz de covarianzas de las muestras asociadas al conjunto de datos.

De acuerdo con Jolliffe y Cadima (2016), el problema equivale a maximizar $\mathbf{a}'\mathbf{S}\mathbf{a} - \lambda(\mathbf{a}'\mathbf{a} - 1)$, donde λ es un multiplicador de Lagrange. Al derivar con respecto a \mathbf{a} e igualar al vector nulo, se obtiene la ecuación $\mathbf{S}\mathbf{a} - \lambda\mathbf{a} = 0 \iff \mathbf{S}\mathbf{a} = \lambda\mathbf{a}$. En consecuencia, \mathbf{a} debe ser un eigenvector y λ

el eigenvalor correspondiente. La técnica de PCA consiste en identificar el mayor eigenvalor y su eigenvector asociado para definir el primer componente principal, y repetir el procedimiento para los siguientes.

En la terminología estándar de PCA, los elementos de los vectores de los eigenvectores \mathbf{a}_k se denominan *PC loadings*, mientras que las combinaciones lineales $\mathbf{X}\mathbf{a}_k$ se conocen como *PC scores*, ya que representan los valores asignados a cada entidad en un componente principal.

4.2.1. PCA para el Procesamiento de Imágenes

Aunque el PCA es conocido para el análisis de datos, este ha sido utilizado exitosamente en la detección de ejes y objetos en imágenes (Nagabhushan et al., 2005) (Shekar et al., 2006). Esto se ha realizado principalmente aprovechando los eigenvalores generados por el algoritmo y los respectivos vectores que representan los objetos de interés en la imagen. A partir de estos trabajos, Lee et al., 2006 propuso un algoritmo de PCA para la detección de líneas en imágenes, el cual es de especial interés para este trabajo.

Como supuesto del trabajo anterior, se asume que ya se tiene un mapa de ejes generado, y es el que se utiliza para la detección de líneas. Primero, se categorizan los ejes en piezas columnna-direccionales y fila-direccionales. Luego se analiza cada línea categorizada para obtener su dirección principal y la rectitud de la línea. A partir de este análisis, es posible detectar líneas rectas, las cuales poseen eigenvalores pequeños debajo de un umbral pre-establecido, que puede depender de la longitud de la línea.

Aunque el PCA es conocido por su uso en análisis de datos, también ha sido aplicado exitosamente en la detección de ejes y objetos en imágenes (Nagabhushan et al., 2005; Shekar et al., 2006). Estas aplicaciones se basan principalmente en el uso de los eigenvalores generados por el algoritmo y de los vectores correspondientes, que representan los objetos de interés en la imagen. Partiendo de estos estudios, Lee et al., 2006 propuso un algoritmo basado en PCA para la detección de líneas en imágenes, el cual resulta especialmente relevante para este trabajo.

Siguiendo los supuestos de trabajos anteriores, se asume que ya se dispone de un mapa de ejes generado, el cual se utiliza como base para la detección de líneas. En primer lugar, los ejes se categorizan en piezas columnna-direccionales y fila-direccionales. Luego, se analiza cada línea categorizada para determinar su dirección principal y la rectitud de la línea. Este análisis permite identificar líneas rectas, caracterizadas por poseer eigenvalores pequeños por debajo de un umbral preestablecido, que puede depender de la longitud de la línea.

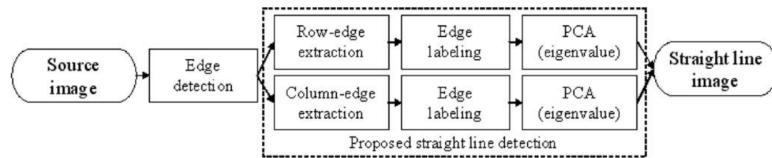


Figura 4.2: Esquema de detección de líneas rectas mediante PCA.

Reproducido de Lee, Y.-S., Koo, H.-S., & Jeong, C.-S. (2006).

Es importante destacar que, en ciertos casos, como en las intersecciones de líneas, es posible que los ejes se clasifiquen en hasta cuatro categorías: fila, columna, fila y columna, e individual (Lee et al., 2006). Una vez categorizados los ejes, estos se conectan utilizando un algoritmo de 8-vecinos con el fin de extraer la dirección primitiva de una posible línea.

Tras obtener las direcciones primitivas de los candidatos a línea, se aplica PCA para calcular sus eigenvalores y eigenvectores. En este contexto, el eigenvalor de una línea representa la dirección principal de la distribución de sus píxeles, mientras que el eigenvector indica la longitud de la línea. Por ejemplo, en un caso ideal de una línea horizontal, el eigenvalor correspondiente al eje x de la línea es mayor que el correspondiente al eje y .

$$s_{11} = \frac{1}{n} \sum_{i=1}^n (x_i - x_m)^2 \quad (4.7)$$

Varianza en la dirección x .

$$s_{12} = s_{21} = \frac{1}{n} \sum_{i=1}^n (x_i - x_m)(y_i - y_m) \quad (4.8)$$

Varianza en la dirección y .

$$s_{22} = \frac{1}{n} \sum_{i=1}^n (y_i - y_m)^2 \quad (4.9)$$

Covarianza entre x y y .

Donde:

$$x_m = \frac{1}{n} \sum_{i=1}^n x_i. \quad (4.10)$$

$$y_m = \frac{1}{n} \sum_{i=1}^n y_i. \quad (4.11)$$

Por lo tanto, los eigenvalores para cada dirección en la matriz de dispersión del PCA son:

$$\lambda_1 = \frac{1}{2} \left\{ s_{11} + s_{22} + \sqrt{(s_{11} - s_{22})^2 + 4s_{12}^2} \right\}. \quad (4.12)$$

$$\lambda_2 = \frac{1}{2} \left\{ s_{11} + s_{22} - \sqrt{(s_{11} - s_{22})^2 + 4s_{12}^2} \right\}. \quad (4.13)$$

Además, es posible obtener el ángulo de la línea con:

$$\theta = \tan^{-1} \left(\frac{\lambda_1 - s_{11}}{s_{12}} \right) \quad \text{o} \quad \theta = \tan^{-1} \left(\frac{s_{21}}{\lambda_1 - s_{22}} \right). \quad (4.14)$$

(Lee et al., 2006)

4.3. Transformada de Fourier

En 1807, Jean Baptiste Fourier postuló que cualquier función periódica puede expresarse como una suma de senos o cosenos de distintas frecuencias, cada uno multiplicado por un coeficiente específico. Esta descomposición se conoce como serie de Fourier. Sin importar la complejidad de la función, siempre que sea periódica o cumpla ciertas condiciones matemáticas, puede representarse de esta forma (Gonzalez & Woods, 2018).

$$f(t) = \sum_{n=-\infty}^{\infty} c_n e^{in\omega t} \quad (4.15)$$

Serie de Fourier.

$$c_n = \frac{1}{T} \int_{-T/2}^{T/2} f(t) e^{-in\omega t} dt \quad (4.16)$$

Coeficiente de Fourier.

Por otro lado, las funciones no periódicas con área finita pueden expresarse como una integral de senos o cosenos ponderados por una función, lo que se conoce como transformada de Fourier.

$$F(\omega) = \int_{-\infty}^{\infty} f(t) e^{-i\omega t} dt \quad (4.17)$$

Transformada de Fourier.

Ambas representaciones comparten que la función original puede reconstruirse sin pérdida de información mediante el proceso inverso correspondiente. Esto permite trabajar en el dominio de Fourier y luego regresar al dominio original sin comprometer la integridad de la información (Gonzalez & Woods, 2018).

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{\infty} F(\omega) e^{i\omega t} d\omega \quad (4.18)$$

Transformada inversa de Fourier.

Aunque los procesos mencionados anteriormente fueron diseñados con señales en mente, sus principios también se aplican al procesamiento de imágenes. En este contexto, una imagen puede considerarse como una señal bidimensional, y la transformada de Fourier permite analizar su contenido en términos de frecuencia espacial. Para esto, es necesario discretizar (4.17) y adaptar a dos dimensiones.

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-i2\pi(\frac{ux}{M} + \frac{vy}{N})} \quad (4.19)$$

Transformada de Fourier discreta en dos dimensiones.

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) e^{i2\pi(\frac{ux}{M} + \frac{vy}{N})} \quad (4.20)$$

Transformada inversa de Fourier discreta en dos dimensiones.

Es importante destacar que la transformada de Fourier discreta no es muy eficiente para grandes cantidades de datos. En una dimensión, si se tienen N muestras, su cálculo directo requiere un orden de tiempo computacional de $O(N^2)$. Esta complejidad se vuelve prohibitiva para el procesamiento de imágenes grandes o aplicaciones en tiempo real, ya que el número de operaciones crece de manera cuadrática con respecto al tamaño de los datos.

Sin embargo, con los avances en las computadoras digitales, se diseñó un algoritmo conocido como la transformada rápida de Fourier (FFT, por sus siglas en inglés), el cual agiliza el cálculo de la transformada discreta al reducir su complejidad a $O(N \log N)$. Esta mejora significativa permite que la transformada de Fourier se utilice de manera eficiente y en aplicaciones de tiempo real.

Aunque existen diversas implementaciones de la FFT, la más común es el algoritmo de Cooley-Tukey. Su funcionamiento se basa en una estrategia de *Divide & Conquer*, donde se divide el problema en transformadas más pequeñas, cuyos resultados pueden reutilizarse y combinarse. En particular, cuando el número de muestras es una potencia de dos, el algoritmo puede descomponer el problema sucesivamente en mitades, simplificando y acelerando el cálculo (Rockmore, 1999).

4.3.1. Análisis de Frecuencia en Imágenes

La transformada de Fourier aplicada a imágenes produce otra imagen con valores complejos, es decir, con una parte real y una parte imaginaria. A partir de estos valores, la imagen resultante puede separarse en un espectro de magnitud y un espectro de fase. En el procesamiento de imágenes, generalmente se utiliza el espectro de magnitud, ya que contiene la mayor parte de la información geométrica de la imagen en el dominio espacial. Sin embargo, el espectro de fase es indispensable para realizar la transformada inversa, por lo que es necesario conservar ambas partes de la representación (Fisher et al., 2003). A pesar de esto, es posible reconstruir la imagen con pérdida de información mínima utilizando solamente el espectro de fase (Juvells et al., 1991).

$$F(u, v) = \text{Re}(u, v) + j \cdot \text{Im}(u, v) \quad (4.21)$$

Transformada de Fourier expresada en términos de su parte real e imaginaria. En este caso, $j = \sqrt{-1}$.

$$F(u, v) = |F(u, v)| e^{j\theta(u, v)} \quad (4.22)$$

Transformada de Fourier en forma polar, con magnitud $|F(u, v)|$ y fase $\theta(u, v)$.

$$|F(u, v)| = \sqrt{\text{Re}(u, v)^2 + \text{Im}(u, v)^2} \quad (4.23)$$

Magnitud del componente de frecuencia (u, v) .

$$\theta(u, v) = \arctan \left(\frac{\text{Im}(u, v)}{\text{Re}(u, v)} \right) \quad (4.24)$$

Fase del componente de frecuencia (u, v) .

(Gonzalez & Woods, 2018)

Dado que la imagen en el dominio de Fourier se descompone en sus componentes sinusoidales, es posible analizar la estructura geométrica de la imagen original a partir de sus frecuencias (Fisher et al., 2003).

Al interpretar los resultados de la transformada de Fourier, es importante considerar algunos aspectos. En primer lugar, el valor correspondiente a $F(0, 0)$ almacena la luminosidad media de la imagen. En la mayoría de las visualizaciones, la imagen se traslada de manera que este valor quede ubicado en el centro. Así, cuanto más alejado se encuentre un punto del centro en el dominio de Fourier, mayor será la frecuencia que representa, mientras que los valores más cercanos al centro corresponden a frecuencias más bajas (Fisher et al., 2003).



Figura 4.3: Imagen espacial de una persona en escala de grises.

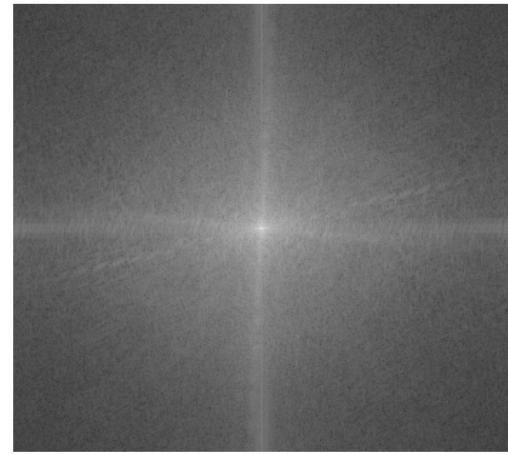


Figura 4.4: Espectro de magnitud (escala logarítmica).

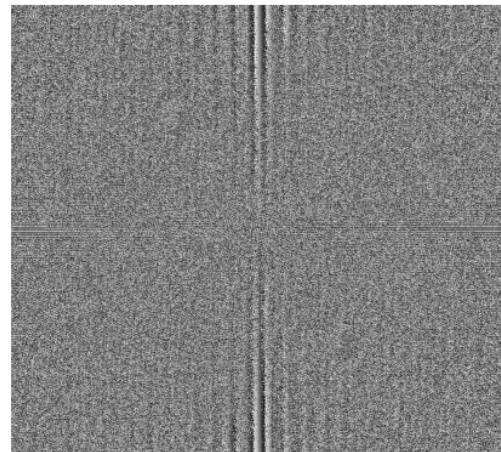


Figura 4.5: Espectro de fase.

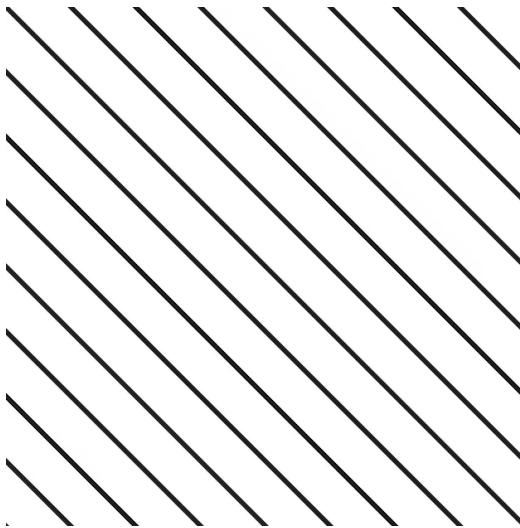


Figura 4.6: Imagen espacial de líneas diagonales.

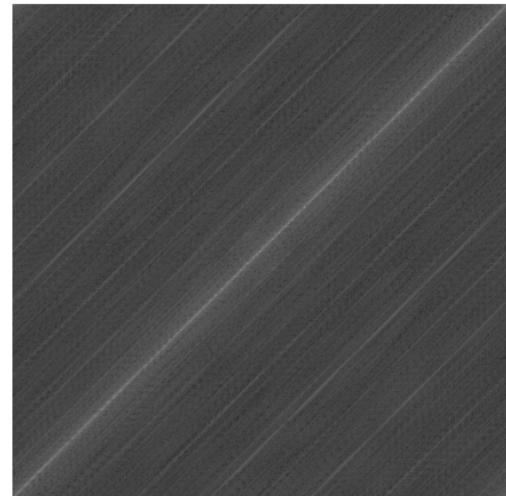


Figura 4.7: Espectro de magnitud (escala logarítmica).

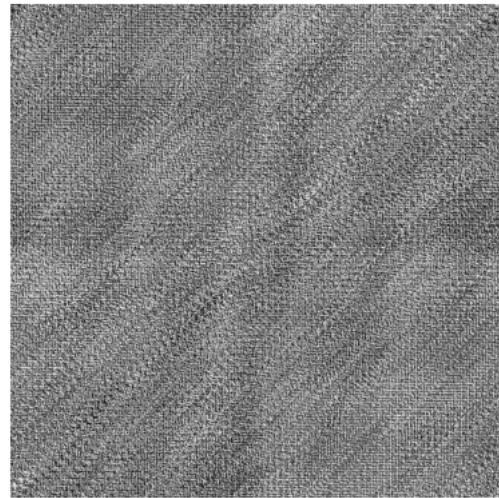


Figura 4.8: Espectro de fase.

En las imágenes anteriores, se puede observar que el valor $F(0,0)$ es el mayor del espectro de magnitud. Cabe mencionar que el rango de valores del espectro de magnitud es muy amplio para ser representado directamente, por lo que se aplica una transformación logarítmica únicamente con fines de visualización. En estos casos, el espectro de magnitud revela las direcciones dominantes presentes en la imagen original (Fisher et al., 2003). Por ejemplo, en la magnitud de las líneas diagonales se aprecian fuertes líneas perpendiculares a la dirección de las líneas originales, resultado de los patrones regulares de la imagen. En la imagen de la persona, se observan algunas líneas en el espectro de magnitud que corresponden a la inclinación general de la persona (la línea tenue inclinada), a los pasos de cebra de la imagen, a los destellos del lente en los semáforos y a otros patrones presentes en el fondo de la imagen.

En contraste, es difícil interpretar información espacial del espectro de fase a simple vista. Aquí, el valor de cada punto indica la fase de la frecuencia respectiva, mientras que el espectro de magnitud muestra líneas de diversas orientaciones que representan patrones de la imagen original.

CAPÍTULO 5

Metodología

Este trabajo forma parte de un sistema más amplio, cuya descripción completa se encuentra fuera del alcance del presente estudio. En particular, se desarrolla un módulo destinado a detectar y cuantificar espacios vacíos en surcos agrícolas a partir de segmentaciones obtenidas de imágenes satelitales. El sistema utiliza como entrada una imagen aérea en formato RGB junto con su correspondiente versión binarizada y, opcionalmente, una máscara binaria que indica qué secciones de la imagen deberían ignorarse.

Cabe destacar que tanto estas imágenes como sus segmentaciones y máscaras son generadas por un pipeline externo, el cual también forma parte del sistema general. Dicho pipeline se encarga de dividir la imagen original en parches de menor tamaño y de realizar su binarización, cuyos resultados sirven como insumo directo para el módulo presentado en este trabajo. Las máscaras binarias observadas en este trabajo no son externas, sino que fueron realizadas manualmente en un editor de imágenes para facilitar la visualización.

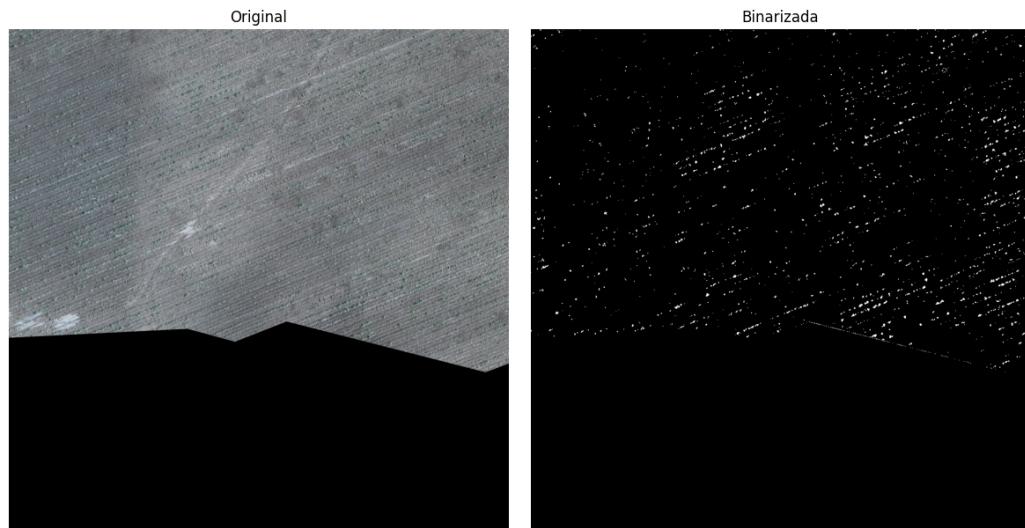


Figura 5.1: Ejemplo de imagen RGB y su versión binarizada.

Como es posible observar en la Figura 5.1, las imágenes aéreas de surcos pueden abstraerse como un conjunto de líneas paralelas y aproximadamente equidistantes. Aunque esta condición no se cumple en todas las imágenes que podrían emplearse, se considera una asunción útil para diseñar un flujo capaz de detectar y representar dichos surcos de manera matemática.

El enfoque principal para lograr este objetivo consiste en inferir la orientación predominante de los surcos, es decir, el ángulo que mejor describe el conjunto de líneas, y determinar la posición en la imagen de cada línea individual. Con estos dos elementos, es posible registrar y cuantificar los espacios vacíos presentes en los surcos.

5.1. Estimación de la orientación principal

Como primer paso, es necesario estimar el ángulo que mejor describe la orientación de las líneas. Para ello, se proponen tres algoritmos:

1. Uno basado en la Transformada de Hough.
2. Otro que utiliza Análisis de Componentes Principales (PCA).
3. Un tercero que analiza el espectro de magnitud de la Transformada de Fourier de la imagen.

5.1.1. Transformada de Hough

En el primer algoritmo, se aplica la Transformada de Hough a la imagen binarizada (utilizando `cv2.HoughLines`). Este proceso devuelve un conjunto de líneas representadas en el formato (ρ, θ) , las cuales son posteriormente filtradas en función de su cercanía en distancia y ángulo. Este proceso de filtrado constituye un subalgoritmo que elimina líneas redundantes generadas por ruido en la transformada.

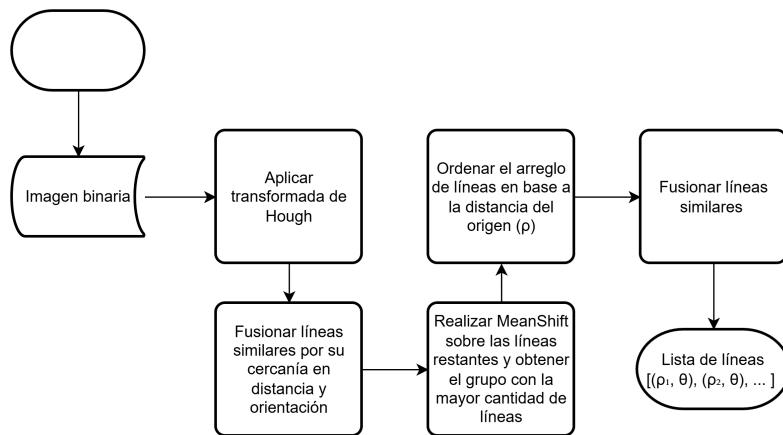


Figura 5.2: Esquema de detección de líneas utilizando la Transformada de Hough.

Dependiendo del umbral establecido en la Transformada de Hough, es posible obtener múltiples líneas con orientaciones incorrectas, que deben ser descartadas. En las imágenes empleadas en este trabajo, se observó que, para umbrales suficientemente altos, las líneas con la orientación correcta constituyen la mayoría de las detecciones, mientras que el resto corresponde a ruido con orientaciones erróneas.

Para conservar únicamente las líneas correctas, se emplea un segundo subalgoritmo que aplica el método *MeanShift* al conjunto de líneas obtenidas, agrupándolas según su ángulo θ . Como se mencionó anteriormente, con un umbral adecuado en la Transformada de Hough, las líneas relevantes se concentran en el grupo con mayor cantidad de elementos. Por lo tanto, para los siguientes pasos del flujo, se utiliza únicamente este conjunto de líneas filtradas.

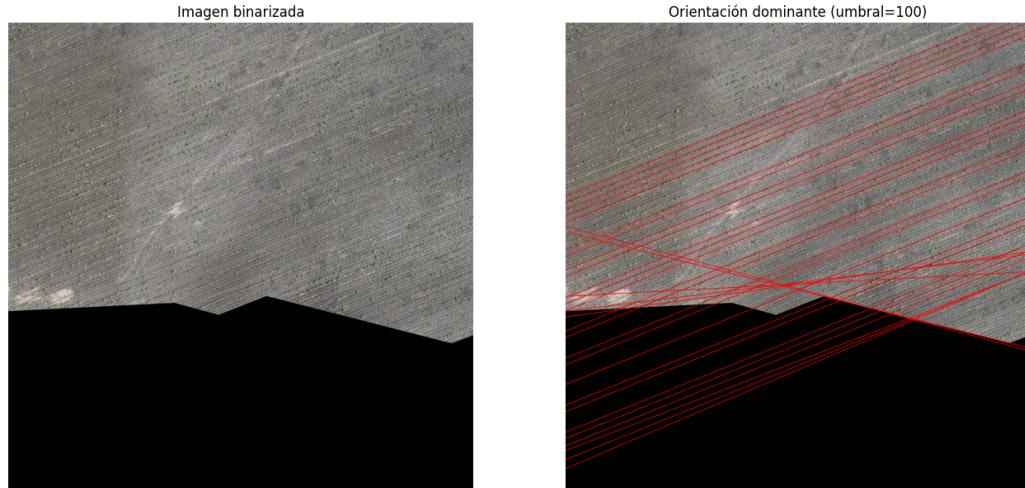


Figura 5.3: Líneas detectadas antes del agrupamiento con MeanShift.

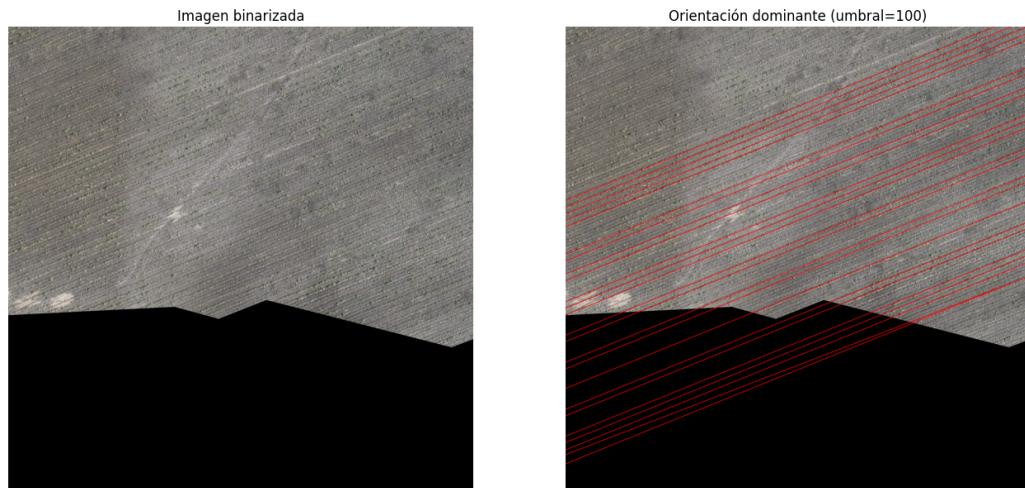


Figura 5.4: Líneas detectadas después del agrupamiento con MeanShift.

Inferencia de líneas faltantes

Una vez filtradas las líneas relevantes, es posible proceder a la detección de espacios vacíos. Sin embargo, el algoritmo descrito anteriormente no logra identificar todas las líneas esperadas en la mayoría de los casos. Generalmente, las líneas cercanas a los bordes de la imagen no acumulan suficientes votos para ser consideradas válidas por la Transformada de Hough. Por ello, se requiere un método adicional para *inferir* la posición y orientación de las líneas faltantes.

Para solventar esta limitación, se emplea un algoritmo de inferencia que parte del conjunto de

líneas resultante del proceso anterior. En primer lugar, las líneas se ordenan según su distancia al origen ρ , y posteriormente se calcula la menor separación entre cada par de líneas (por encima de un umbral determinado). Este algoritmo asume que la menor separación entre líneas corresponde a la distancia real entre los surcos en la imagen, dado que, en todas las imágenes analizadas, las líneas son aproximadamente equidistantes. Así, la menor separación observada suele coincidir con la separación más común y consistente.

La menor separación entre líneas se define como la distancia mínima entre los valores de ρ del conjunto de líneas detectadas. Formalmente, puede expresarse como:

$$d_{\min} = \min_{i,j} |\rho_i - \rho_j|, \quad i \neq j. \quad (5.1)$$

Donde ρ_i y ρ_j representan las distancias al origen de dos líneas distintas en el espacio de parámetros de Hough. Esta distancia d_{\min} se asume como la separación real entre surcos consecutivos en la imagen, bajo la hipótesis de que los surcos son aproximadamente equidistantes. Es importante señalar que esta hipótesis falla si, a pesar de los procesos de limpieza anteriores, el conjunto aún contiene líneas producto del ruido o si la cantidad de líneas detectadas es insuficiente, lo cual conduce a estimaciones incorrectas de la separación.

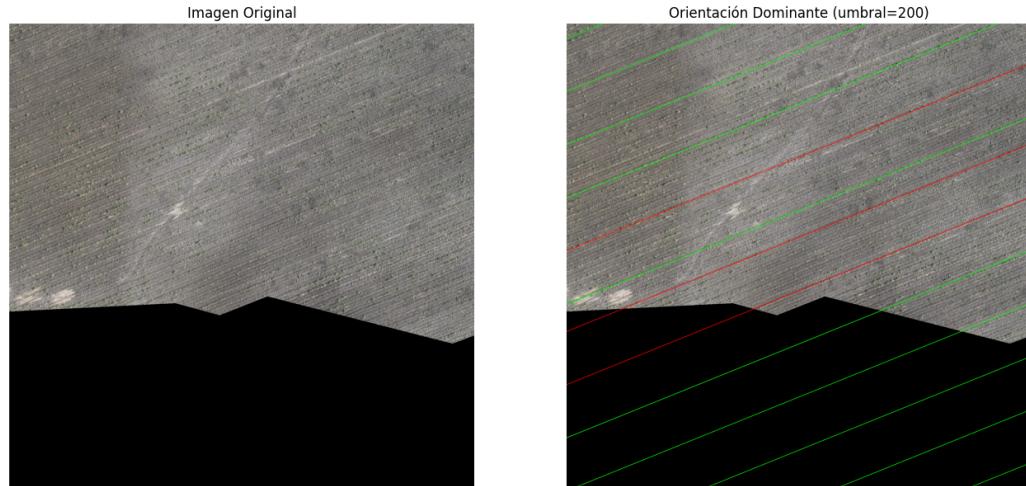


Figura 5.5: Ejemplo de detección incompleta con líneas excesivamente separadas.

Al conocer la separación esperada entre los surcos, se itera sobre el conjunto de líneas ordenadas de manera ascendente según su valor de ρ . Para cada línea, se verifica si sus vecinos más cercanos se encuentran a una distancia mayor que $d_{\min} \cdot \sigma$, donde σ es un parámetro de tolerancia definido por el usuario.

En las imágenes procesadas en este trabajo, se utilizó un valor de $\sigma = 0.5$, determinado empíricamente mediante prueba y error hasta encontrar un valor que funcionara adecuadamente para la mayoría de los casos. En esencia, este parámetro define el grado de tolerancia del algoritmo para determinar si faltan líneas vecinas, considerando que los surcos son aproximadamente equidistantes y que la distancia entre cada par de líneas no siempre es exactamente la misma. Además, el ruido presente en las imágenes puede provocar que las líneas detectadas mediante la Transformada de Hough no coincidan perfectamente con el centro de cada surco, por lo que esta tolerancia permite manejar dichas desviaciones.

Si la distancia al siguiente vecino más cercano excede el umbral $d_{\min} \cdot \sigma$, se inserta una nueva línea definida como:

$$(\rho_i + d_{\min}, \theta). \quad (5.2)$$

En caso contrario, la línea es omitida.

Con este procedimiento, los espacios vacíos entre líneas detectadas son rellenados mediante la inserción de nuevas líneas, restaurando así la continuidad del patrón de surcos. Sin embargo, este método no contempla los espacios vacíos que se encuentran fuera del rango del conjunto de líneas detectadas, por lo que las líneas ubicadas cerca de los bordes de la imagen tienden a ser omitidas.

Para solventar este problema, se identifican las líneas ubicadas en los extremos del conjunto resultante (aquellas con los valores de ρ_{\min} y ρ_{\max}) y se extrapolan nuevas líneas a partir de ellas. Partiendo de la línea con el menor valor de ρ , se insertan líneas adicionales definidas como:

$$(\rho_{\min} - d_{\min} \cdot k, \theta). \quad (5.3)$$

Donde k representa el número de línea generada. Este proceso se repite hasta que una de las líneas extrapoladas deja de intersectar el área visible de la imagen. El mismo procedimiento se aplica de manera análoga a la línea con ρ_{\max} , utilizando la siguiente expresión:

$$(\rho_{\max} + d_{\min} \cdot k, \theta). \quad (5.4)$$

De esta manera, se obtiene un conjunto de líneas que representan todos los posibles surcos presentes en la imagen, completando así la etapa de detección de líneas del algoritmo basado en la Transformada de Hough.

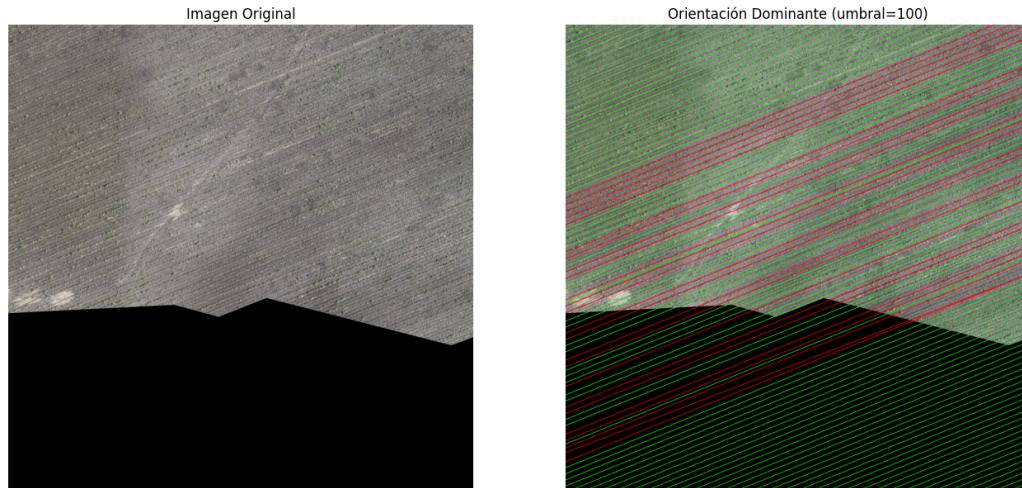


Figura 5.6: Conjunto final de líneas tras la extrapolación de los extremos y la inserción de líneas faltantes.

Como se observa en la Figura 5.6, el algoritmo logra restaurar de forma efectiva la estructura completa de surcos, incluyendo aquellos que inicialmente no fueron detectados por la Transformada de Hough debido a limitaciones de cobertura o ruido en la imagen.

Selección de parámetros y consideraciones prácticas

El aspecto más importante para el funcionamiento adecuado de este algoritmo es la selección de un umbral de votos apropiado para la Transformada de Hough. No existe un método consistente que permita determinar un valor óptimo de este umbral para todos los casos, ya que depende de las características particulares de cada imagen. Por esta razón, en este trabajo se empleó un rango de valores entre [50, 300], con incrementos de 50, definido de manera empírica mediante un proceso de prueba y error.

El algoritmo descrito anteriormente se ejecutó para cada valor dentro de este rango, y se seleccionó un valor tentativo de umbral a partir de aquel que generó la mayor cantidad de líneas en el conjunto final previo al paso de relleno. Este método de selección no garantiza resultados perfectos, por lo que, en algunos casos, es necesario ajustar manualmente el umbral hasta obtener el resultado deseado. A pesar de ello, el procedimiento resultó exitoso en la mayoría de los casos, permitiendo determinar un valor cercano al ideal de forma consistente.

Por otro lado, es importante mencionar otros parámetros empleados durante este proceso. Para la Transformada de Hough, se utilizó una resolución de un píxel en ρ y de 1° en θ . Estos valores corresponden a los más comúnmente utilizados en aplicaciones similares, y en este trabajo se obtuvieron resultados satisfactorios sin requerir un proceso adicional de ajuste.

En cuanto al algoritmo de agrupamiento de líneas basado en *MeanShift*, se definió un parámetro de rango de 1° para determinar los conjuntos de líneas. Este valor también fue establecido mediante prueba y error, buscando un equilibrio adecuado de sensibilidad. Durante la experimentación, se observó que valores elevados de este parámetro generaban grupos de líneas demasiado amplios y ruidosos, mientras que valores demasiado bajos producían una cantidad excesiva de grupos con pocas líneas.

Adicionalmente, durante el filtrado de líneas redundantes basado en su cercanía, se empleó un umbral de 20 unidades en ρ y de 5° en θ . Esto implica que pares de líneas cuya distancia sea menor a 20 y cuya diferencia angular sea inferior a 5° se combinan en una sola línea. La nueva línea resultante se define con el valor promedio de ρ entre ambas y con el θ más cercano al promedio global del conjunto.

Cabe destacar que estos parámetros no son óptimos para todos los casos posibles y deben ajustarse cuidadosamente según las condiciones específicas de las imágenes analizadas. No obstante, los valores aquí descritos demostraron ofrecer resultados consistentemente satisfactorios a lo largo del conjunto de imágenes de prueba utilizado en este trabajo.

5.1.2. Detección de líneas mediante Análisis de Componentes Principales (PCA)

El siguiente algoritmo propuesto para la detección de líneas se basa en la aplicación del Análisis de Componentes Principales para estimar el ángulo predominante en los surcos presentes en la imagen. A partir de la imagen binarizada, se extrae el componente conectado más grande utilizando la función `cv2.connectedComponents`, y se aplica PCA únicamente a los puntos que pertenecen a dicho componente.

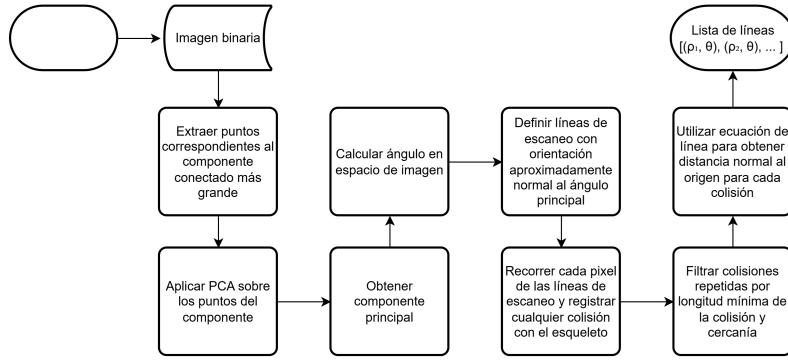


Figura 5.7: Esquema de detección de líneas utilizando PCA.

El primer componente principal obtenido mediante PCA corresponde a la dirección de mayor varianza de los puntos. Como resultado, para componentes alargados, esta dirección representa de forma aproximada la orientación del surco. Es importante destacar que esta suposición puede fallar en componentes muy pequeños o con formas irregulares, ya que, en tales casos, la dirección de máxima varianza no necesariamente coincide con la orientación real del surco.

Resultado del PCA sobre el componente conectado más grande

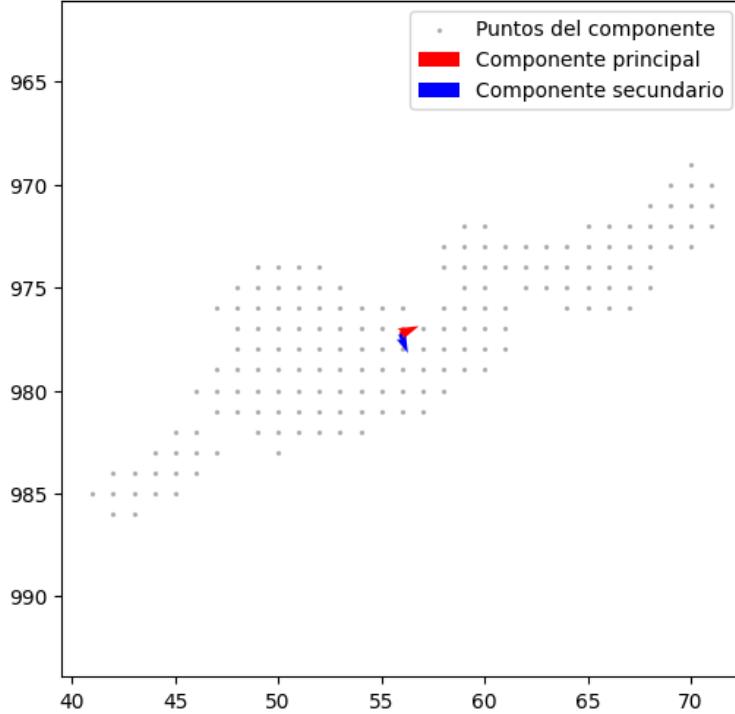


Figura 5.8: Ejemplo de resultado de la aplicación de PCA sobre el componente conectado más grande.

Bajo las mismas suposiciones sobre la estructura de las imágenes y los patrones lineales, el ángulo predominante de las líneas puede obtenerse mediante la siguiente expresión:

$$\theta_{\text{line}} = \arctan 2(v_y, v_x). \quad (5.5)$$

Donde v_x y v_y representan las componentes del vector principal obtenido por PCA.

Este método es significativamente más sencillo que el basado en la Transformada de Hough, aunque presenta la desventaja de que únicamente proporciona el ángulo de las líneas, sin información sobre sus posiciones.

Determinación de ρ mediante líneas de escaneo

El subalgoritmo propuesto parte del ángulo θ_{line} obtenido previamente. En primer lugar, se define una línea de escaneo que atraviesa la imagen desde una esquina hasta su opuesta. La elección de las esquinas depende del signo del ángulo: si el ángulo es negativo, se utiliza la diagonal superior izquierda a inferior derecha. En caso contrario, la diagonal opuesta. Esta elección busca garantizar que la línea de escaneo cubra la mayor extensión posible de la imagen, maximizando la probabilidad de colisionar con los surcos presentes. Dicho enfoque también es funcional para orientaciones cercanas a la vertical u horizontal, donde recorrer la imagen de esquina a esquina asegura la cobertura completa del campo visual.

A continuación, la línea de escaneo se recorre pixel a pixel, registrando todas las colisiones con píxeles blancos en la imagen binarizada. Dado que los surcos poseen un ancho mayor a un solo píxel, este proceso puede generar múltiples detecciones redundantes de una misma línea. Para mitigar este efecto, los puntos de colisión se agrupan en función de su proximidad espacial (en este caso, con una distancia máxima de 1 píxel). Para cada grupo de colisiones se calcula el punto medio, que representa el centro aproximado del surco correspondiente. Aunque en la mayoría de los casos este punto coincide con el centro geométrico del surco, pueden existir ligeras desviaciones en casos particulares.

Una vez obtenidos los puntos representativos de los surcos, estos se transforman al espacio de parámetros (ρ, θ) , de manera similar al proceso utilizado en la Transformada de Hough.

Uso de múltiples líneas de escaneo

Dado que las imágenes analizadas pueden contener espacios vacíos entre los surcos (por ausencia de plantas o ruido en la binarización), una única línea de escaneo podría no intersectar todos los surcos existentes. Para abordar esta limitación, se definen múltiples líneas de escaneo paralelas con el mismo ángulo θ_{line} , separadas entre sí por un desplazamiento *offset*. En este trabajo, se emplearon desplazamientos de 50 píxeles y un total de 10 líneas adicionales. Formalmente, las líneas se definen como:

$$\rho_k = \rho_0 \pm k \cdot \text{offset}, \quad k = 1, 2, \dots, n. \quad (5.6)$$

De esta manera, se obtiene un conjunto de $2n + 1$ líneas que son sometidas al mismo proceso de escaneo descrito anteriormente. El uso de líneas desplazadas aumenta la robustez de la detección, ya que reduce la probabilidad de que los espacios vacíos afecten significativamente los resultados. Sin embargo, en casos donde los surcos presentan grandes discontinuidades o un número reducido de plantas, pueden ser necesarias etapas adicionales de relleno de líneas.

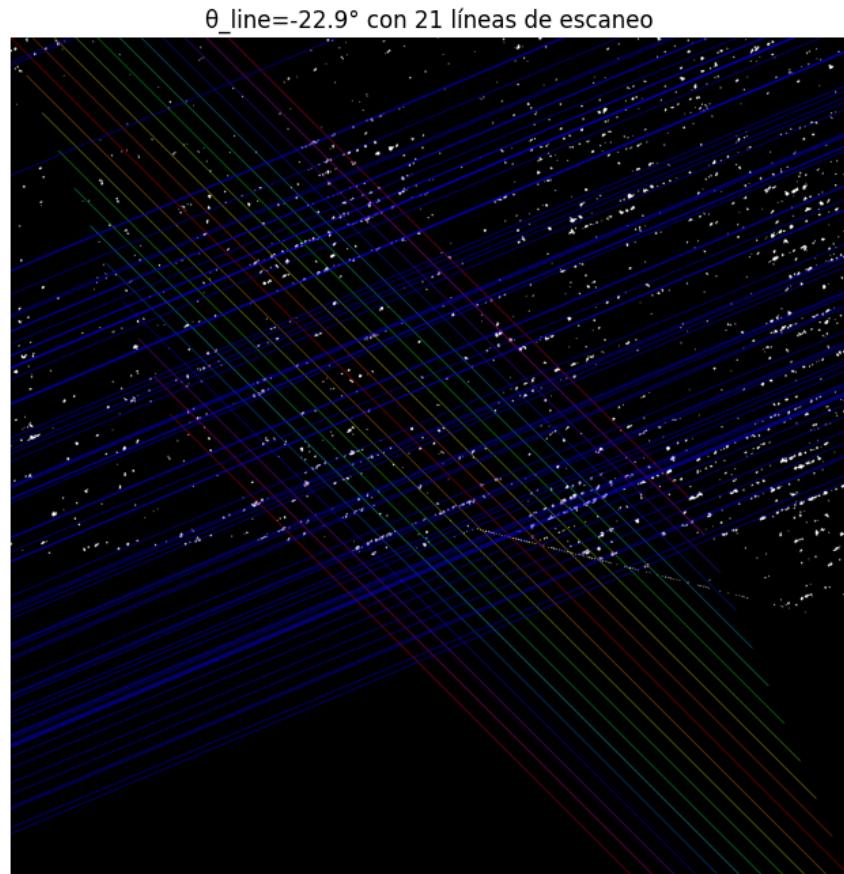


Figura 5.9: Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul).

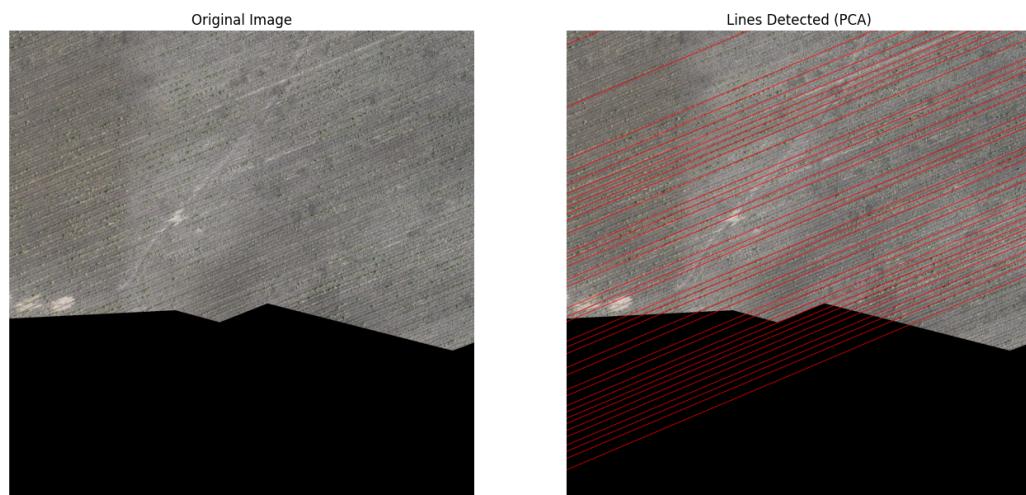


Figura 5.10: Conjunto de líneas tras agrupamiento y eliminación de redundancia.

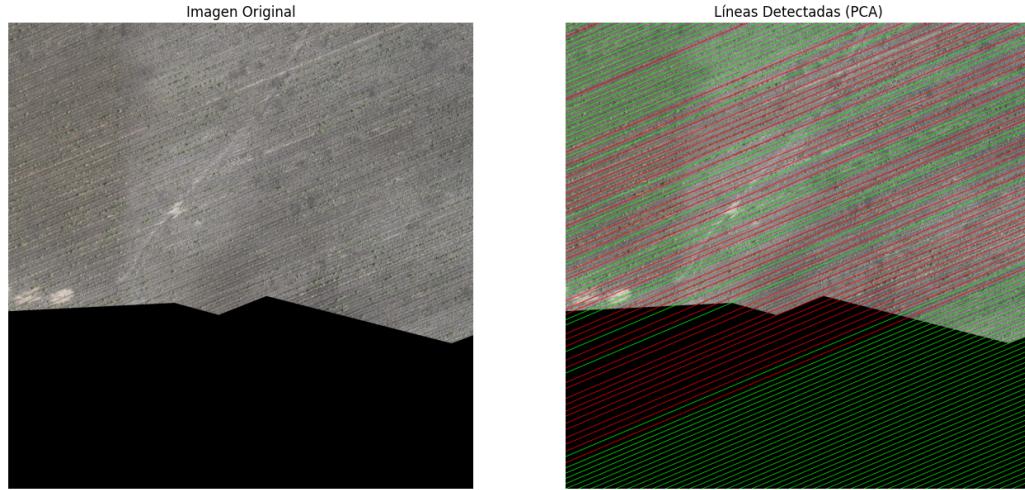


Figura 5.11: Conjunto final tras relleno de líneas faltantes (verde).

Parámetros del algoritmo

Los parámetros de desplazamiento y número de líneas adicionales fueron definidos empíricamente. Si el desplazamiento es demasiado grande, las líneas podrían quedar fuera de los límites de la imagen, reduciendo su efectividad. Por el contrario, valores muy pequeños o pocas líneas adicionales pueden dejar regiones sin explorar. Por otro lado, un número excesivo de líneas genera redundancias y un mayor costo computacional.

Finalmente, para reducir el impacto del ruido en la binarización (píxeles aislados), se define un parámetro de distancia mínima de recorrido. Este parámetro establece la longitud mínima de un segmento continuo de colisión para ser considerado como línea válida. De esta forma, se descartan píxeles aislados sin estructura aparente, conservando únicamente los segmentos coherentes con la geometría de los surcos. En este trabajo se utilizó un valor de 2, suficiente para eliminar la mayoría del ruido sin perder surcos válidos. No obstante, valores excesivamente altos pueden causar la omisión de surcos delgados o incompletos.

5.1.3. Detección de líneas mediante Transformada de Fourier

El tercer algoritmo propuesto para la detección de líneas se basa en el análisis del espectro de magnitud de la Transformada de Fourier de la imagen binarizada, con el objetivo de inferir la orientación predominante de los surcos.

En primer lugar, se aplica la transformada de Fourier bidimensional a la imagen binarizada y, posteriormente, se realiza un desplazamiento de cuadrante (`fftshift`) para centrar las frecuencias bajas en el origen. A continuación, se separan los espectros de magnitud y fase. Como se aprecia en la Figura 4.7, el espectro de magnitud presenta una estructura con una línea cuya orientación es aproximadamente normal a la dirección de los surcos.

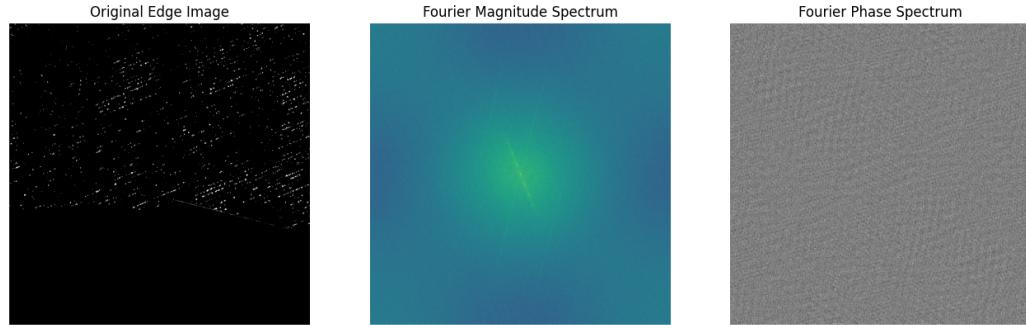


Figura 5.12: Espectros de magnitud y fase resultantes de imagen binarizada.

Para extraer esta orientación, se seleccionan los N puntos de mayor intensidad en el espectro de magnitud. El resultado de esta extracción es un conjunto de puntos distribuidos a lo largo de la estructura mencionada. Posteriormente, estos puntos se transforman a coordenadas espaciales y se realiza una regresión lineal para obtener la pendiente m de dicha estructura:

$$m = \frac{\Delta y}{\Delta x}. \quad (5.7)$$

Puntos Dominantes en Espectro de Magnitud

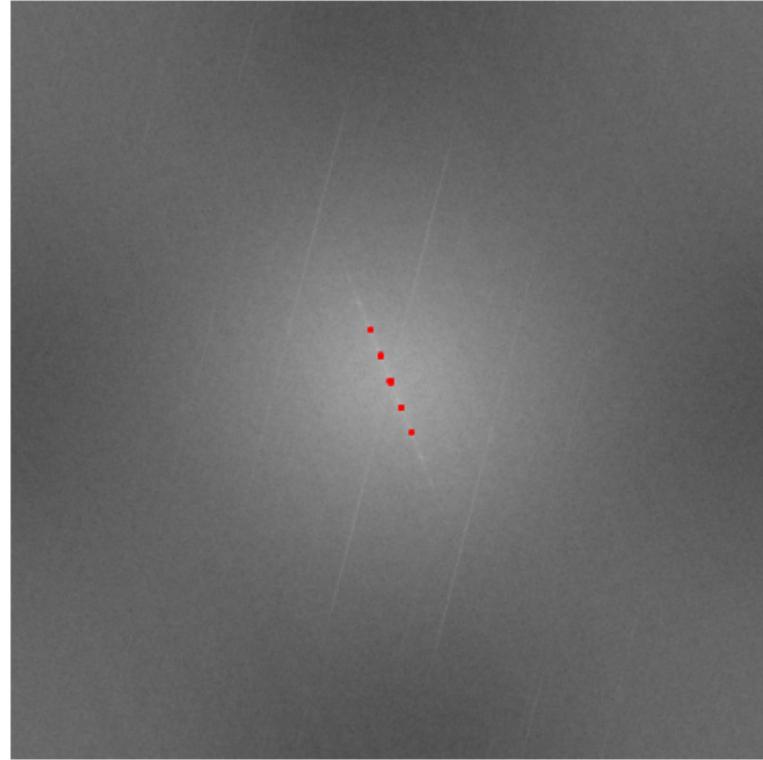


Figura 5.13: Puntos de mayor intensidad sobreuestos al espectro de magnitud.

Una vez obtenida la pendiente, se calcula el ángulo correspondiente mediante:

$$\theta_{\text{mag}} = \arctan(m). \quad (5.8)$$

Dado que el espectro de magnitud presenta una orientación normal respecto a las líneas de los surcos, el ángulo real de las líneas puede obtenerse a partir de la dirección ortogonal:

$$\theta_{\text{line}} = \theta_{\text{mag}} + \frac{\pi}{2} \quad (5.9)$$

Regresión Lineal sobre Puntos Dominantes

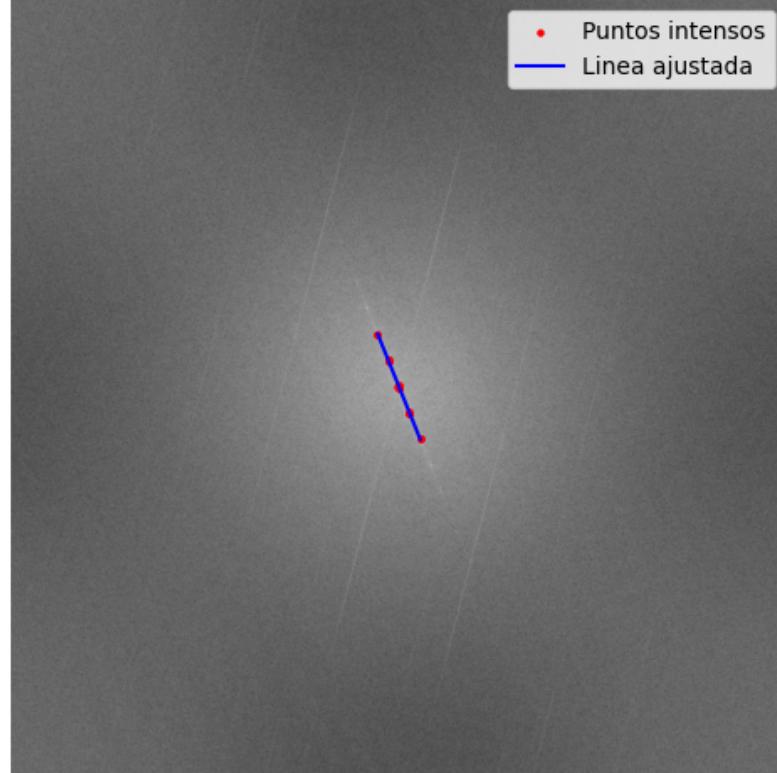


Figura 5.14: Resultado de la regresión lineal aplicada a los puntos más intensos del espectro.

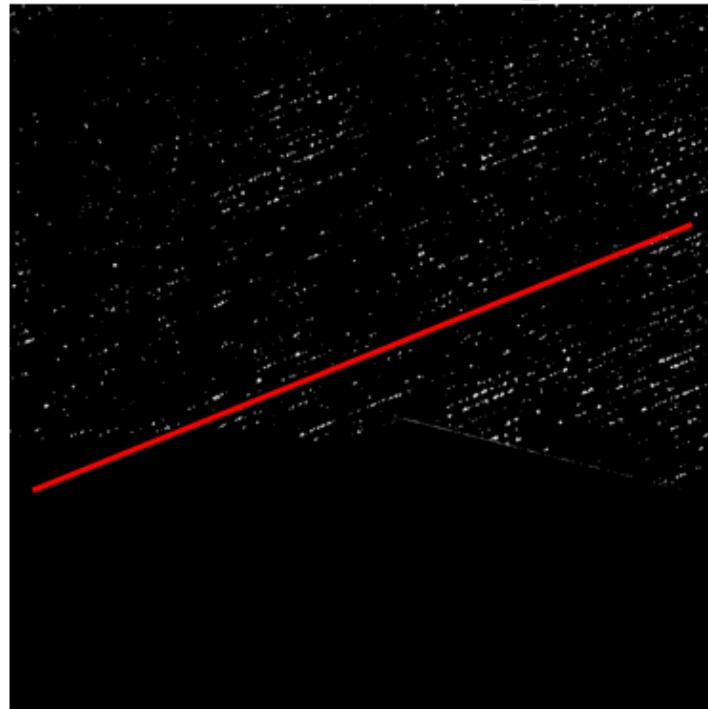
Orientación Espacial Resultante ($\theta_{\text{line}}=2.8 \text{ rad}$)

Figura 5.15: Ejemplo de línea con ángulo correcto.

De manera análoga al algoritmo basado en PCA, este enfoque produce únicamente el ángulo predominante θ_{line} , sin información sobre las posiciones ρ de las líneas. Por ello, se aplica el mismo procedimiento descrito previamente en la sección correspondiente al algoritmo de PCA (véase Figura 5.7) para inferir las posiciones de las líneas de surco.

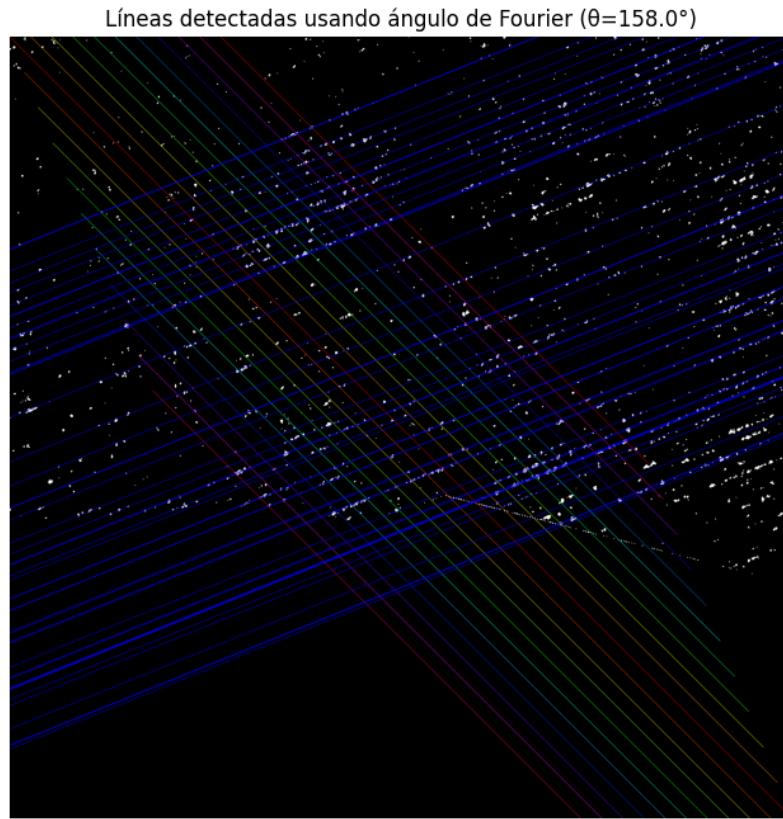


Figura 5.16: Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul) utilizando ángulo de Fourier.

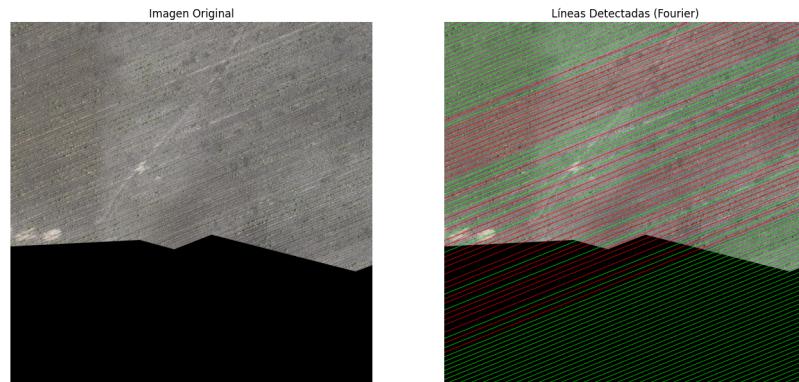


Figura 5.17: Conjunto de líneas final luego de agrupamiento y relleno.

Parámetros del algoritmo

El único parámetro relevante de este método es la cantidad de puntos N seleccionados para la regresión lineal. En este trabajo, se empleó un valor empírico de $N = 20$. Durante la experimentación se observó que valores más bajos tienden a ofrecer mejores resultados, ya que reducen la probabilidad de incluir puntos ajenos a la estructura principal del espectro (ruido). Por el contrario, valores altos pueden introducir puntos lejanos y desviar la pendiente estimada, afectando directamente el ángulo

final.

Limitaciones del método

De los tres algoritmos propuestos para la inferencia del ángulo, el basado en la Transformada de Fourier resultó ser el menos consistente. En múltiples casos de prueba, incluso con espectros visualmente correctos, el ángulo obtenido se desvió varios grados respecto al valor esperado, lo cual lo hace inadecuado para este trabajo, dado que se requiere una alta precisión angular para representar correctamente los surcos.

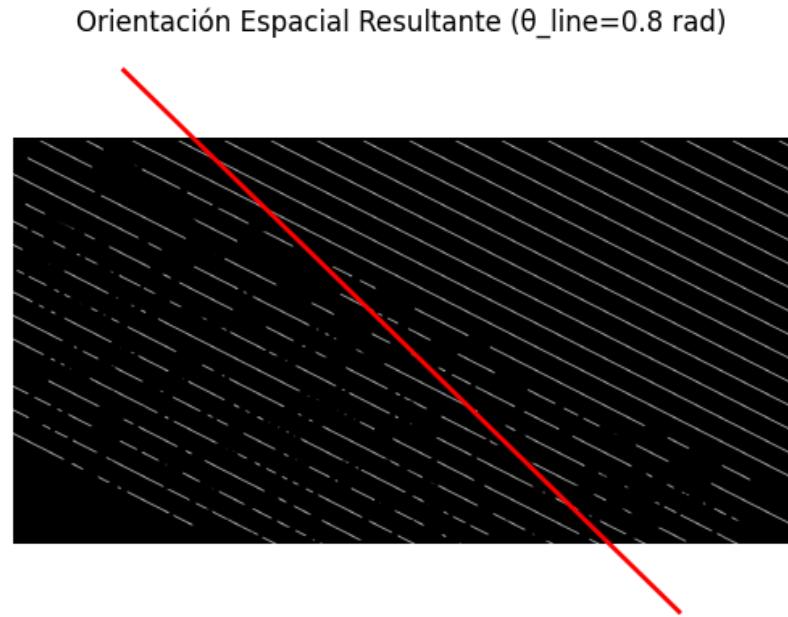


Figura 5.18: Ejemplo de caso donde el ángulo obtenido mediante Fourier difiere significativamente del esperado.

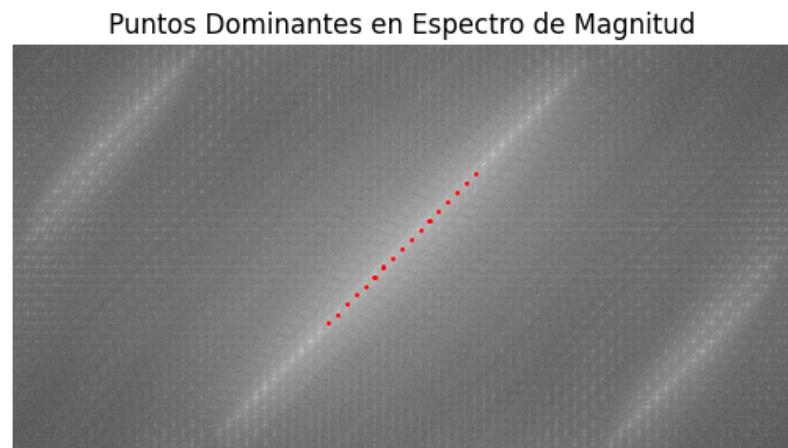


Figura 5.19: Puntos más intensos en el espectro de magnitud del caso de ejemplo fallido.

Mejora mediante Transformada de Hough en el dominio de Fourier

Con el fin de mitigar estas inconsistencias, se experimentó con la aplicación de la *Transformada de Hough* directamente sobre el espectro de magnitud. Para ello, primero se aplicó una transformación logarítmica al espectro para atenuar las diferencias de intensidad y, posteriormente, se aplicó un umbral que conserva únicamente el 2 % de los puntos más intensos (valor ajustable). El resultado se binarizó, produciendo una imagen que idealmente contiene una única línea orientada de forma ortogonal a los surcos.

A continuación, se aplicó la Transformada de Hough utilizando los mismos parámetros descritos previamente, con un umbral de 100 (ajustable). Este proceso obtiene la línea con mayor cantidad de votos, de la cual se extrae el ángulo correspondiente. En las pruebas realizadas, el ángulo obtenido mediante este método fue prácticamente idéntico al calculado por regresión lineal, lo cual sugiere que las desviaciones observadas no provienen del método de estimación angular en sí, sino del enfoque de Fourier como aproximación general.

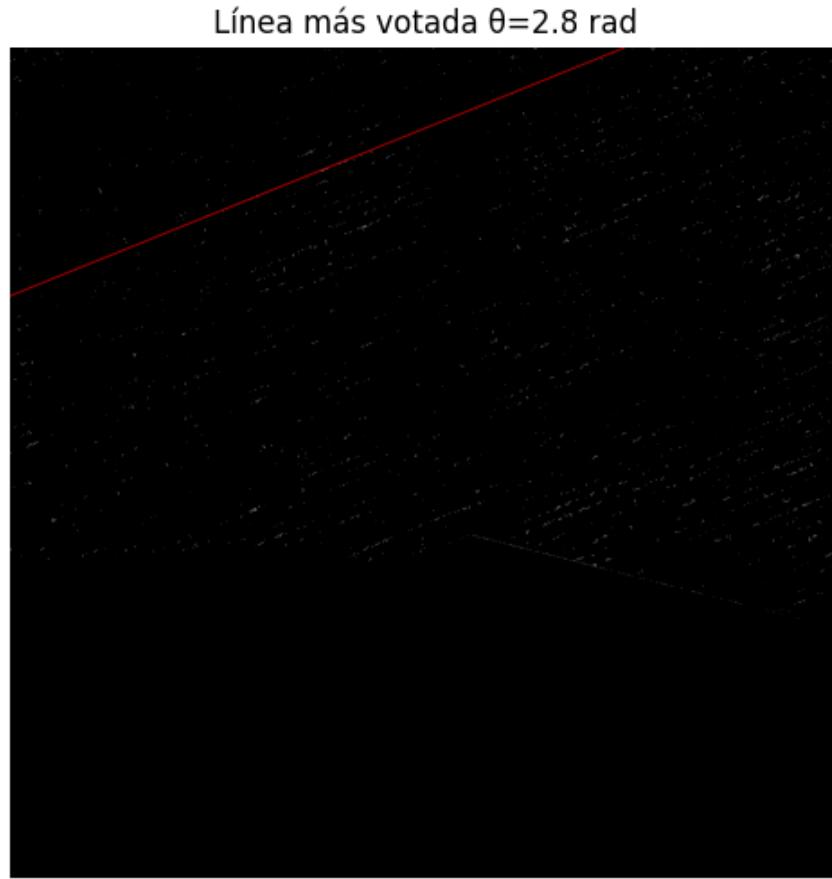


Figura 5.20: Resultado de la aplicación conjunta de la Transformada de Hough sobre el espectro de Fourier.

5.2. Detección de espacios vacíos

Independientemente del método utilizado para obtener el conjunto de líneas, a este punto se posee un arreglo de líneas en la forma (ρ, θ) , el cual representa la ubicación y orientación de los

surcos detectados en la imagen. A partir de este conjunto, el objetivo de esta etapa es identificar los segmentos ausentes o *espacios vacíos* que existen a lo largo de dichas líneas, con el propósito de cuantificarlos y presentarlos de manera visual.

El proceso inicia recorriendo cada línea detectada y generando una máscara binaria en la que se dibuja la línea correspondiente con un grosor de un píxel. A partir de esta máscara, se obtienen las coordenadas de todos los puntos que pertenecen a la línea. Luego, se calcula un vector unitario perpendicular a la línea, de manera que, para cada punto de la línea, se realiza un barrido en dirección normal hacia ambos lados de la línea en un rango de tolerancia definido por el parámetro *perp_tol*. Este barrido tiene como objetivo detectar si, en dicha vecindad perpendicular, existen píxeles blancos en la imagen binarizada.

En caso de no encontrar ningún píxel blanco dentro de este rango, se asume que el punto actual pertenece a un posible segmento vacío. Estos puntos son agrupados de forma consecutiva a lo largo de la línea, considerando además una tolerancia longitudinal *line_tol* que permite unir pequeños saltos o interrupciones dentro de un mismo segmento de vacío. Cuando la distancia entre dos puntos consecutivos supera este umbral, el segmento anterior se considera cerrado y se almacena si su longitud es mayor al mínimo establecido por el parámetro *min_seg_len*.

El resultado de este procedimiento son tres conjuntos de datos:

- **gap_points**: los píxeles centrales de los segmentos detectados como vacíos,
- **gap_slices**: los píxeles analizados a lo largo de todos los barridos perpendiculares, y
- **gap_segments**: los píxeles pertenecientes únicamente a los segmentos válidos (aquellos que superaron el umbral de longitud mínima).

Estos segmentos representan las ubicaciones donde existen interrupciones significativas a lo largo de las líneas detectadas. Posteriormente, esta información se utiliza para calcular el espacio total sin aprovechar en la imagen y visualizar estos espacios de manera agradable para el usuario. Para convertir los espacios vacíos a dimensiones físicas, se emplea un factor obtenido de los metadatos de las imágenes aéreas, el cual indica el área representada por cada pixel. En todas las imágenes se utiliza una resolución de (0.129, 0.129) m/pixel, lo que significa que cada píxel abarca 0.129 m tanto en el eje X como en el eje Y.

En este trabajo, los valores utilizados para los parámetros fueron determinados de forma empírica mediante experimentación con las imágenes de prueba. Se emplearon valores de *perp_tol* = 2, *min_seg_len* = 5, y *line_tol* = 1. Durante la experimentación, se observó que valores demasiado altos provocan la detección de falsos vacíos debido a ruido, mientras que valores demasiado bajos pueden omitir interrupciones reales en las líneas. En general, los resultados obtenidos con estos valores fueron consistentes y satisfactorios para las condiciones de las imágenes utilizadas.

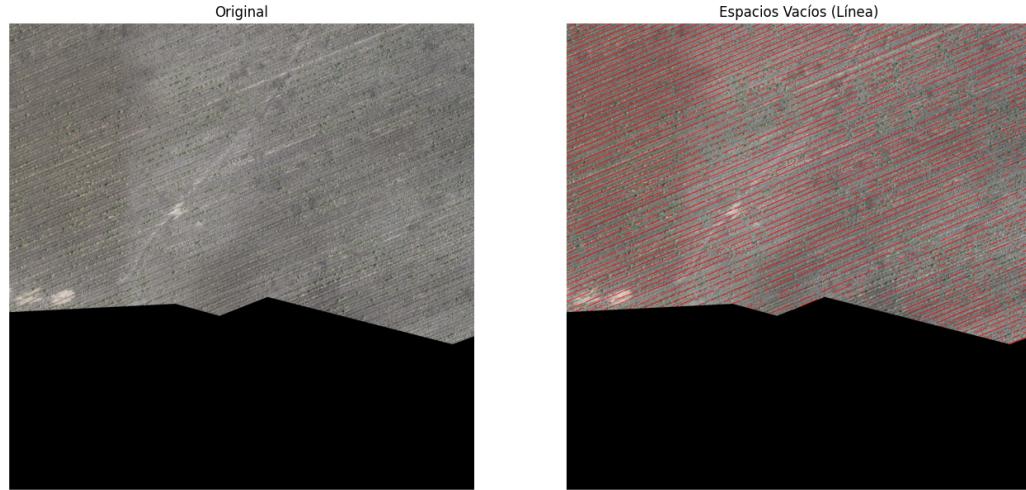


Figura 5.21: Visualización de los espacios vacíos detectados a lo largo de las líneas.

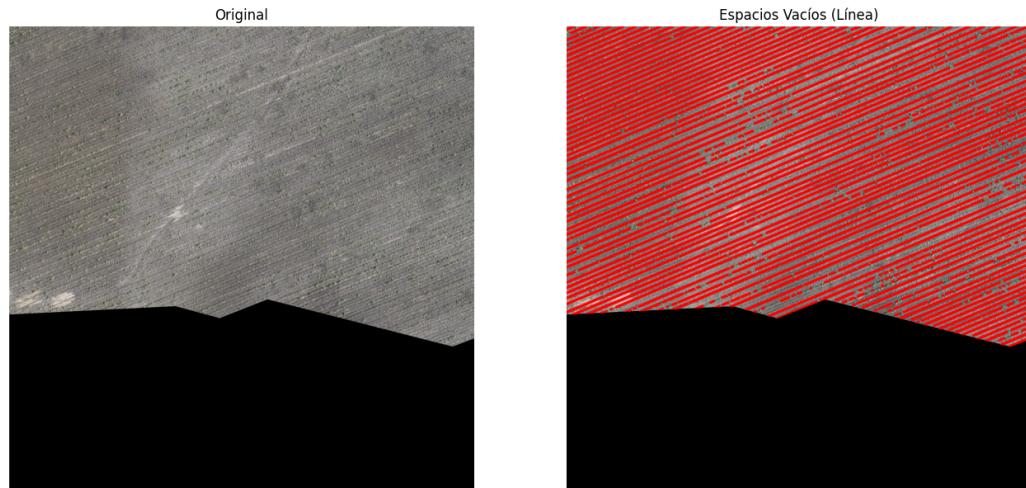


Figura 5.22: Visualización de los espacios vacíos detectados a lo largo de las líneas. Las cajas rojas indican los píxeles escaneados pertenecientes a segmentos vacíos.

CAPÍTULO 6

Resultados

6.0.1. Caso base de evaluación de algoritmos

Para visualizar los resultados en un *caso base*, se generó una imagen binarizada compuesta por varias líneas paralelas equidistantes con segmentos faltantes. Posteriormente, se eliminaron manualmente algunas líneas con el fin de evaluar el correcto funcionamiento del algoritmo de relleno de líneas. Esta imagen contiene un total de 20 líneas detectables, de las cuales se espera que se rellenen 14. La imagen inicial se muestra en la Figura 6.1.

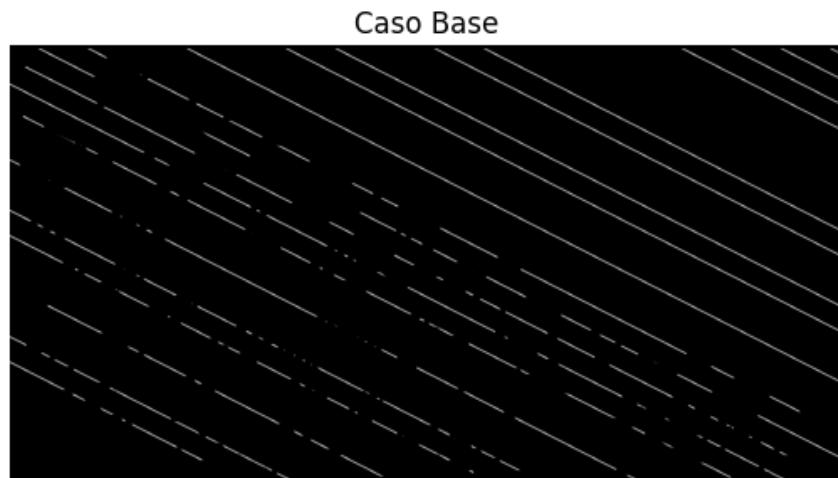


Figura 6.1: Imagen de caso ideal.

El primer algoritmo evaluado fue el basado en la Transformada de Hough. Las líneas detectadas por este método se muestran en la Figura 6.2. En este caso, se detectaron 18 líneas y se llenaron 16, con un tiempo promedio de procesamiento de 0.046 segundos.

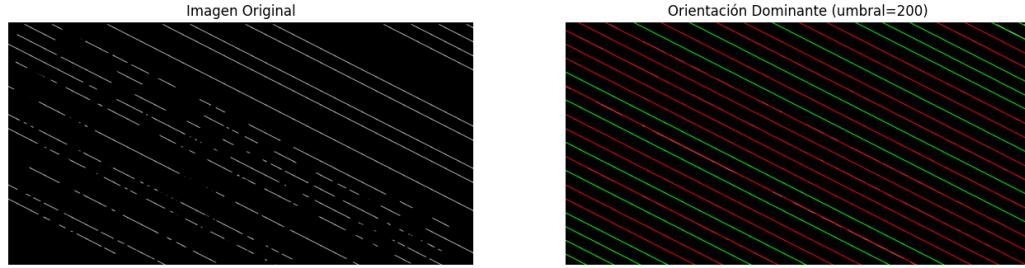


Figura 6.2: Líneas detectadas mediante la Transformada de Hough (rojo) y líneas rellenas por inferencia (verde).

El tiempo reportado para cada algoritmo corresponde al tiempo total desde el inicio del proceso hasta la obtención del conjunto final de líneas (detectadas e inferidas), promediado sobre cinco ejecuciones consecutivas.

A partir de este conjunto de líneas, se identificaron los espacios vacíos con los parámetros `perp_tol = 5` y `min_seg_len = 5`, mostrados en la Figura 6.3. Además, la Figura 6.4 muestra la visualización de estos espacios en función del área escaneada.

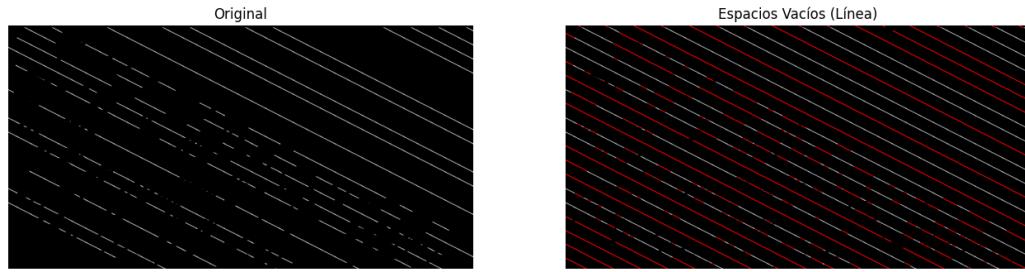


Figura 6.3: Espacios vacíos detectados.

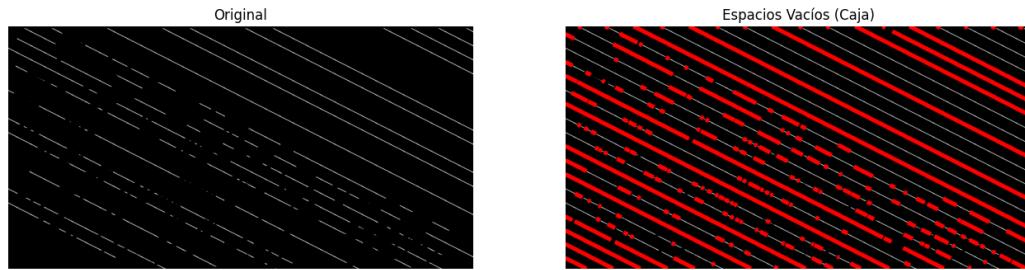


Figura 6.4: Espacios vacíos visualizados por su área escaneada.

En segundo lugar, se aplicó el algoritmo basado en el análisis de componentes principales (PCA). Se realizaron tres ejecuciones sobre la misma imagen, con el objetivo de analizar el impacto del parámetro k , correspondiente a la cantidad de líneas adicionales de escaneo. En la primera iteración se utilizó $k = 10$, resultando en 21 líneas de escaneo. En la segunda iteración se empleó $k = 5$, y en la tercera $k = 0$, correspondiente a una única línea de escaneo. La Figura 6.5 muestra el conjunto de líneas de escaneo para el caso de $k = 10$.

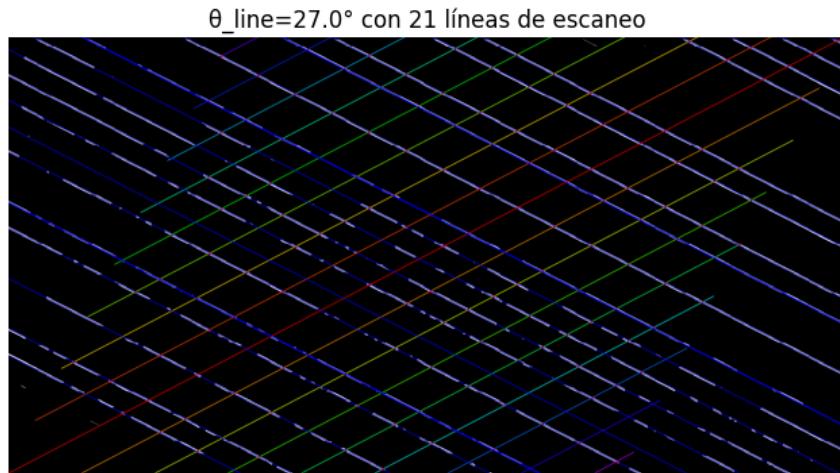


Figura 6.5: Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul) para $k = 10$.

Las líneas detectadas e inferidas resultantes se presentan en la Figura 6.6. En esta primera ejecución, se detectaron 20 líneas y se rellenaron 14, con un tiempo promedio de 0.494 segundos.

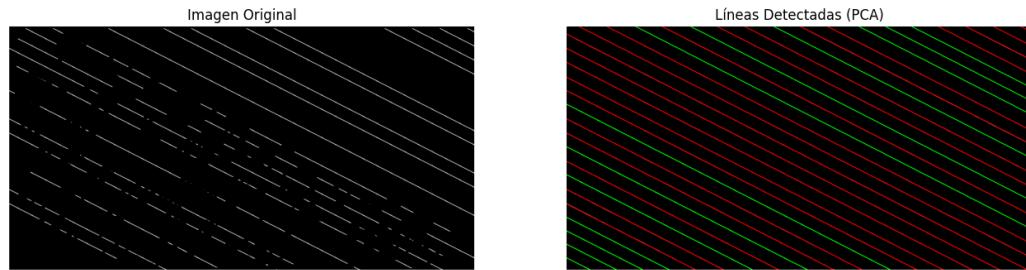


Figura 6.6: Líneas detectadas (rojo) y líneas rellenadas por inferencia (verde) para $k = 10$.

Para la segunda ejecución, la Figura 6.7 muestra las líneas de escaneo generadas con $k = 5$. Al igual que en el caso anterior, se detectaron 20 líneas y se rellenaron 14, pero se obtuvo un tiempo promedio de 0.311 segundos. Por lo tanto, el conjunto de líneas generado es idéntico al mostrado en la Figura 6.6.

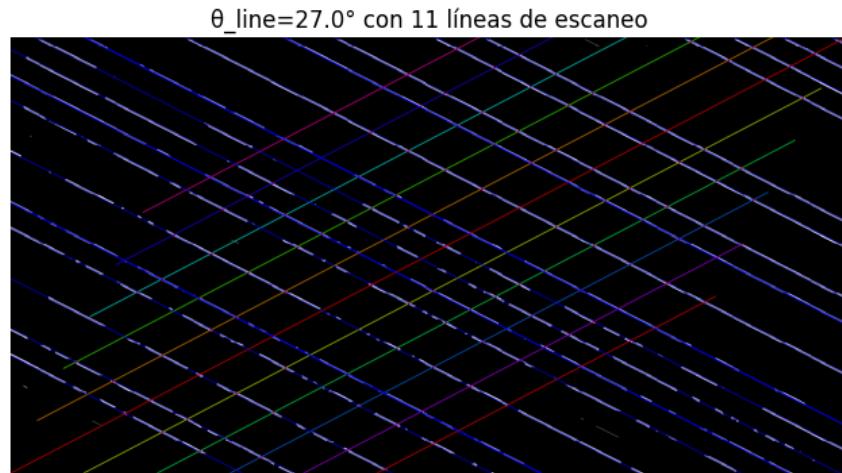


Figura 6.7: Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul) para $k = 5$.

Finalmente, con $k = 0$, se observa en la Figura 6.8 una única línea de escaneo, y en la Figura 6.9 el resultado correspondiente de las líneas detectadas e inferidas. En este caso, se detectaron 15 líneas y se rellenaron 19, con un tiempo promedio de procesamiento de 0.243 segundos.

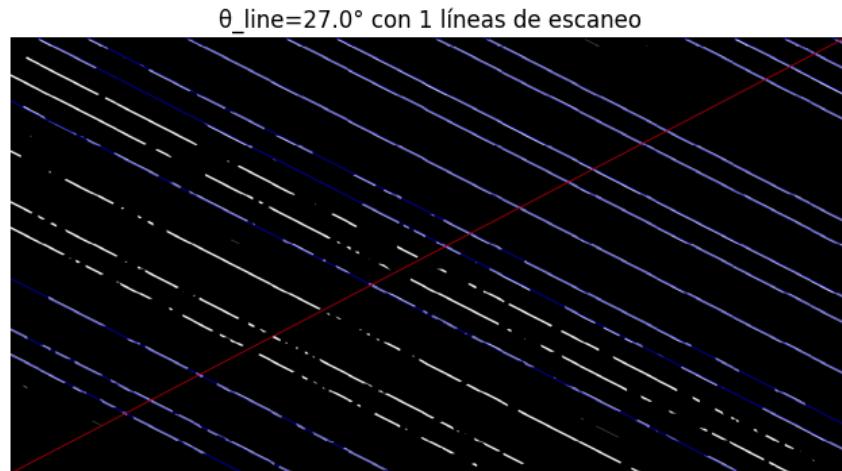


Figura 6.8: Línea de escaneo (rojo) y surcos detectados previo al agrupamiento (azul) para $k = 0$.

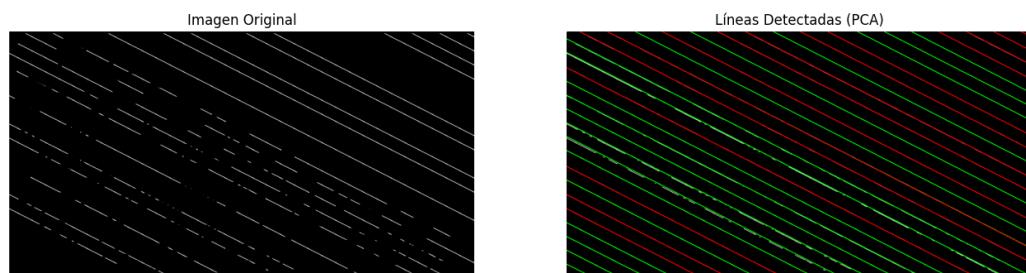


Figura 6.9: Líneas detectadas (rojo) y líneas rellenas por inferencia (verde) para $k = 0$.

Se observa que para $k = 0$ se detecta un menor número de líneas mediante el escaneo, dependiendo en mayor medida del proceso de inferencia para completar los surcos faltantes. A pesar de ello, el conjunto final de líneas detectadas e inferidas es equivalente al obtenido con valores mayores de k .

En lo que respecta al método basado en la Transformada de Fourier, este no logró determinar correctamente el ángulo dominante de los surcos. Aunque el espectro de magnitud obtenido parece visualmente correcto (Figura 6.10), los puntos de máxima intensidad no reflejan la orientación real de las líneas.

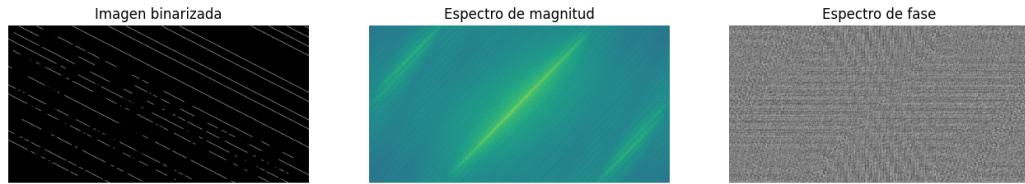


Figura 6.10: Espectros de magnitud y fase resultantes de la imagen binarizada.

Los $N = 20$ puntos más intensos en el espectro se muestran en la Figura 6.11, mientras que la Figura 6.12 muestra la línea arbitraria generada a partir de estos puntos, cuyo ángulo fue determinado mediante regresión lineal.

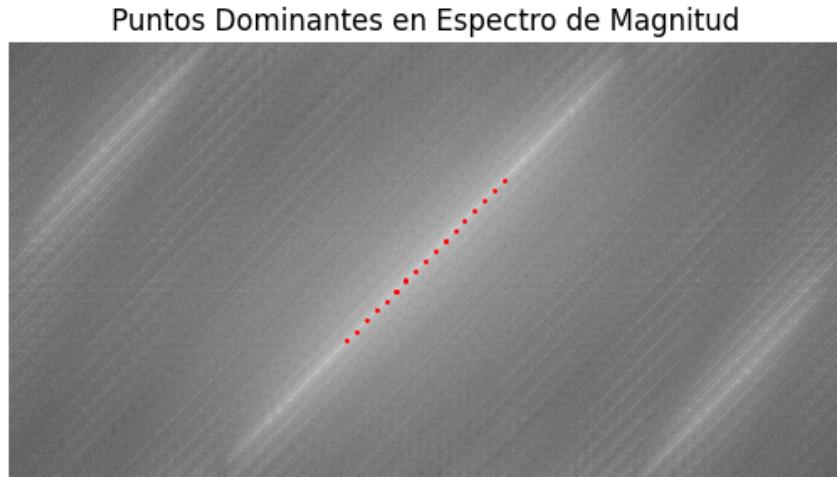


Figura 6.11: Puntos de mayor intensidad sobreuestos al espectro de magnitud.

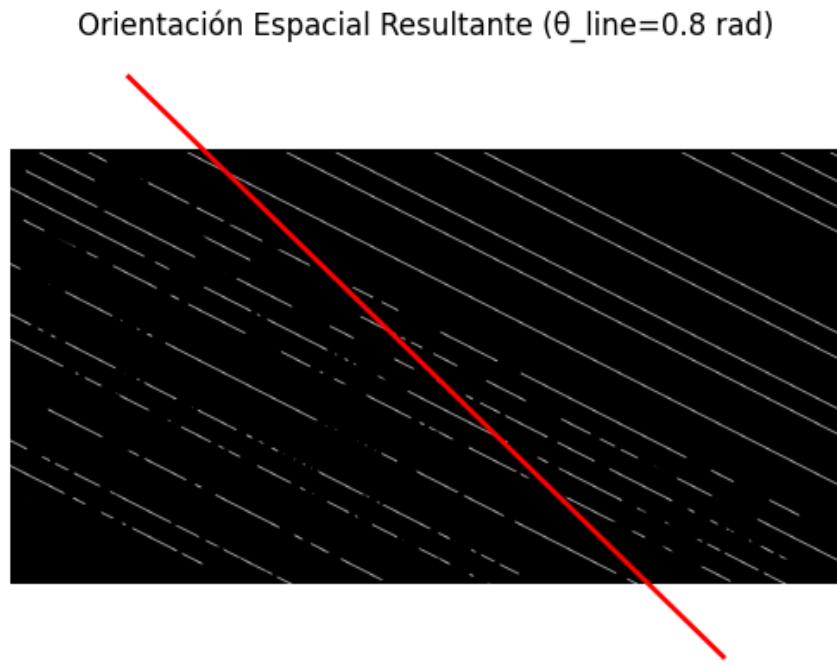


Figura 6.12: Línea arbitraria con ángulo resultante del análisis en el dominio de Fourier.

Al aplicar el algoritmo de escaneo descrito en la Sección ??, las líneas resultantes se muestran en las Figuras 6.13 y 6.14. Debido al ángulo incorrecto calculado, las líneas detectadas y los espacios vacíos resultantes son erróneos, como se observa en la Figura 6.15.

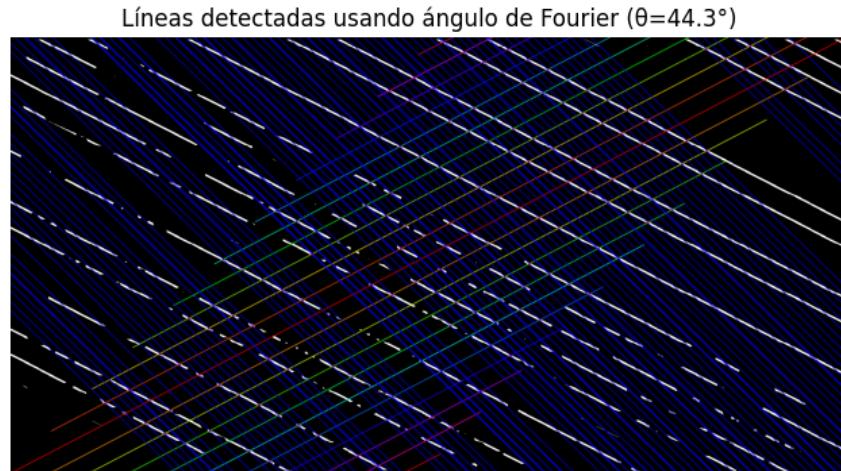


Figura 6.13: Líneas de escaneo (líneas coloridas) y surcos detectados previo al agrupamiento (azul).

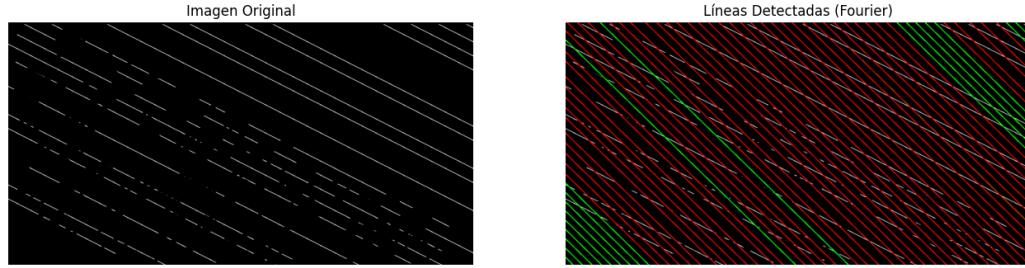


Figura 6.14: Líneas detectadas (rojo) y líneas rellenas por inferencia (verde).

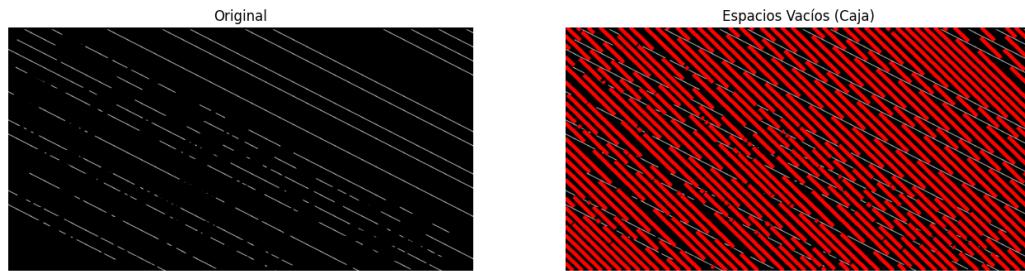


Figura 6.15: Espacios vacíos visualizados por su área escaneada.

Este acercamiento detecta 48 líneas y rellena 19, con un tiempo promedio de procesamiento de 0.363 segundos.

Como se muestra en la Tabla 6.1, el enfoque basado en Fourier no resultó funcional para este caso, ya que es propenso a calcular ángulos incorrectos, generando resultados inconsistentes. En contraste, los métodos basados en Hough y PCA fueron exitosos, siendo el segundo más robusto, aunque más lento, debido a su proceso de escaneo y agrupamiento. El método de Hough, si bien más rápido, tiende a omitir líneas cercanas a los bordes de la imagen, una limitación que el PCA no presenta.

Tabla 6.1: Comparativa de algoritmos de detección y relleno de líneas.

Algoritmo	Líneas Detectadas	Líneas Rellenadas	Tiempo Promedio (s)
Transformada de Hough	18	16	0.046
PCA ($k = 10$)	20	14	0.494
PCA ($k = 5$)	20	14	0.311
PCA ($k = 0$)	15	19	0.243
Transformada de Fourier	48	19	0.363

A continuación, se presentan los resultados de los tres algoritmos aplicados a cinco imágenes reales, obtenidas del *pipeline* externo descrito en el Capítulo 5. Todas las imágenes de esta fuente poseen una resolución de 2048x2048 píxeles, equivalente a un área de $69797m^2$. La Figura 6.16 corresponde a la primer imagen aérea, la cual presenta surcos verticales en la mitad superior, mientras que la parte inferior contiene árboles y un cuerpo de agua. En su versión binarizada, se conservaron algunas plantas que no forman parte de los surcos, lo que representa un desafío considerable para los algoritmos de detección de líneas.

Por motivos demostrativos, se aplicó una máscara manual para eliminar los elementos que no pertenecen a la estructura de los surcos, cuyo resultado se muestra en la Figura 6.17.

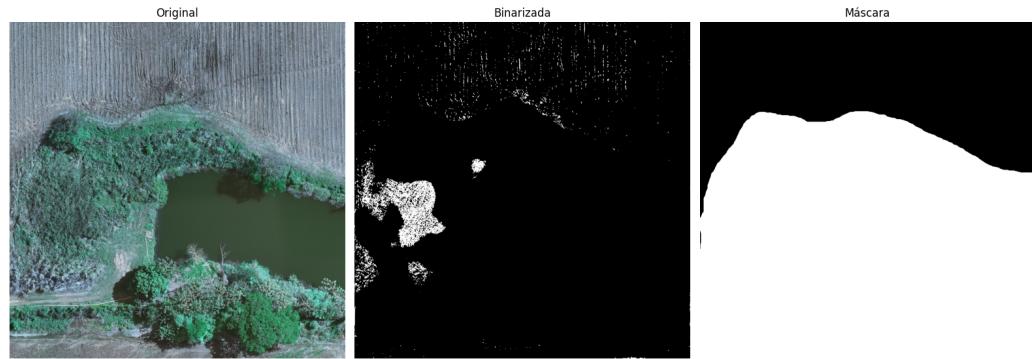


Figura 6.16: Primera imagen aérea.

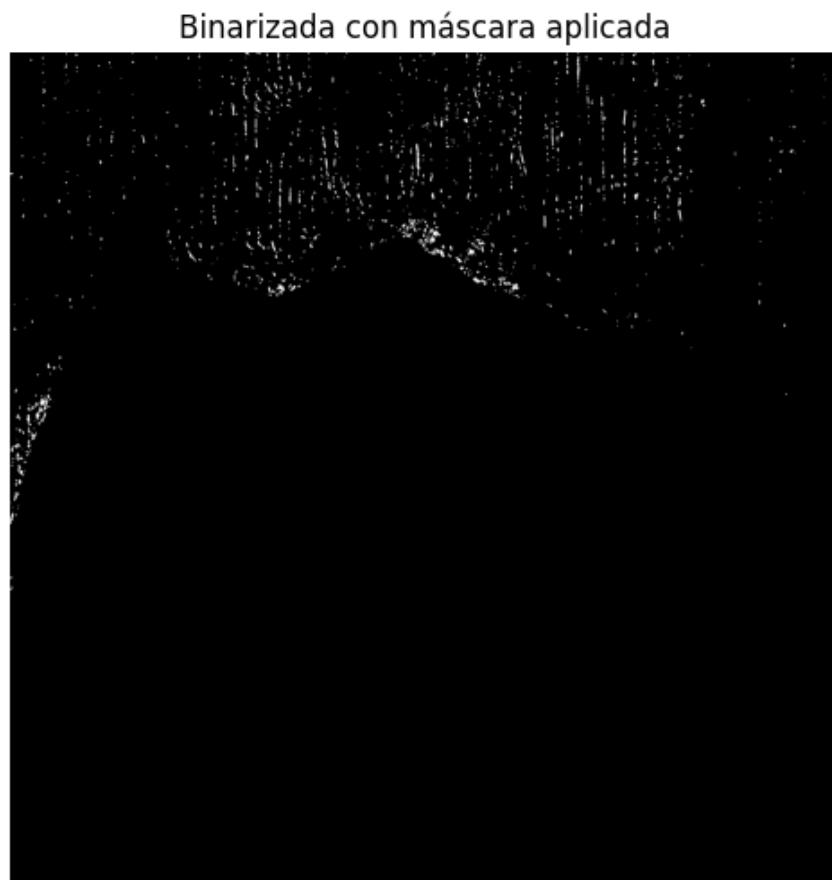


Figura 6.17: Máscara aplicada a imagen binaria.

Para el algoritmo basado en la Transformada de Hough, el umbral óptimo determinado fue de 100. Con este valor, se detectaron 7 líneas, de las cuales 2 resultaron redundantes al encontrarse sobre otra línea con un ángulo ligeramente distinto, insuficiente para ser descartadas durante el proceso de eliminación de duplicados. Con base en estas detecciones, el algoritmo fue capaz de inferir 51 líneas adicionales, como se observa en la Figura 6.18.

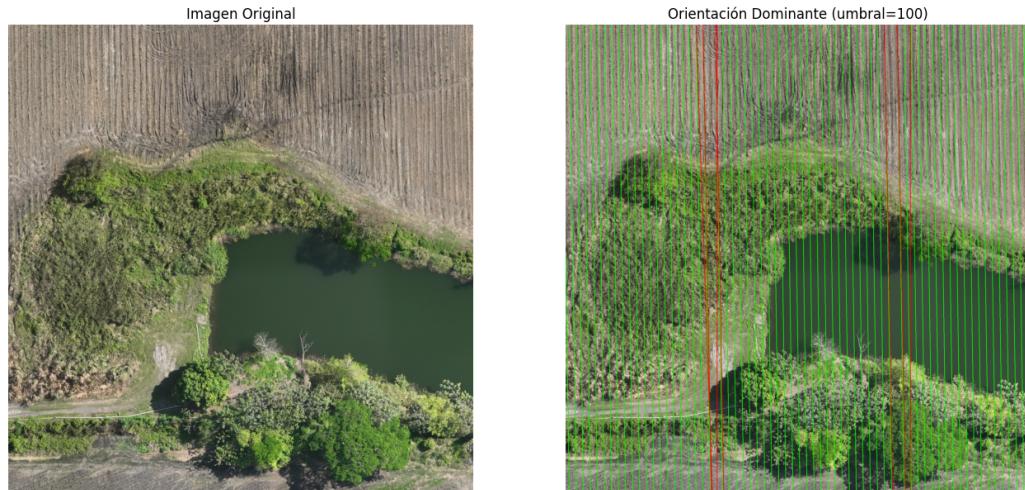


Figura 6.18: Líneas detectadas e inferidas por el algoritmo basado en la Transformada de Hough.

A partir de este conjunto de líneas y utilizando la máscara binaria, se obtuvieron los espacios vacíos mostrados en la Figura 6.19. Las métricas cuantitativas correspondientes a este método se presentan en el Cuadro 6.2.



Figura 6.19: Espacios vacíos detectados con el algoritmo basado en la Transformada de Hough.

En el caso del algoritmo basado en PCA, se observa en la Figura 6.20 que, incluso con la máscara binaria aplicada (Figura 6.17), el ángulo estimado para los surcos no corresponde al real. Esto se debe a que el componente conectado más grande de la imagen pertenece a una región que no forma parte de los surcos principales. En consecuencia, el componente principal calculado resulta incorrecto, evidenciando una de las principales limitaciones de este método.

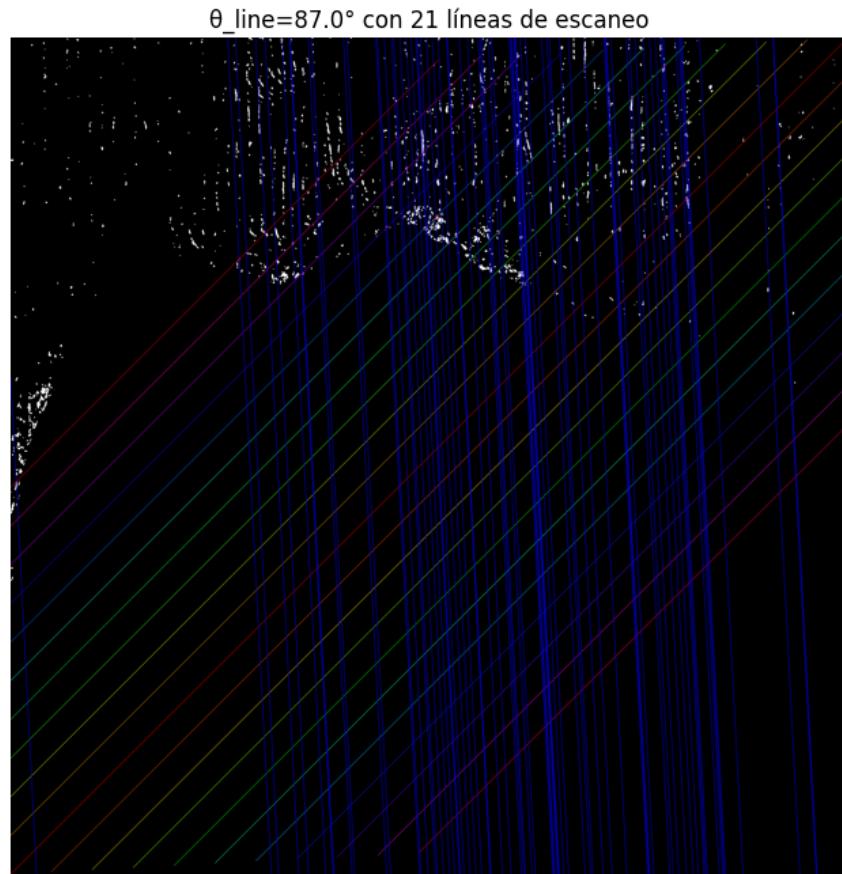


Figura 6.20: Líneas de escaneo determinadas a partir del ángulo estimado por PCA.

Como resultado de utilizar un ángulo erróneo, las líneas obtenidas (Figura 6.21) no se alinean con la estructura de los surcos, generando una detección de espacios vacíos inexacta, tal como se muestra en la Figura 6.22. En este caso, el algoritmo detectó 33 líneas e infirió 58 adicionales, aunque dos surcos cercanos al centro de la imagen no fueron detectados. Las métricas de desempeño se detallan en el Cuadro 6.2.



Figura 6.21: Líneas detectadas e inferidas por el algoritmo basado en PCA.



Figura 6.22: Espacios vacíos detectados con el algoritmo basado en PCA.

Finalmente, para el método basado en la Transformada de Fourier, se generó el espectro de magnitud correspondiente y se localizaron los $N = 20$ puntos más intensos, visibles en la Figura 6.23. A partir de estos puntos, se realizó una regresión lineal que permitió determinar un ángulo coherente con la orientación real de los surcos, resultando en una detección exitosa.

Puntos Dominantes en Espectro de Magnitud

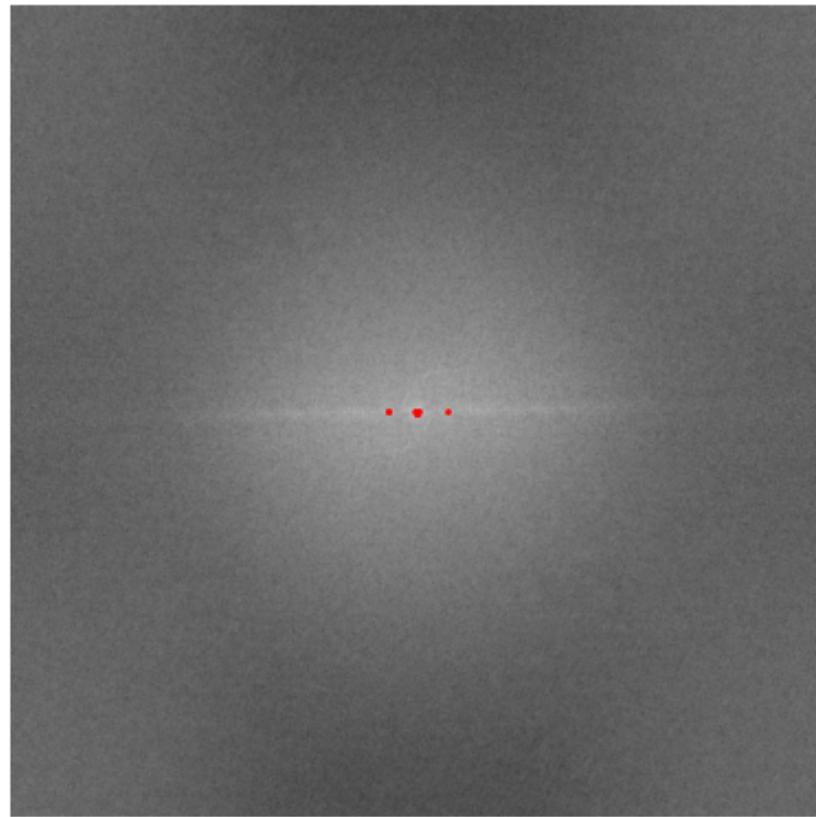


Figura 6.23: Espectro de magnitud (escala logarítmica) y puntos de mayor intensidad.

Con el ángulo estimado, se efectuó el escaneo de líneas mostrado en la Figura 6.24, logrando detectar 28 líneas y rellenar 56 adicionales. El conjunto resultante de líneas detectadas e inferidas se muestra en la Figura 6.25. Si bien el desempeño general del método fue satisfactorio, se observó la ausencia de un surco en la parte izquierda de la imagen y una leve desalineación de algunas líneas respecto a su estructura original. Los espacios vacíos resultantes se muestran en la Figura 6.26.

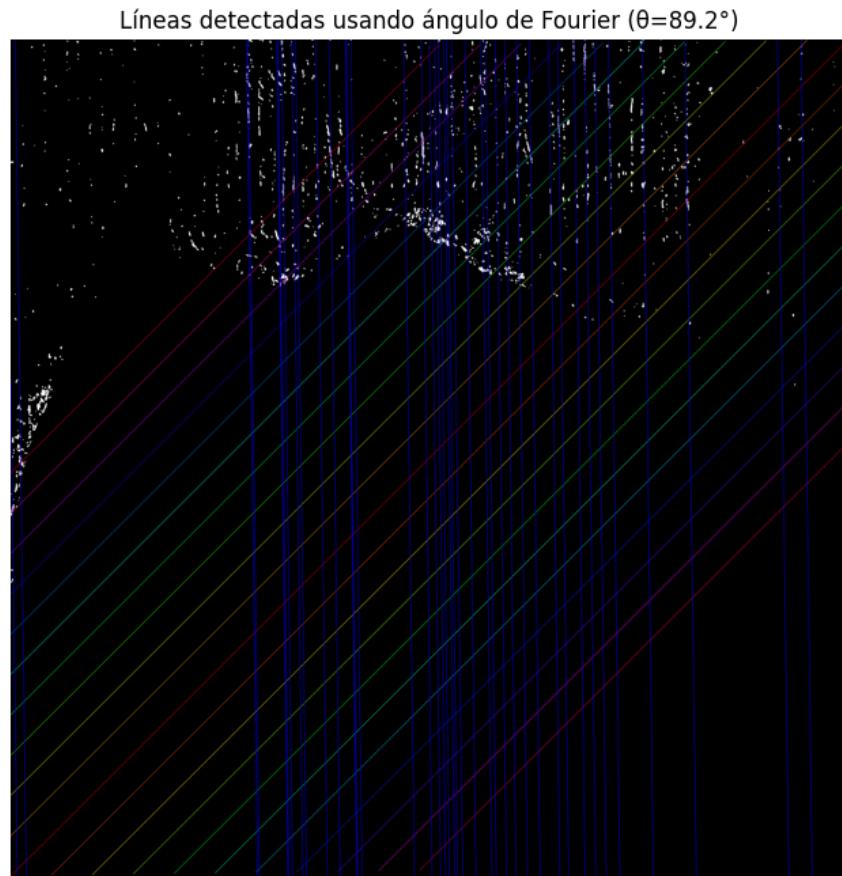


Figura 6.24: Líneas de escaneo determinadas mediante la Transformada de Fourier.



Figura 6.25: Líneas detectadas e inferidas por el algoritmo basado en la Transformada de Fourier.



Figura 6.26: Espacios vacíos detectados mediante la Transformada de Fourier.

El Cuadro 6.2 resume las métricas obtenidas para cada uno de los tres métodos en esta primera imagen. Se incluyen el porcentaje de área vacía detectada, el porcentaje de área válida respecto a la región analizada, y la longitud total de los surcos detectados, expresada en metros.

Tabla 6.2: Métricas de desempeño para los algoritmos aplicados a la primera imagen real.

Algoritmo	Porcentaje vacío (%)	Porcentaje válido (%)	Longitud total (m)
Transformada de Hough	0.98	2.89	16,523.61
PCA	1.40	4.12	23,170.78
Transformada de Fourier	1.39	4.08	23,108.64

En general, los métodos basados en Hough (Figuras 6.18 y 6.19) y Fourier (Figuras 6.23, 6.24, 6.25 y 6.26) presentaron resultados más consistentes que el de PCA (Figuras 6.20, 6.21 y 6.22), debido a la detección incorrecta del ángulo. Por otro lado, el método de Hough produjo algunas líneas redundantes, las cuales pueden llegar a inflar las métricas resultantes ya que, efectivamente, se estarían contando algunos espacios dos veces. Para esta imagen, el método por Transformada de Fourier resultó ser el más exitoso.

Para la segunda imagen, visible en la Figura 6.27, se optó por emplear una máscara vacía con el objetivo de analizar el impacto de estructuras binarias con formas irregulares. En este caso, en la esquina superior izquierda se observa una estructura de tamaño considerable en comparación con los surcos, correspondiente a una región donde los cultivos están completamente crecidos. Además, la imagen presenta cuatro zonas de surcos claramente separadas por un camino. Las dos regiones del lado izquierdo poseen una orientación y separación de surcos prácticamente idénticas, mientras que las del lado derecho presentan ángulos distintos. Estos factores pueden afectar significativamente la detección de surcos en algunos algoritmos.

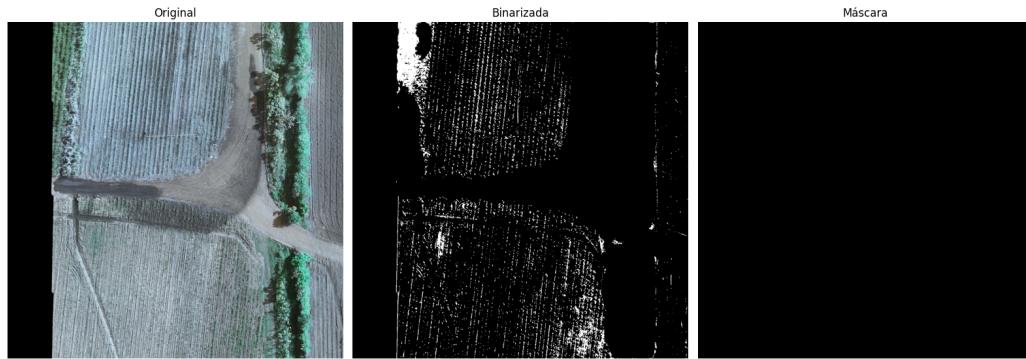


Figura 6.27: Segunda imagen aérea.

El algoritmo basado en la Transformada de Hough no se vio afectado de forma considerable por los obstáculos mencionados, dado que la detección de cada línea es completamente independiente del resto. En este caso, se utilizó un umbral considerablemente más alto (450), ya que con valores menores la estructura irregular en la esquina superior izquierda generaba un número significativo de líneas incorrectas. Con este parámetro, se detectaron 7 líneas y se infirieron 67, de las cuales 2 se intersectan en la parte inferior de la imagen, lo que resulta problemático al momento de calcular los espacios vacíos. Asimismo, al no emplear una máscara que elimine los surcos del extremo derecho, el algoritmo infiere aún más líneas para cubrir dichas zonas, aunque con orientaciones incorrectas.



Figura 6.28: Líneas detectadas e inferidas mediante la Transformada de Hough.

Al carecer de una máscara, la detección de espacios arroja métricas artificialmente elevadas, ya que múltiples regiones irrelevantes son consideradas como espacios sin cultivo. No obstante, al observar únicamente las áreas relevantes, las líneas detectadas y sus respectivos vacíos son razonablemente precisos, limitados principalmente por los detalles perdidos durante la binarización.



Figura 6.29: Espacios vacíos detectados con la Transformada de Hough.

En cuanto al algoritmo basado en PCA, la Figura 6.30 muestra que, de manera similar al caso anterior, la detección del ángulo principal es completamente errónea debido a la influencia de los componentes conectados con formas irregulares. En particular, el componente de gran tamaño en la esquina superior izquierda ocasiona que el eje principal de la imagen no corresponda con la orientación de los surcos.

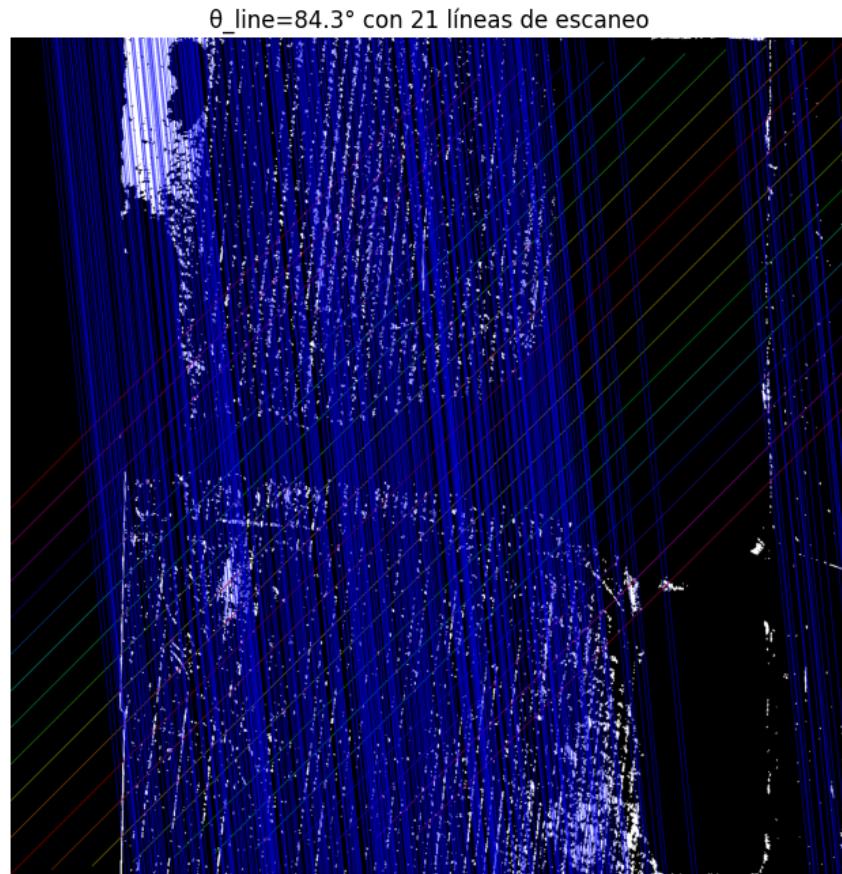


Figura 6.30: Líneas de escaneo con ángulo determinado mediante PCA.

Como consecuencia del ángulo incorrecto, tanto las líneas resultantes como los espacios vacíos detectados son completamente erróneos. En este caso, el algoritmo detectó 61 líneas y se infirieron 15, sin considerar aquellas que recaen sobre regiones negras de la imagen original.



Figura 6.31: Líneas detectadas e inferidas mediante PCA.



Figura 6.32: Espacios vacíos detectados mediante PCA.

Respecto al algoritmo que emplea la Transformada de Fourier, el espectro de magnitud revela una estructura lineal principal, aunque los $N = 20$ puntos más intensos se concentran cerca del centro del espectro, como se observa en la Figura 6.33.

Puntos Dominantes en Espectro de Magnitud

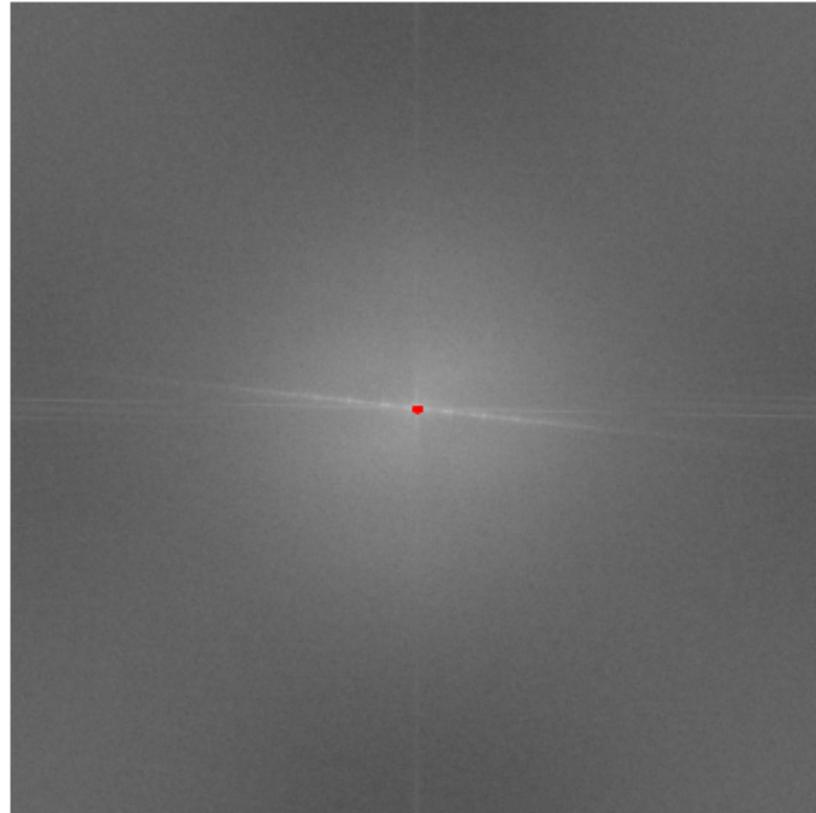


Figura 6.33: Espectro de magnitud (escala logarítmica) y puntos más intensos.

Debido a esta concentración, la regresión lineal que estima el ángulo de los surcos obtiene un resultado incorrecto, por lo que tanto el escaneo como las líneas resultantes también presentan orientaciones erróneas. Cabe destacar que el ángulo estimado por este método difiere únicamente en 2 respecto al obtenido mediante PCA, lo que explica que la cantidad de líneas detectadas e inferidas sea idéntica para ambos casos.

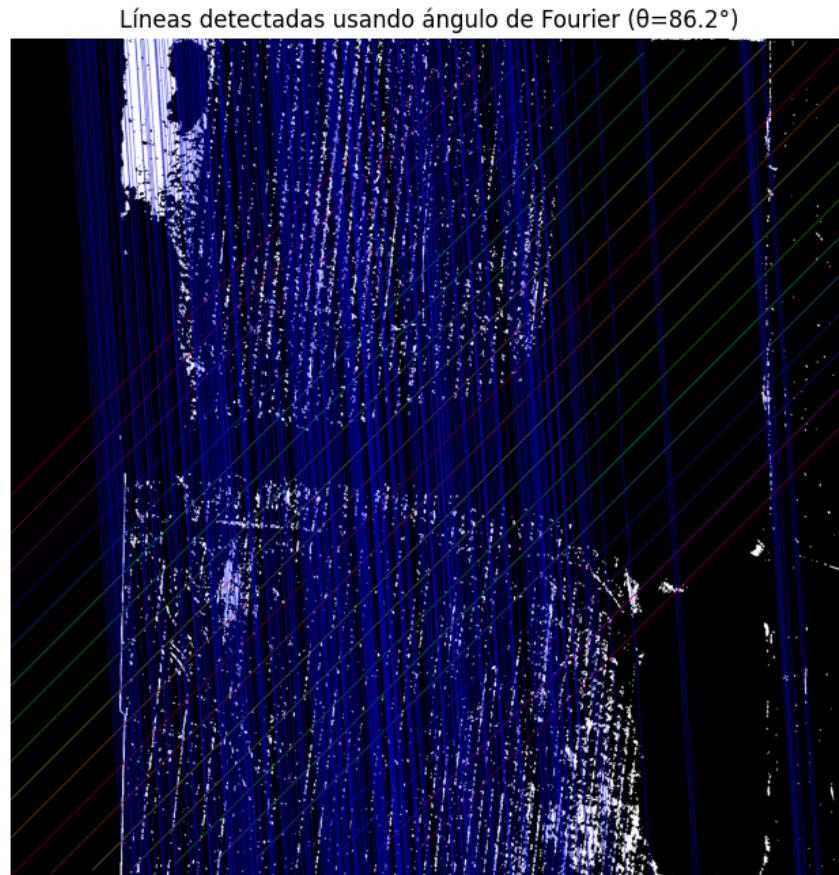


Figura 6.34: Líneas de escaneo con ángulo determinado por la Transformada de Fourier.



Figura 6.35: Líneas detectadas e inferidas mediante la Transformada de Fourier.

Al igual que con PCA, la detección de espacios vacíos y las métricas derivadas son incorrectas, debido tanto a las regiones irrelevantes consideradas como al ángulo de escaneo equivocado.



Figura 6.36: Espacios vacíos detectados mediante la Transformada de Fourier.

Las métricas cuantitativas obtenidas para cada método se resumen en el Cuadro 6.3, donde se reportan el porcentaje de área vacía detectada, el porcentaje válido dentro de la región de interés, y la longitud total de surcos estimada en metros.

Tabla 6.3: Métricas comparativas de los tres métodos para la segunda imagen.

Método	Porcentaje vacío (%)	Porcentaje válido (%)	Longitud total (m)
Transformada de Hough	2.58	2.58	15,835.16
PCA	3.06	3.06	19,750.69
Transformada de Fourier	2.96	2.96	19,184.49

La tercera imagen, visualizada en la Figura 6.37, exhibe una estructura considerablemente buena ya que toda la imagen corresponde exclusivamente a surcos, sin áreas irrelevantes. En este caso, se opta por utilizar una máscara para eliminar el componente anómalo en la parte inferior de la imagen (Figura 6.38), que corresponde a arbustos que no son relevantes en este análisis. Por lo tanto, la máscara únicamente cubre este espacio, con el fin de solventar los problemas vistos en los ejemplos anteriores en el algoritmo de PCA.

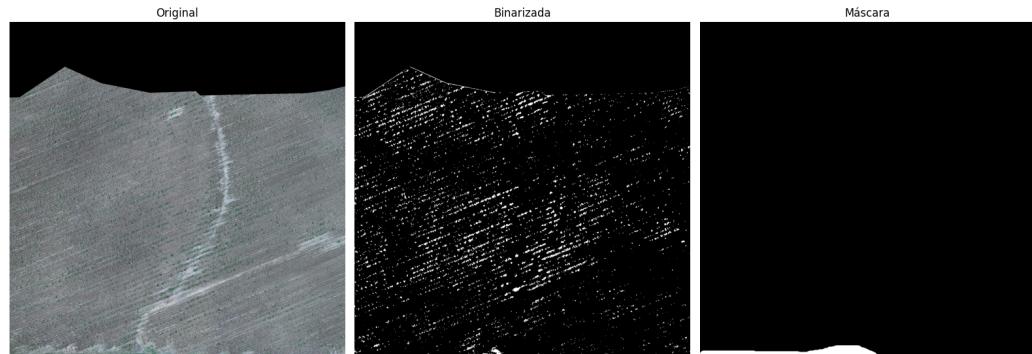


Figura 6.37: Tercera imagen aérea.

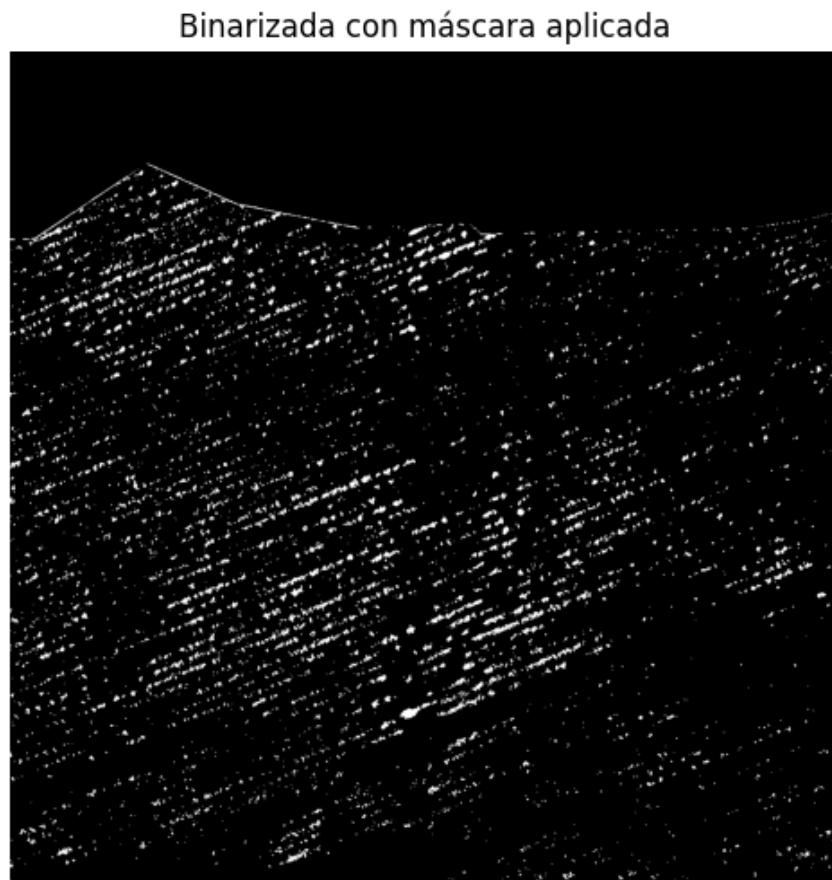


Figura 6.38: Máscara aplicada a imagen binaria.

En cuanto al algoritmo que emplea la Transformada de Hough, se utilizó un umbral relativamente alto (300). Con umbrales más bajos, se producía una cantidad significativa de líneas redundantes, mientras que este proporciona líneas considerablemente buenas, consistentes con la estructura de los cultivos. Sin embargo, las líneas inferidas se desfasan cerca de las esquinas de la imagen, lo cual impacta la cuantificación de espacios vacíos en pasos posteriores. En total, el algoritmo detectó 17 líneas con 69 inferidas (Figura 6.39).

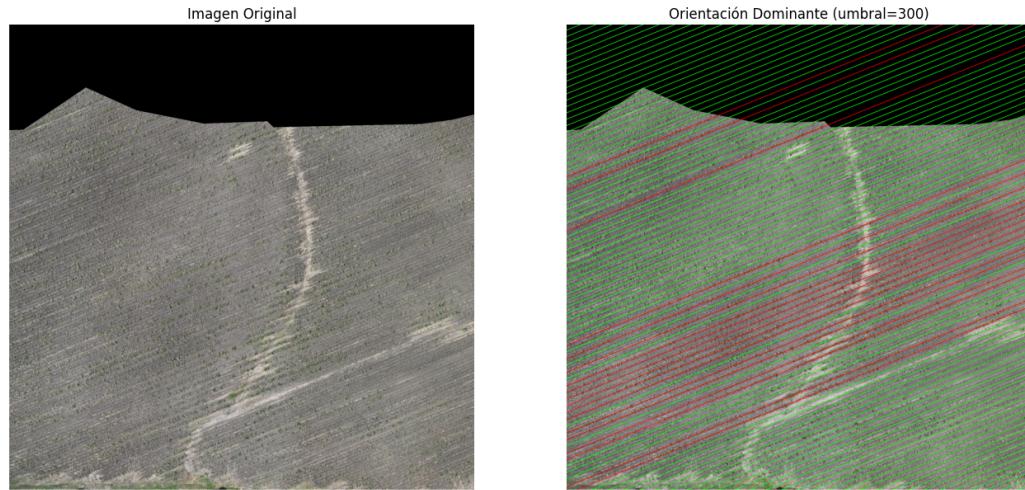


Figura 6.39: Líneas detectadas e inferidas por algoritmo con Transformada de Hough.

Dado que el conjunto de líneas resultó bastante bueno, el análisis de espacios vacíos también resulta exitoso. Sin embargo, gracias al desfase ligero mencionado anteriormente, las líneas cercanas a las orillas se consideran completamente vacías ya que no se encuentran precisamente sobre los surcos, lo cual resulta en métricas erróneas (Figura 6.40).

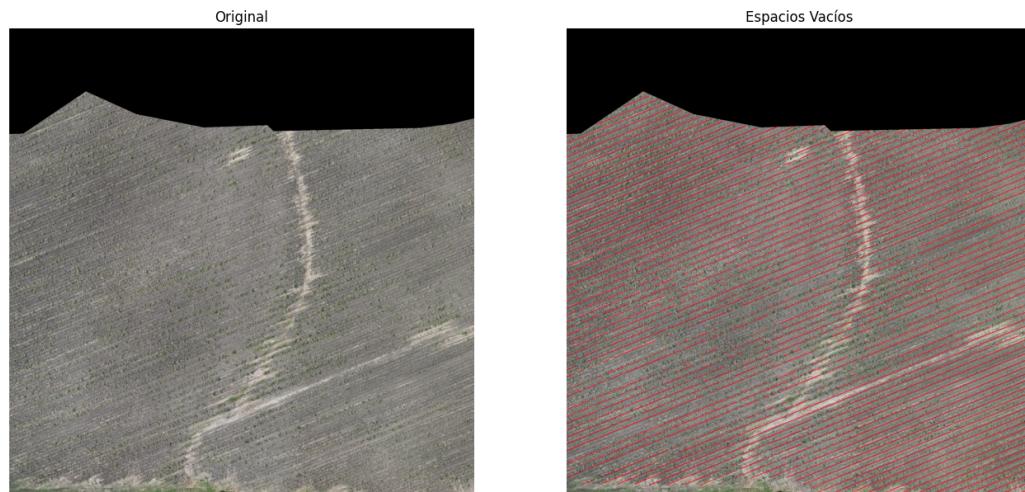


Figura 6.40: Espacios vacíos detectados con Transformada de Hough.

En cuanto al algoritmo de PCA, se puede observar que el ángulo detectado es acertado, gracias a la eliminación de la estructura en parte inferior de la imagen. Sin esta limitante, el algoritmo de PCA es capaz de encontrar ángulos acertados. Gracias a esto, el escaneo de las líneas también es

exitoso, encontrando 73 líneas con 23 inferidas (Figuras 6.41 y 6.42). Además, es de notar que las líneas en esta imagen no poseen un desfase respecto a los surcos de la imagen, por lo que la detección de espacios vacíos es considerablemente buena (Figura 6.43).

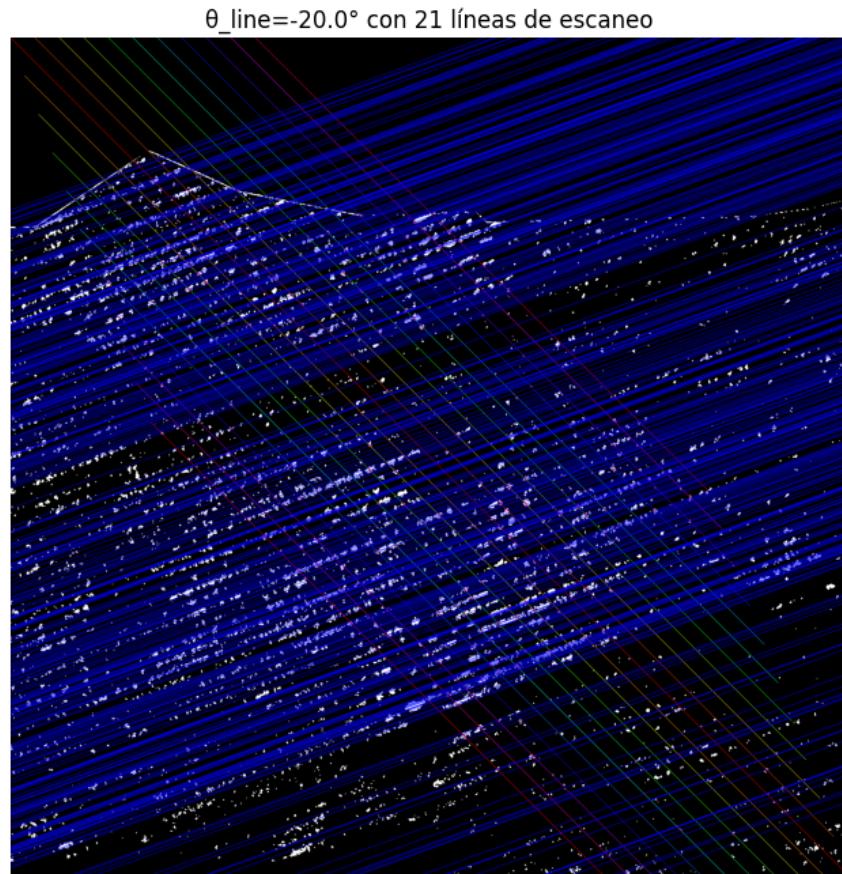


Figura 6.41: Líneas de escaneo con ángulo determinado por PCA.

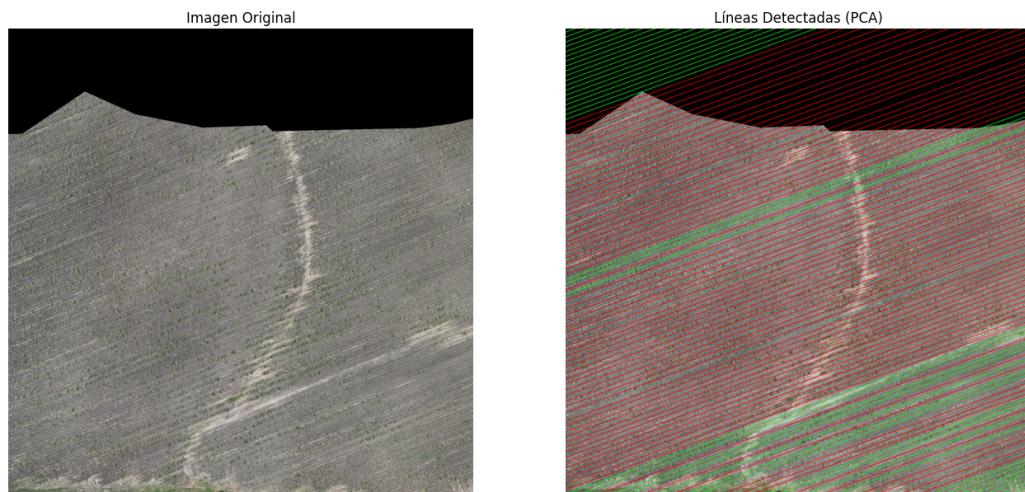


Figura 6.42: Líneas detectadas e inferidas por algoritmo con PCA.

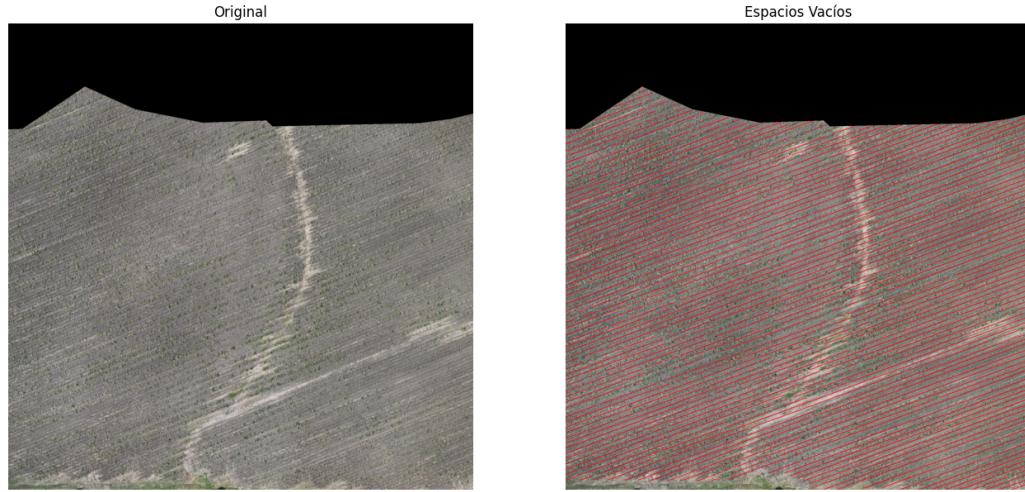


Figura 6.43: Espacios vacíos detectados con PCA.

En cuanto al algoritmo de Fourier, el espectro de magnitud revela una estructura lineal bien definida, por lo que los $N = 20$ puntos más intensos se encuentran en una línea clara (Figura 6.44). Al aplicar regresión lineal sobre estos puntos, se obtiene un ángulo muy similar al del PCA, nuevamente variando solamente por 2° luego de normalizar el ángulo a un rango de $[0^\circ, 180^\circ]$. Por lo tanto, la cantidad de líneas detectadas para estos dos métodos y sus resultados son bastante similares (Figuras 6.45, 6.46 y 6.47).

Puntos Dominantes en Espectro de Magnitud

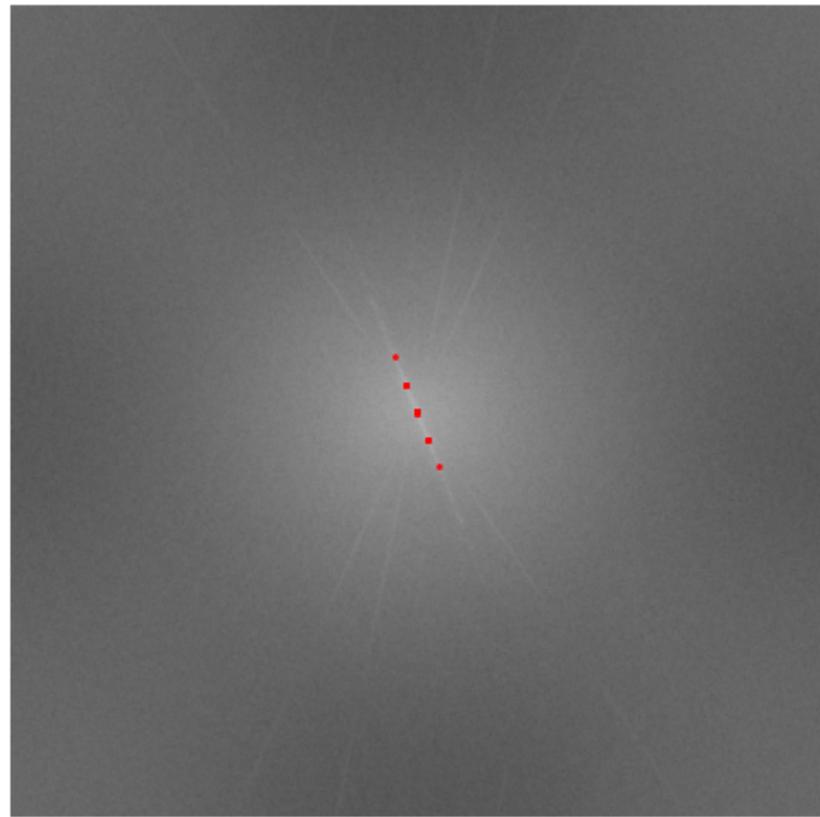


Figura 6.44: Espectro de magnitud (escala logarítmica) y puntos más intensos.

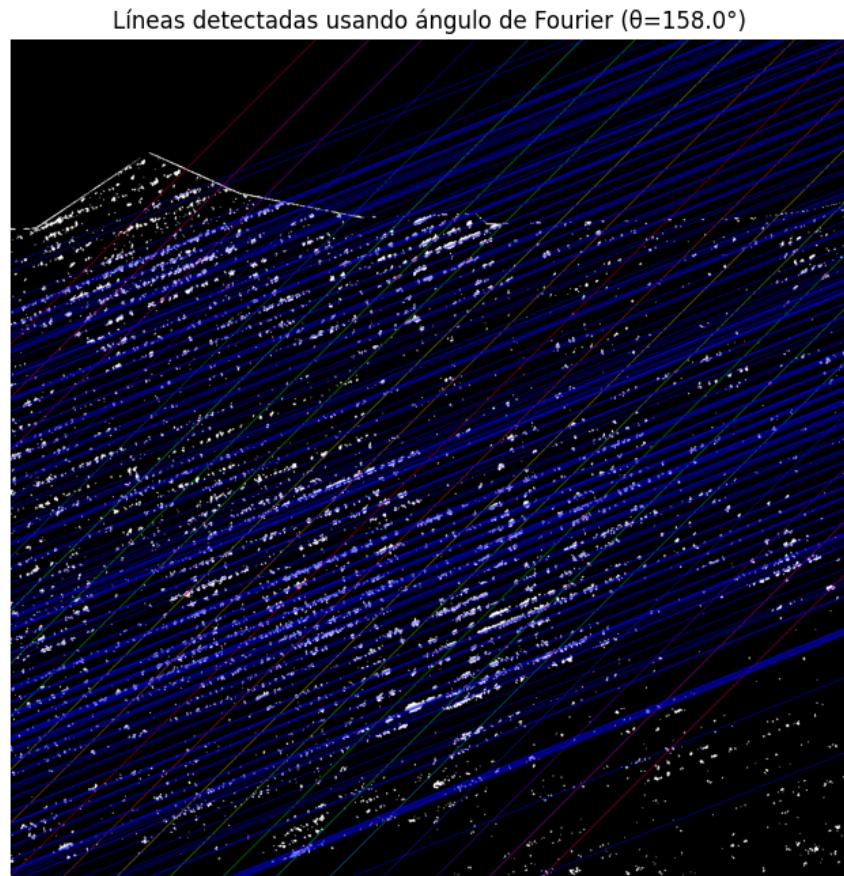


Figura 6.45: Líneas de escaneo con ángulo determinado por Transformada de Fourier.

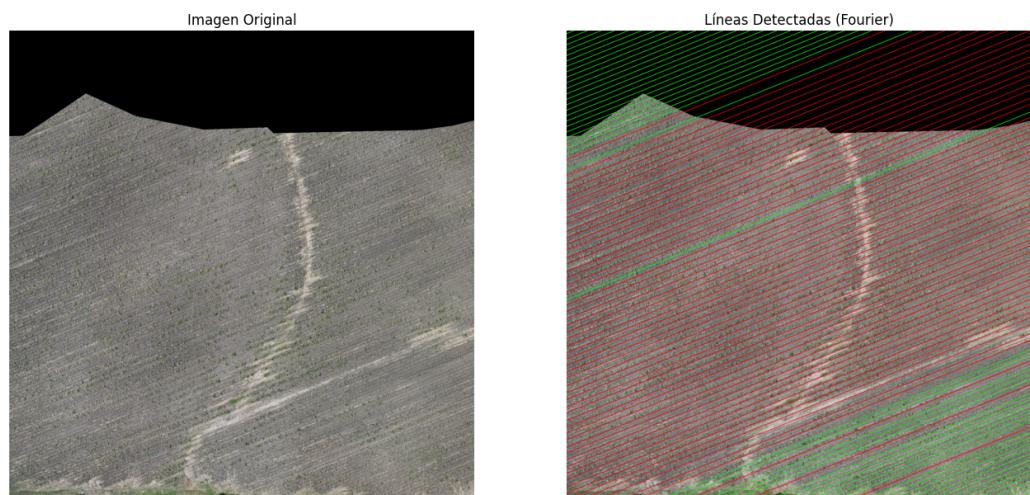


Figura 6.46: Líneas detectadas e inferidas por algoritmo con Transformada de Fourier.

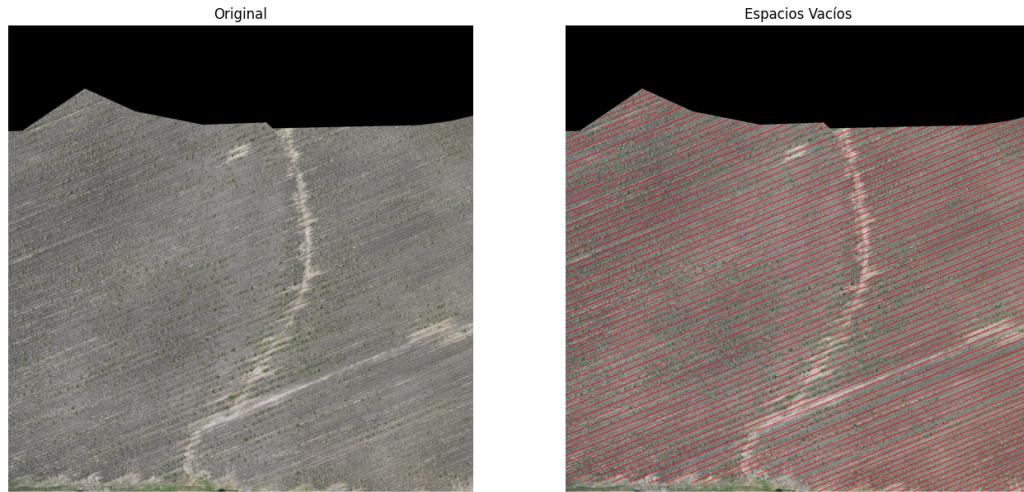


Figura 6.47: Espacios vacíos detectados con Transformada de Fourier.

Los resultados numéricos y visuales de los tres métodos se muestran a continuación. Los valores obtenidos para el porcentaje de espacios vacíos, porcentaje relativo al área válida y la longitud total medida en metros se detallan en la Tabla 6.4.

Tabla 6.4: Resultados de detección de espacios vacíos para la tercera imagen.

Método	Porcentaje vacío (%)	Porcentaje válido (%)	Longitud total (m)
Transformada de Hough	1.99	2.01	15 416.51
PCA	2.71	2.74	20 157.30
Transformada de Fourier	2.15	2.18	16 700.69

En términos generales, los tres métodos muestran una correspondencia adecuada entre las líneas detectadas y las estructuras reales en la imagen, confirmando que el enmascaramiento aplicado al área inferior (Figura 6.38) permitió eliminar elementos irrelevantes y mejorar la consistencia angular del análisis. Por lo tanto, esta tercera imagen sirve como validación de la efectividad de las máscaras y de la robustez del procedimiento de cuantificación de espacios vacíos.

Para la cuarta imagen, se puede observar un entorno ideal, donde no existen estructuras anómalas ni irregulares ni espacios irrelevantes. Por lo tanto, no se optó por utilizar una máscara.

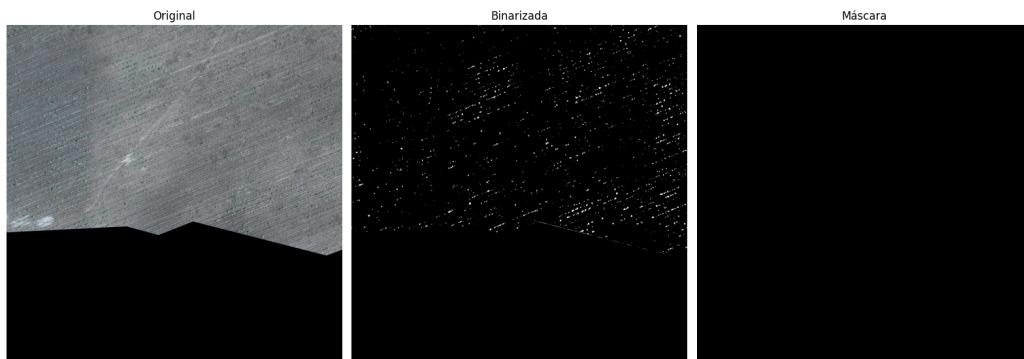


Figura 6.48: Cuarta imagen aérea.

Con un umbral de 150, el algoritmo con Transformada de Hough produce resultados considerablemente buenos, donde las líneas detectadas son consistentes con la estructura de los surcos y sin líneas redundantes o que intersecten. En total, se encontraron 10 líneas con 67 inferidas.

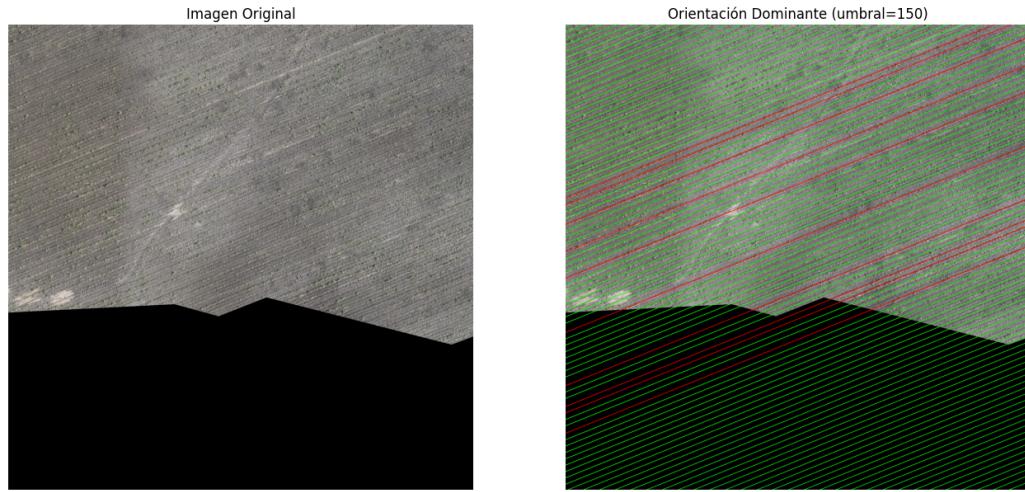


Figura 6.49: Líneas detectadas e inferidas por algoritmo con Transformada de Hough.

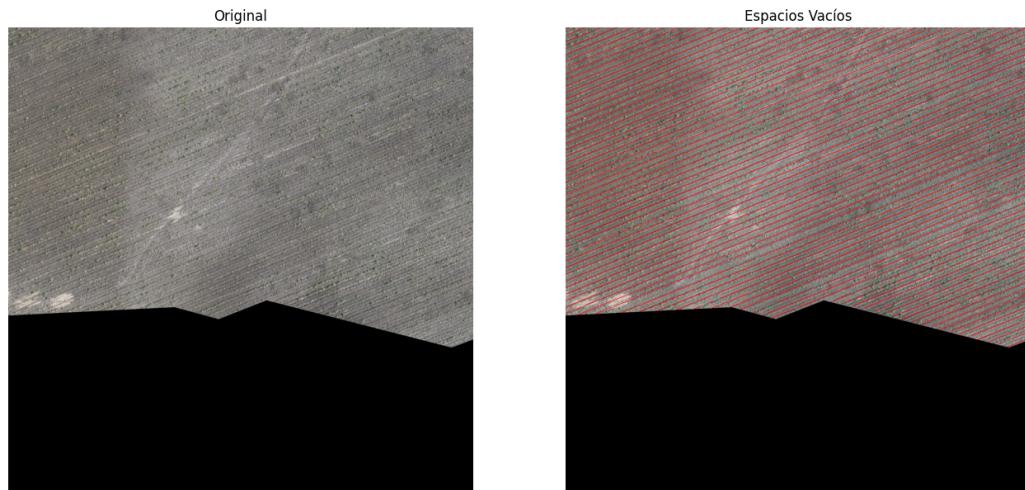


Figura 6.50: Espacios vacíos detectados con Transformada de Hough.

En este caso, tanto el algoritmo basado en PCA como el de Fourier identificaron ángulos prácticamente idénticos, con una diferencia menor a 1, lo que se refleja en la similitud entre las Figuras 6.52 y 6.56. El método de Hough también obtuvo resultados precisos (Figura 6.49), aunque con una leve subestimación en la longitud total (Tabla 6.5).

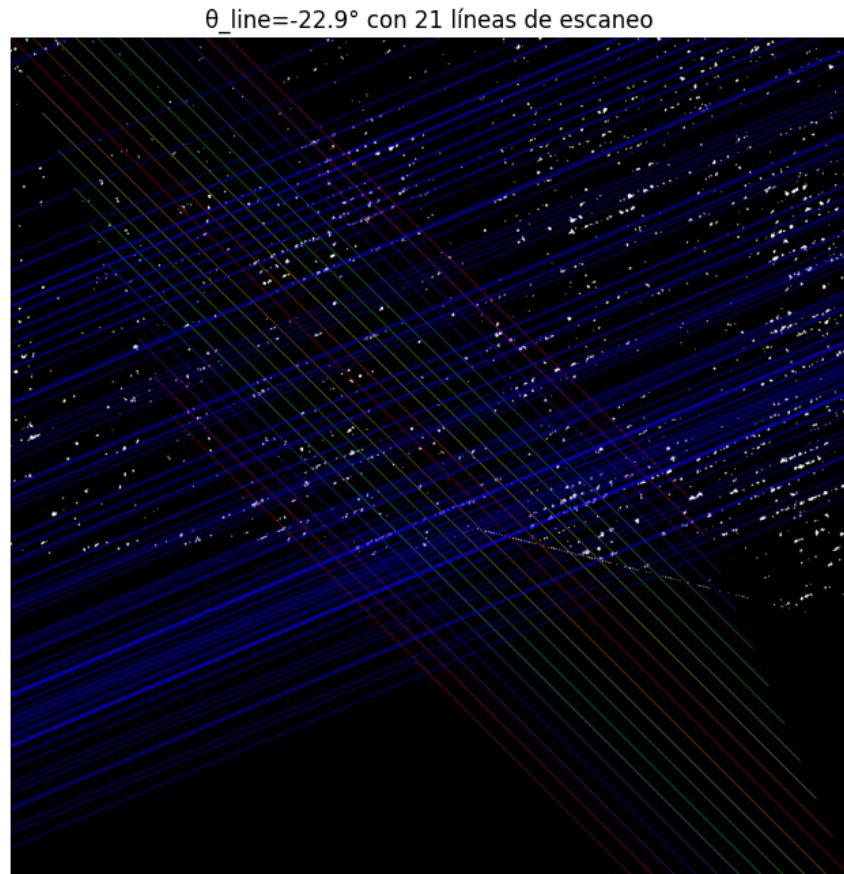


Figura 6.51: Líneas de escaneo con ángulo determinado por PCA.

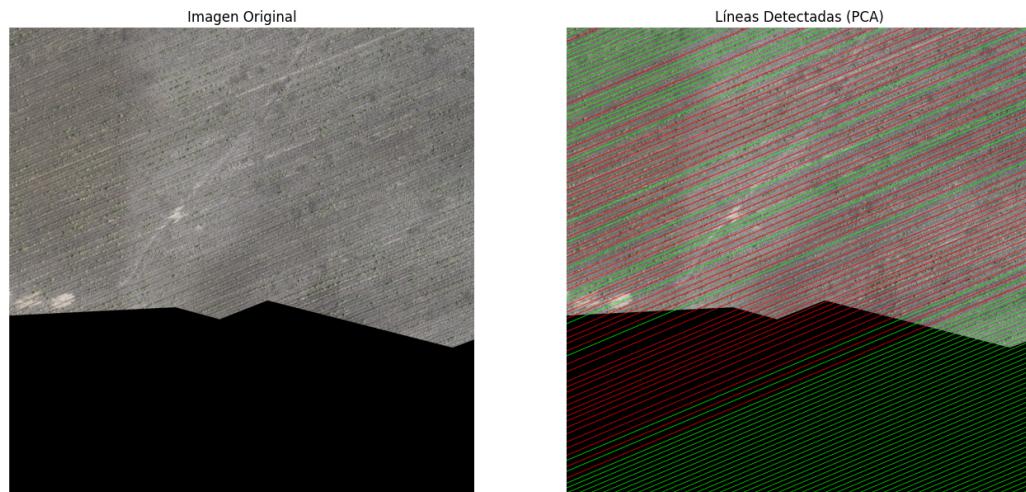


Figura 6.52: Líneas detectadas e inferidas por algoritmo con PCA.

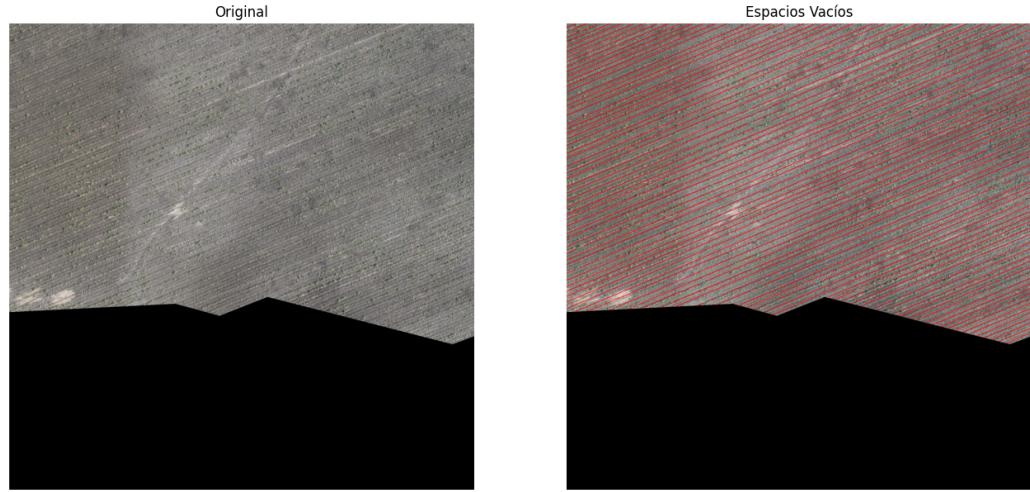


Figura 6.53: Espacios vacíos detectados con PCA.

Puntos Dominantes en Espectro de Magnitud

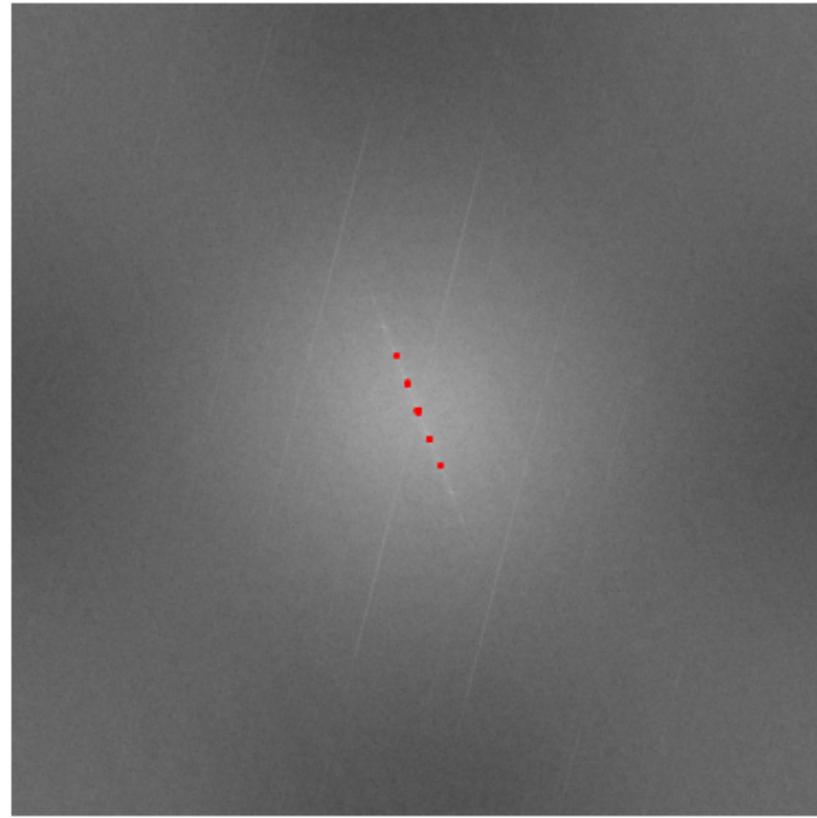


Figura 6.54: Espectro de magnitud (escala logarítmica) y puntos más intensos.

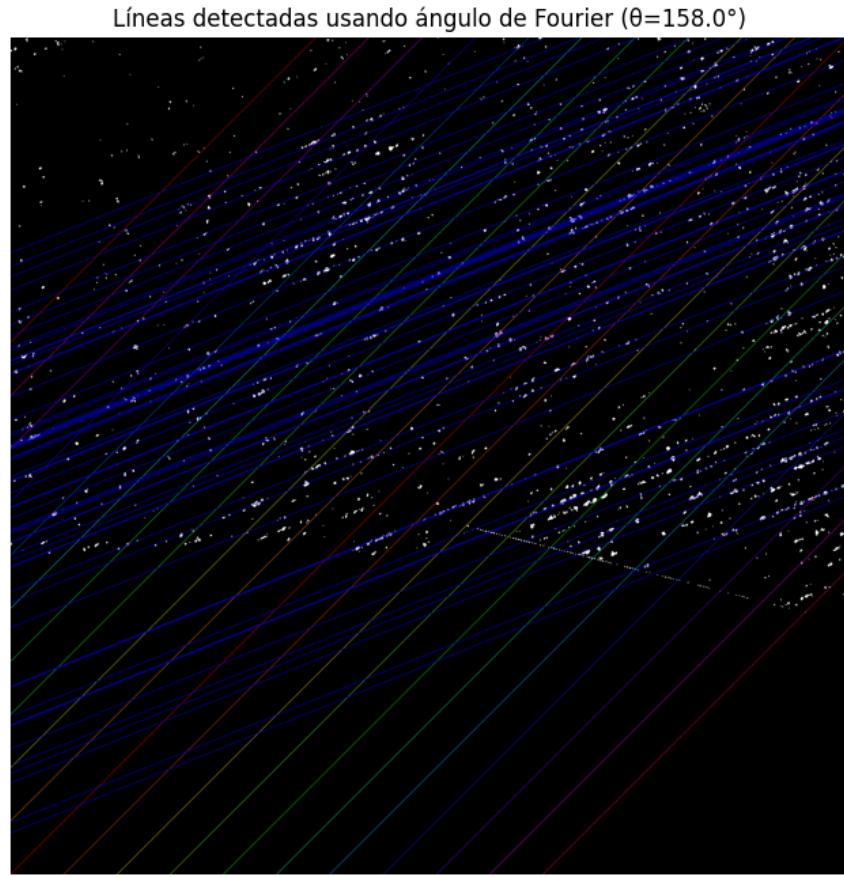


Figura 6.55: Líneas de escaneo con ángulo determinado por Transformada de Fourier.

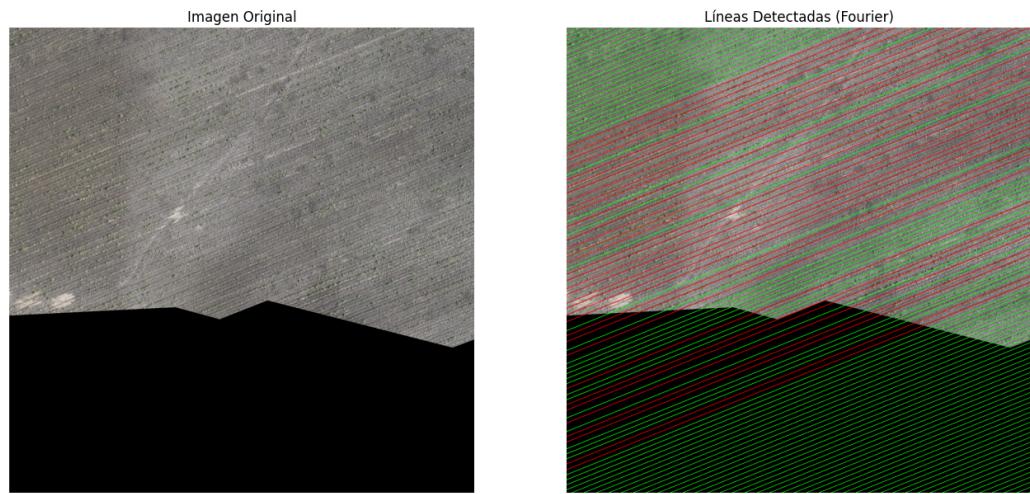


Figura 6.56: Líneas detectadas e inferidas por algoritmo con Transformada de Fourier.

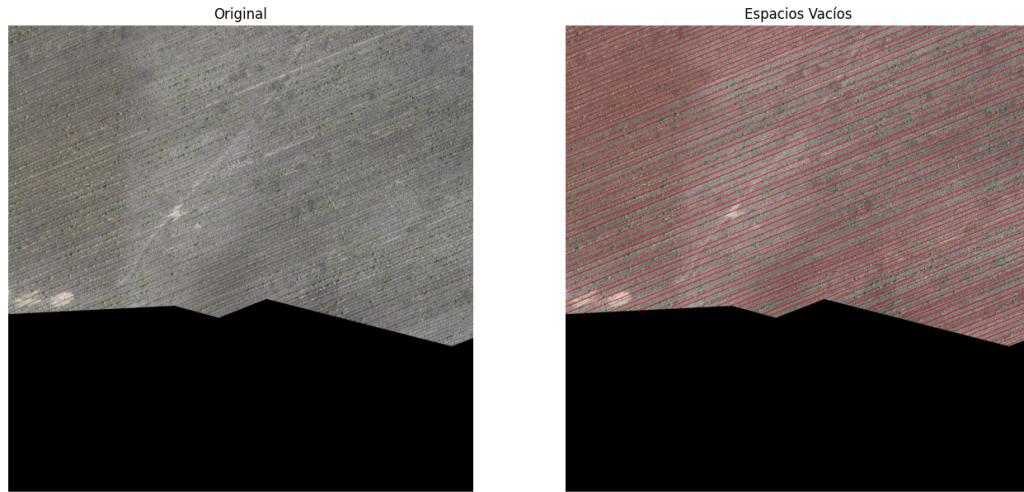


Figura 6.57: Espacios vacíos detectados con Transformada de Fourier.

Los resultados cuantitativos de los tres métodos se resumen en la Tabla 6.5. Puede observarse que todos presentan valores muy similares, lo que confirma la homogeneidad de la imagen y la correcta orientación de las líneas detectadas.

Tabla 6.5: Resultados de detección de espacios vacíos para la cuarta imagen.

Método	Porcentaje vacío (%)	Porcentaje válido (%)	Longitud total (m)
Transformada de Hough	2.00	2.00	19 165.07
PCA	2.13	2.13	21 644.53
Transformada de Fourier	2.12	2.12	21 645.41

Dado que la imagen no contiene estructuras anómalas ni regiones enmascaradas (Figura 6.48), todos los métodos presentan un desempeño óptimo, con detecciones de líneas y de espacios vacíos (Figuras 6.50, 6.53 y 6.57) altamente consistentes entre sí.

La quinta imagen representa un caso donde no es posible obtener un resultado óptimo sin modificar la imagen original. Como se observa en la Figura 6.58, esta posee una estructura compuesta por dos conjuntos de surcos con orientaciones distintas. La mitad superior contiene surcos predominantemente verticales, mientras que la mitad inferior presenta surcos inclinados en un ángulo. Entre ambas regiones, existen figuras irregulares que interfieren con la detección, las cuales deben eliminarse mediante una máscara, como se muestra en la Figura 6.59, para evitar que el análisis de PCA genere resultados incorrectos, como se evidenció en la Figura 6.31.

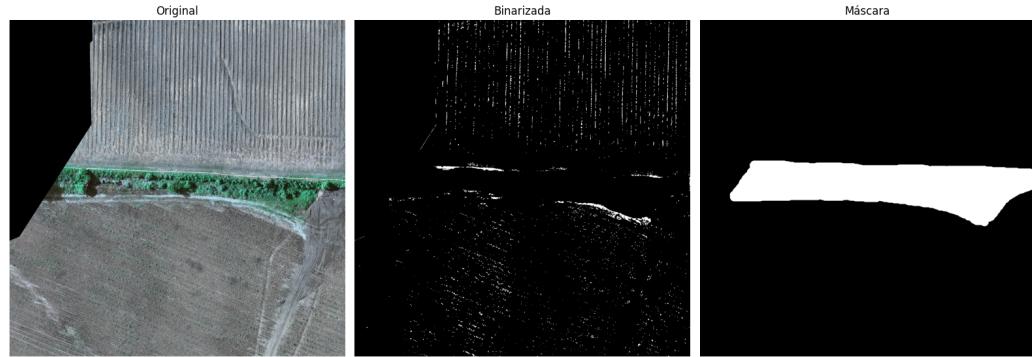


Figura 6.58: Quinta imagen aérea.



Figura 6.59: Máscara aplicada a la imagen binaria.

El algoritmo basado en la Transformada de Hough, con un umbral de 150, determinó que el conjunto dominante de surcos corresponde a la mitad superior de la imagen. En consecuencia, las líneas detectadas e inferidas (Figura 6.60) son correctas únicamente para esa región, pero erróneas en la parte inferior. En total, se detectaron 22 líneas con 53 líneas inferidas. Sin embargo, tras una inspección visual, se observó que faltan dos surcos en la parte superior.

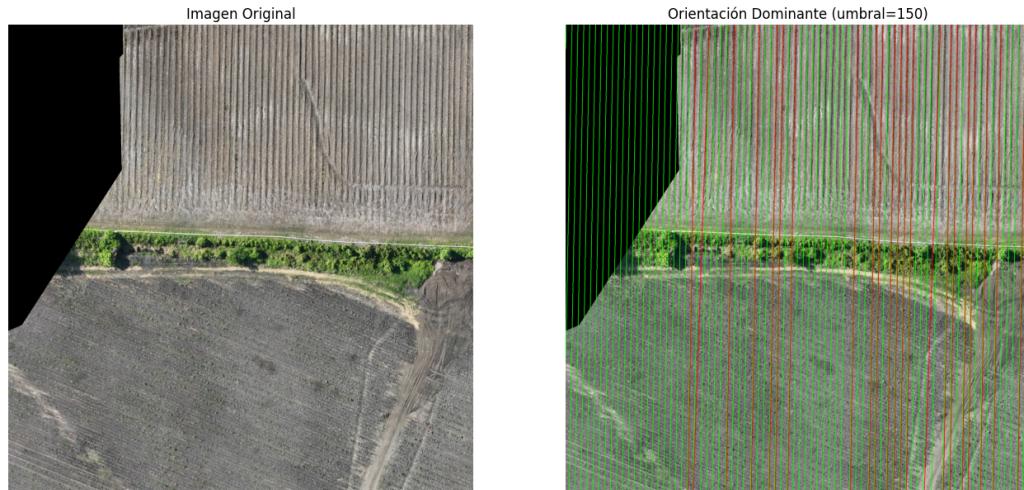


Figura 6.60: Líneas detectadas e inferidas por el algoritmo con Transformada de Hough.

La detección de espacios vacíos presenta el mismo patrón, donde la mitad superior de la Figura 6.61 muestra resultados correctos, mientras que la inferior contiene errores significativos debido a la diferencia de orientación entre ambos grupos de surcos.

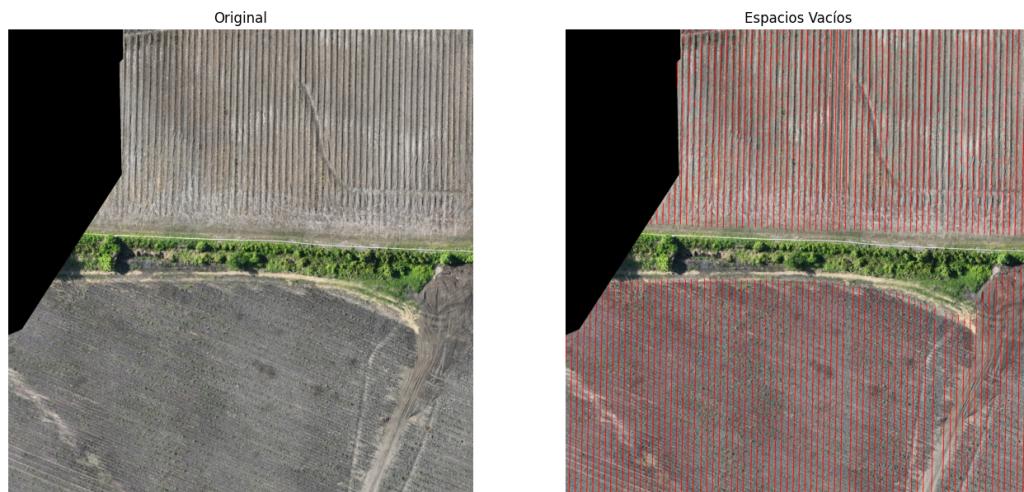


Figura 6.61: Espacios vacíos detectados con Transformada de Hough.

Por su parte, el algoritmo basado en PCA produjo resultados similares. En la Figura 6.62 se observa que el ángulo estimado sólo es correcto para la mitad superior, mientras que en la Figura 6.63 las líneas detectadas e inferidas se ajustan de forma parcial. Aunque ambos métodos fallan en la parte inferior, la principal diferencia radica en la proporción entre líneas detectadas e inferidas, ya que el algoritmo de PCA únicamente infirió 14 líneas, mientras que las restantes fueron detectadas directamente. Adicionalmente, la detección de espacios vacíos (Figura 6.64) también falla considerablemente debido a la división de la estructura en la imagen.

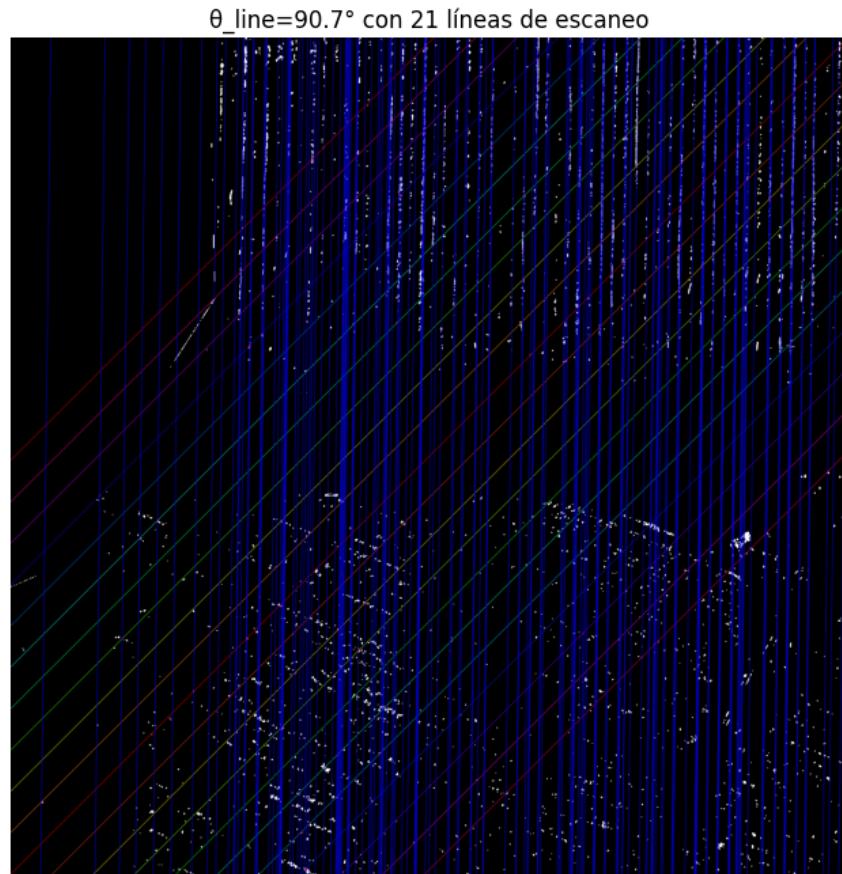


Figura 6.62: Líneas de escaneo con ángulo determinado por PCA.

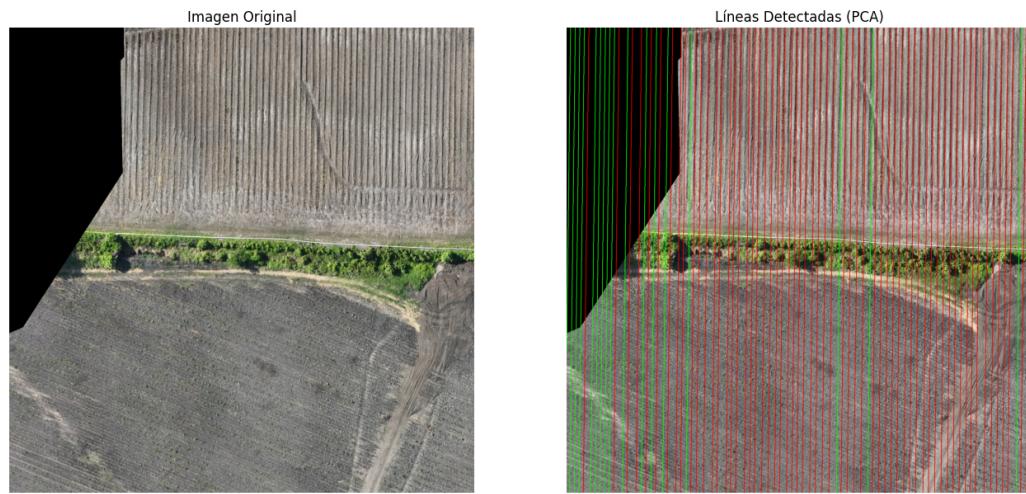


Figura 6.63: Líneas detectadas e inferidas por el algoritmo con PCA.



Figura 6.64: Espacios vacíos detectados con PCA.

El espectro de magnitud generado mediante la Transformada de Fourier (Figura 6.65) indica que la estructura lineal principal corresponde nuevamente a la mitad superior, ya que los $N = 20$ puntos más intensos se alinean sobre la línea perpendicular a esta orientación. Esto conlleva a un ángulo prácticamente idéntico al obtenido por PCA, lo que explica la similitud de las líneas (Figura 6.67) y los espacios vacíos (Figura 6.68) generados por ambos métodos.

Puntos Dominantes en Espectro de Magnitud

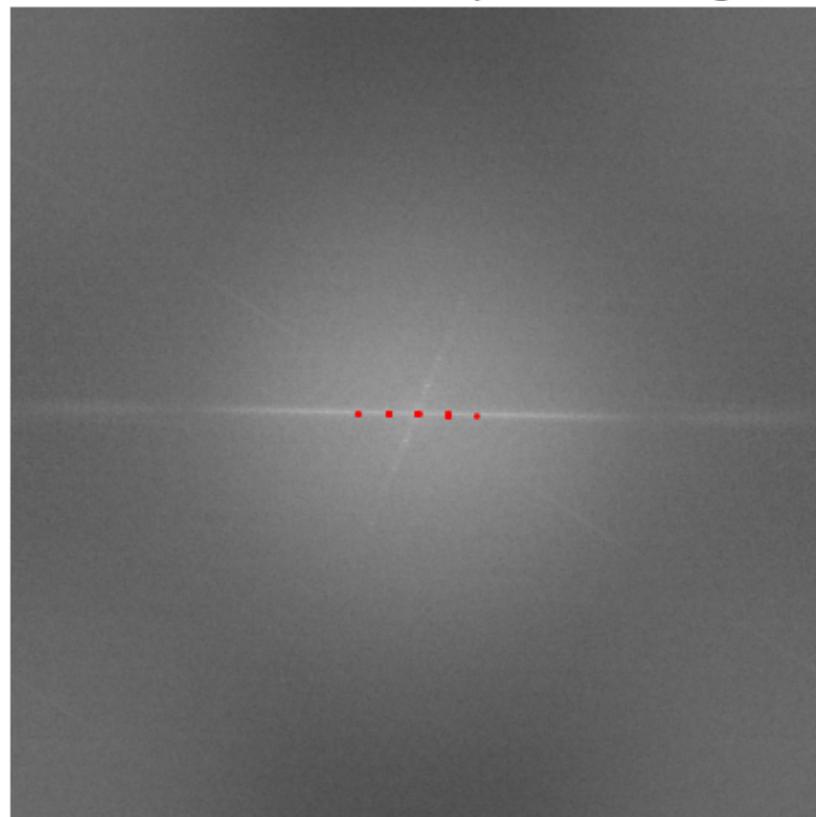


Figura 6.65: Espectro de magnitud (escala logarítmica) y puntos más intensos.

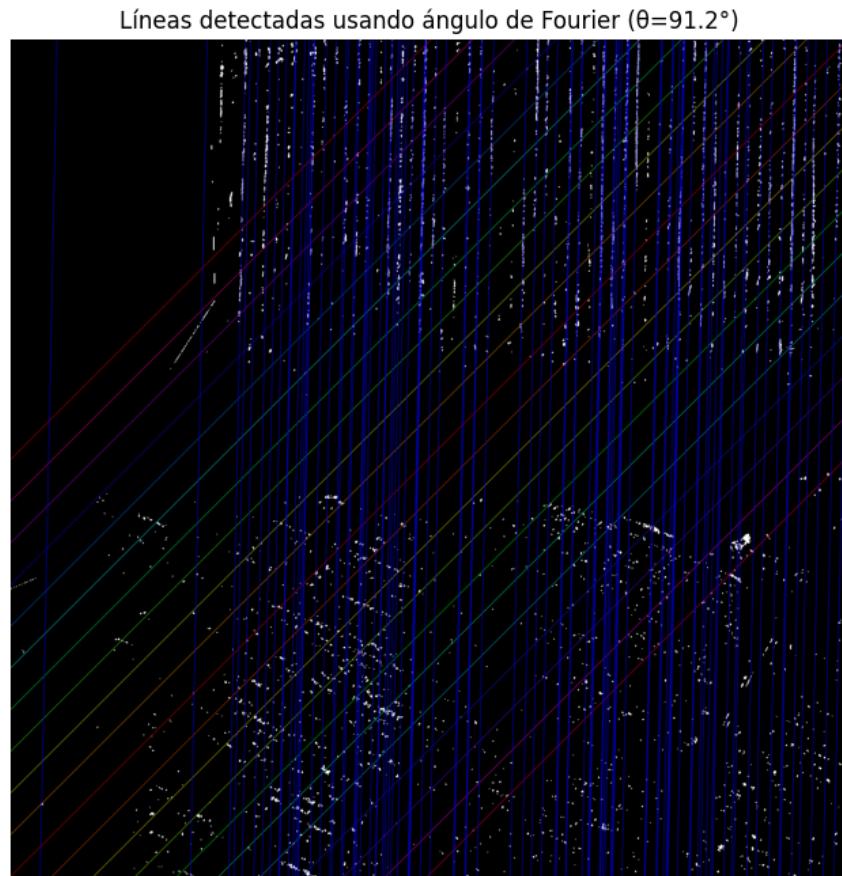


Figura 6.66: Líneas de escaneo con ángulo determinado por Transformada de Fourier.

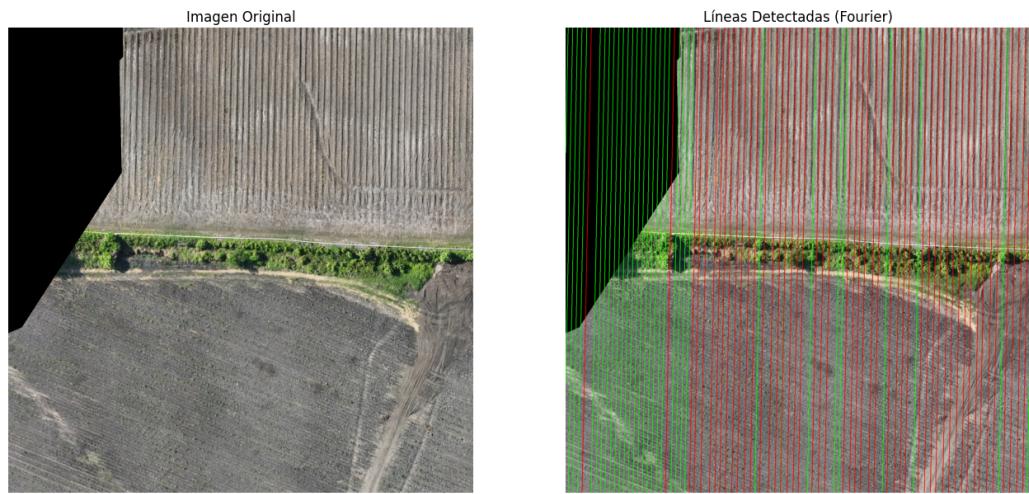


Figura 6.67: Líneas detectadas e inferidas por el algoritmo con Transformada de Fourier.

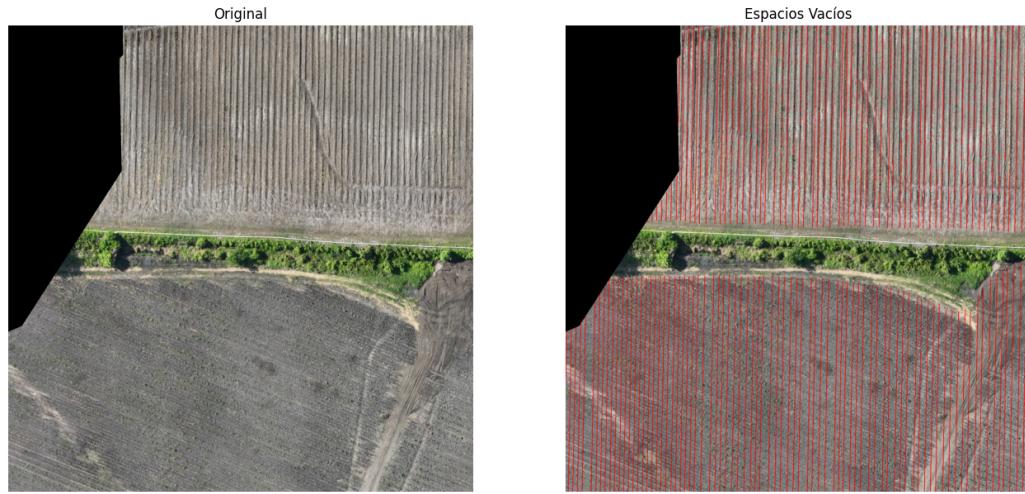


Figura 6.68: Espacios vacíos detectados con Transformada de Fourier.

Los resultados cuantitativos se resumen en la Tabla 6.6, donde se observa que los tres métodos producen valores similares de proporción de píxeles vacíos y longitud total estimada, con ligeras variaciones debido a las diferencias en detección de líneas y orientación.

Tabla 6.6: Resultados cuantitativos para la quinta imagen.

Método	Porcentaje vacío (%)	Porcentaje válido (%)	Longitud total (m)
Transformada de Hough	2.40	2.67	18,733.43
PCA	2.57	2.87	20,693.23
Transformada de Fourier	2.67	2.98	20,260.39

CAPÍTULO 7

Discusión de Resultados

Los resultados obtenidos evidencian tanto el potencial como las limitaciones del enfoque propuesto para la detección y cuantificación de espacios vacíos en cultivos a partir de imágenes aéreas binarizadas. En términos generales, los tres métodos evaluados presentan desempeños consistentes cuando las imágenes poseen una estructura clara y libre de elementos ajenos a los surcos. Sin embargo, la calidad de las imágenes provenientes del *pipeline* externo y la falta de máscaras precisas influyen directamente en la precisión de los resultados.

Una de las limitaciones más relevantes radica en la pérdida de detalle durante el proceso de binarización. En ciertas imágenes, como se observa en la Figura 6.48, la información de los surcos en la esquina superior izquierda se pierde parcialmente, lo cual provoca que el algoritmo identifique erróneamente segmentos sobre cultivos como espacios vacíos (Figura 6.57). Este tipo de error no proviene de las técnicas de análisis espacial, sino de la representación binarizada en sí, que omite regiones cultivadas debido a su baja respuesta de intensidad o diferencias de textura.

Otro problema significativo ocurre cuando el proceso de binarización conserva componentes no relacionados con el área cultivada, como vegetación adyacente, caminos o arbustos. En la Figura 6.16, por ejemplo, dichos elementos son incluidos como regiones relevantes, lo que afecta especialmente al algoritmo de PCA, pues este método es sensible a la presencia de componentes masivos que alteran la orientación del vector principal. En los casos donde esto ocurre, el PCA tiende a calcular ángulos erróneos, resultando en una detección incorrecta de las líneas y, por ende, en métricas de vacíos inexactas.

Debido a estas limitaciones, es necesario aplicar máscaras manuales para excluir zonas irrelevantes y aislar únicamente las áreas de cultivo. Aunque este procedimiento mejoró la coherencia angular y la precisión en la cuantificación en los casos analizados, se reconoce que la creación manual de máscaras no es una solución escalable. En el sistema externo, dichas máscaras se generarán dentro del *pipeline* junto con las imágenes binarizadas, permitiendo así una integración más robusta y generalizable. Sin embargo, persisten errores en la delimitación de bordes o en la segmentación de cultivos de baja densidad, lo que limita la fiabilidad total de las mediciones.

En cuanto al desempeño de cada algoritmo, el método basado en la Transformada de Hough depende fuertemente de la selección del umbral de detección. En este trabajo, dicho parámetro se determinó mediante un enfoque de fuerza bruta, escogiendo el valor que produjera la mayor cantidad de líneas válidas tras el filtrado y agrupamiento. No obstante, esta estrategia puede fallar cuando umbrales bajos generan un gran número de líneas con ángulos incorrectos. Una posible

mejora consistiría en combinar los resultados obtenidos con distintos umbrales y calcular el ángulo predominante, lo cual podría aumentar la estabilidad del método. Sin embargo, este enfoque perdería parte de las ventajas intrínsecas de la Transformada de Hough, como lo es la localización espacial precisa de líneas, y dependería en mayor medida del algoritmo de escaneo, que puede volverse computacionalmente costoso para valores altos de k o imágenes de gran tamaño.

En cuanto a la Transformada de Fourier, su desempeño fue generalmente sólido, especialmente en imágenes con patrones periódicos claros. No obstante, existen casos en los que el espectro de magnitud no presenta una estructura lineal definida, impidiendo la estimación precisa del ángulo dominante. Esta limitación es inherente a la naturaleza global del análisis de Fourier, que tiende a confundir componentes frecuenciales no orientados con información direccional relevante.

Finalmente, el PCA demostró ser un método muy sensible a la calidad de la segmentación, pero con un rendimiento excelente en imágenes limpias y correctamente enmascaradas. En estos casos, logró ángulos consistentes con los obtenidos mediante Fourier, confirmando su validez como alternativa computacionalmente eficiente para determinar la orientación dominante de los surcos.

Los resultados confirman que la consistencia angular y la calidad del enmascaramiento son los factores que más influyen en la exactitud de la cuantificación de espacios vacíos. Si bien los tres algoritmos pueden producir estimaciones confiables bajo condiciones adecuadas, su desempeño se degrada significativamente cuando las imágenes presentan ruido, pérdida de detalle o componentes irrelevantes.

CAPÍTULO 8

Conclusiones

A partir del desarrollo, implementación y análisis de los tres métodos propuestos para la detección de fallos en surcos de cultivos mediante imágenes aéreas, se obtienen las siguientes conclusiones:

1. Se desarrolló un método capaz de identificar espacios vacíos en surcos de cultivo utilizando técnicas de detección de líneas y cuantificación de vacíos. Dicho método permitió obtener métricas significativas de aprovechamiento del espacio de siembra y visualizar los resultados de forma clara y coherente con la estructura real de los cultivos.
2. Se diseñó un procedimiento efectivo para la detección de surcos de cultivos a partir de tres enfoques distintos: la Transformada de Hough, el Análisis de Componentes Principales (PCA) y la Transformada de Fourier. Cada método presentó ciertas ventajas, como Hough destaca por su precisión espacial, PCA por su eficiencia y Fourier por su robustez frente al ruido global. En conjunto, estos enfoques conforman una metodología versátil que puede adaptarse a distintos tipos de imágenes agrícolas.
3. La comparación entre métodos permitió identificar las condiciones en las que cada algoritmo resulta más adecuado. La Transformada de Hough mostró un desempeño sobresaliente cuando los surcos son lineales y bien definidos, aunque depende críticamente del umbral de detección. El PCA, en cambio, requiere imágenes limpias o enmascaradas para calcular correctamente la orientación de los surcos. Por su parte, la Transformada de Fourier demostró ser efectiva cuando la estructura del cultivo presenta patrones periódicos uniformes. Estas observaciones permiten seleccionar el método óptimo según las características de cada imagen aérea.
4. Se generaron representaciones visuales integradas con métricas cuantitativas que facilitan la interpretación de los resultados. Las figuras y tablas presentadas evidencian de manera intuitiva las líneas detectadas, los espacios vacíos y el aprovechamiento de espacio de cultivos, contribuyendo así a una evaluación visual y numérica del estado de los cultivos.
5. Se comprobó que la calidad de la imagen binarizada y del enmascaramiento tiene un impacto determinante en la precisión de todos los métodos. La pérdida de detalle en las etapas de segmentación o la presencia de componentes irrelevantes puede inducir errores en la orientación o la localización de los surcos. Por lo tanto, el éxito del método propuesto depende directamente de la calidad del *pipeline* de preprocesamiento.
6. La inclusión de máscaras manuales resultó esencial para eliminar componentes no relacionados con los cultivos, permitiendo mejorar la coherencia angular y la exactitud de las métricas. No

obstante, se reconoce que la creación manual de máscaras no es escalable y, por ello, futuras implementaciones deberían automatizar esta etapa dentro del flujo de procesamiento externo.

7. El trabajo contribuye al avance del análisis automatizado de imágenes agrícolas al proponer una metodología cuantitativa para la identificación de fallos en cultivos. Los resultados obtenidos validan la viabilidad de integrar estos algoritmos en sistemas de monitoreo agrícola de precisión, con potencial para optimizar el uso del espacio de siembra y apoyar la toma de decisiones agronómicas basadas en datos objetivos.

CAPÍTULO 9

Recomendaciones

A partir de los resultados obtenidos y las limitaciones identificadas en el presente estudio, se proponen las siguientes recomendaciones para mejorar la precisión, eficiencia y escalabilidad del método desarrollado:

1. **Optimización del preprocesamiento** Se recomienda centrar los esfuerzos en la mejora de las etapas iniciales del *pipeline*, particularmente en la generación automática de máscaras y la binarización de las imágenes. La calidad de estas fases determina en gran medida la fidelidad con que los algoritmos de detección representan la estructura real del cultivo. El uso de técnicas de segmentación basadas en aprendizaje profundo, o enfoques híbridos que integren información espectral y espacial, podría reducir la pérdida de detalle y mejorar la separación entre regiones cultivadas y no cultivadas.
2. **Automatización de la selección de umbrales en la Transformada de Hough.** El desempeño del algoritmo de Hough depende de manera crítica del umbral de detección utilizado. Por ello, se propone desarrollar un método de selección automática de umbrales, basado en análisis estadístico de la respuesta del espacio de acumulación o mediante técnicas de optimización heurística. Este enfoque permitiría mejorar la consistencia de la detección y eliminar la necesidad de ajuste manual.
3. **Filtrado adaptativo de líneas redundantes** El algoritmo actual utiliza parámetros de tolerancia angular y espacial para agrupar líneas cercanas. Sin embargo, el equilibrio entre ambos parámetros puede resultar problemático cuando existen múltiples surcos con separaciones muy pequeñas. Se recomienda implementar un filtrado más estricto, basado en métricas de densidad local, análisis de clústeres o intersecciones, con el fin de eliminar líneas redundantes y conservar únicamente las que representen surcos reales.
4. **Evaluación sobre un conjunto de datos ampliado** Sería conveniente realizar pruebas sobre un conjunto más extenso y diverso de imágenes aéreas, obtenidas en distintas condiciones de iluminación, etapas de crecimiento y tipos de cultivo. Esto permitiría establecer métricas de desempeño más completas y determinar la escalabilidad del método en entornos reales de monitoreo agrícola.
5. **Optimización computacional** Aunque el proceso actual resulta efectivo, algunos pasos, como el escaneo de líneas o la detección de vacíos, pueden volverse costosos para imágenes de gran tamaño o con alta resolución. La paralelización de estos procesos o su implementación en

GPU permitiría reducir considerablemente los tiempos de ejecución, facilitando su aplicación en sistemas de análisis a gran escala.

6. **Desarrollo de una interfaz visual de análisis** Finalmente, se recomienda la creación de una herramienta gráfica que integre todos los módulos del proceso, desde el preprocesamiento hasta la visualización de resultados. Esto no solo facilitaría la validación visual de las detecciones, sino que también permitiría ajustar parámetros en tiempo real y adaptar el flujo de trabajo a distintos escenarios de cultivo.

Bibliografía

- Balafoutis, A. T., Van Evert, F. K., & Fountas, S. (2020). Smart Farming Technology Trends: Economic and Environmental Effects, Labor Impact, and Adoption Readiness. *Agronomy*, 10(5), 743. <https://doi.org/10.3390/agronomy10050743>
- Banco de Guatemala. (n.d.). VII. *La Producción de Bienes y Servicios* [Recuperado de <https://banguat.gob.gt/page/vii-la-produccion-de-bienes-y-servicios>]. <https://banguat.gob.gt/page/vii-la-produccion-de-bienes-y-servicios>
- Duda, R. O., & Hart, P. E. (1972). *Pattern Classification and Scene Analysis*. Wiley.
- Fisher, R. B., Perkins, S., Walker, A., & Wolfart, E. (2003). Fourier Transform [Recuperado el 16 de agosto de 2025, de <https://homepages.inf.ed.ac.uk/rbf/HIPR2/fourier.htm>].
- Gerig, G. (1987). Linking image-space and accumulator space: a new approach for object recognition. *Proceedings of the IEEE First International Conference on Computer Vision*, 112-117.
- Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4.^a ed.). Pearson.
- Gutiérrez, K., Moralez, R., Díaz, O., & Ruiz, E. (2018). Sistema de procesamiento de imágenes multiespectrales aéreas para agricultura de precisión. *Sistemas & Telemática*, 16(47), 45-58. <https://doi.org/10.18046/syt.v16i47.3221>
- Hough, P. V. C. (1962). Method and Means for Recognizing Complex Patterns. *U.S. Patent 3,069,654*.
- Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 374(2065), 20150202. <https://doi.org/10.1098/rsta.2015.0202>
- Juvells, I., Vallmitjana, S., Carnicer, A., & Campos, J. (1991). The role of amplitude and phase of the Fourier transform in the digital image processing. *American Journal of Physics*, 59(8), 744-748. <https://doi.org/10.1119/1.16754>
- Kiryati, N., Eldar, Y., & Bruckstein, A. M. (1991). A probabilistic Hough transform. *Pattern Recognition*, 24(4), 303-316.
- Lee, Y.-S., Koo, H.-S., & Jeong, C.-S. (2006). A straight line detection using principal component analysis. *Pattern Recognition Letters*, 27(14), 1744-1754. <https://doi.org/10.1016/j.patrec.2006.04.016>
- Matas, J., Galambos, C., & Kittler, J. (2000). Robust Detection of Lines Using the Progressive Probabilistic Hough Transform. *Computer Vision and Image Understanding*, 78(1), 119-137. <https://doi.org/10.1006/cviu.1999.0831>
- Miyake, S., & Bargiel, D. (2017). 'Underutilised' agricultural land: its definitions, potential use for future biomass production and its environmental implications [Abstract 626]. *EGU General Assembly 2017*.
- Nagabhushan, P., Guru, D. S., & Shekar, B. H. (2005). Eigen transformation based edge detector for gray images. *Pattern Recognition and Machine Intelligence (PReMI 2005)*, 3776, 434-440. https://doi.org/10.1007/11551222_65

- Oliveira, H. C., Guizilini, V. C., Nunes, I. P., & Souza, J. R. (2018). Failure detection in row crops from UAV images using morphological operators. *IEEE Geoscience and Remote Sensing Letters*, 15(7), 991-995. <https://doi.org/10.1109/LGRS.2018.2819944>
- Osco, L. P., Marcato Junior, J., Ramos, A. P. M., Jorge, L. A. d. C., Fatholahi, S. N., Silva, J. d. A., Matsubara, E. T., Pistori, H., Gonçalves, W. N., & Li, J. (2021). A Review on Deep Learning in UAV Remote Sensing [arXiv preprint arXiv:2101.10861].
- Rejeb, A., Abdollahi, A., Rejeb, K., & Treiblmaier, H. (2022). Drones in agriculture: A review and bibliometric analysis. *Computers and Electronics in Agriculture*, 198, 107017. <https://doi.org/10.1016/j.compag.2022.107017>
- Rockmore, D. N. (1999). The FFT—An Algorithm the Whole Family Can Use [Departments of Mathematics and Computer Science, Dartmouth College]. *Computing in Science & Engineering*, 1(1), 60-64.
- Shekar, B. H., Guru, D. S., & Nagabhushan, P. (2006). Object recognition through the principal component analysis of spatial relationship amongst lines. *Asian Conference on Computer Vision (ACCV 2006)*, 3851, 170-179. https://doi.org/10.1007/11612704_18
- Sishodia, R. P., Ray, R. L., & Singh, S. K. (2020). Applications of Remote Sensing in Precision Agriculture: A Review. *Remote Sensing*, 12(19), 3136. <https://doi.org/10.3390/rs12193136>